



Deep Learning Foundations and Concepts 1주차

김호중 / 2026.01.23



Computational Data Science LAB


CONTENTS

1. The Deep Learning Revolution
2. Machine Learning Tutorial: Polynomial Curve Fitting
3. Probability Theory
4. Probability Distributions & MLE
5. Information Theory
6. Bayesian Methods

01 | Deep Learning Revolution


Impact of Deep Learning

- Medical Diagnosis (Classification)
 - ✓ 피부 병변 이미지(피부암 흑색종 vs 양성 모반) 분류 문제에서 딥러닝은 2,500만 개의 파라미터를 학습하여 전문의 수준의 정확도를 달성
 - ✓ Transfer Learning (전이 학습): 128만 장의 일반 이미지로 사전 학습된 네트워크를 상대적으로 적은 수 (129,000장)의 병변 데이터로 미세 조정(Fine-tuning)하여 데이터 부족 문제 해결
 - Protein Structure Prediction (Regression/Structure)
 - ✓ 아미노산 서열(1차원 정보)로부터 단백질의 3차원 입체 구조를 예측하는 난제 해결
 - Image Synthesis (Generative AI)
 - ✓ Unsupervised Learning (비지도 학습): 레이블이 없는 이미지 데이터의 통계적 속성을 학습하여 새로운 이미지를 생성
 - Large Language Models (LLM)
 - ✓ Self-Supervised Learning (자기 지도 학습): 방대한 텍스트 데이터에서 다음 단어 예측이라는 목표로 학습
- ❖ 컴퓨터 비전, 자연어 처리, 생물학 등 상이한 분야가 딥러닝(Deep Neural Networks)이라는 단일 프레임워크로 통합



02 | Machine Learning Tutorial: Polynomial Curve Fitting

Linear Models for Regression



- Problem Definition

- ✓ 주어진 입력 x 에 대해 목표값 t 를 예측하는 Supervised Learning (지도 학습) 문제
- ✓ Data Generation: $t_n = \sin(2\pi x_n) + noise$

- Polynomial Model

$$y(x, w) = w_0 + w_1 x + w_2 x^2 + \dots + w_M x^M = \sum_{j=0}^M w_j x^j$$

- ✓ Parameters

M : 다항식의 차수. 모델의 복잡도를 결정하는 파라미터
 w : 학습해야 할 가중치(Coefficients)

- ✓ Linear Regression

이 모델은 입력 x 에 대해서는 비선형이지만, 파라미터 w 에 대해서는 선형(Linear) 함수

02 | Machine Learning Tutorial: Polynomial Curve Fitting

Error Minimization

- Loss Function (Objective Function):

- ✓ 학습 데이터셋 x 와 타겟 t 에 대해, 모델 예측값 $y(x_n, w)$ 와 실제값 t_n 의 차이를 최소화해야 함

- ✓ Sum of Squares Error (SSE):


$$E(w) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, w) - t_n\}^2$$

- ✓ Why 1/2? 미분 시 지수 2가 내려와서 상쇄되도록 하는 편의상 상수(최적해 위치에는 영향 없음)

- Optimization:

- ✓ 오차 함수 $E(w)$ 는 계수 w 에 대한 이차 함수임

- ✓ 따라서 기울기가 0인 지점에서 유일한 최솟값(Global Minimum)을 가지며, 이를 통해 닫힌 해(Closed-form solution)를 구할 수 있음




02 | Machine Learning Tutorial: Polynomial Curve Fitting

Overfitting & Generalization

- Root Mean Square Error (RMSE):
 - ✓ 데이터 개수 N 에 따른 스케일 차이를 보정하고, 타겟 변수와 같은 단위를 갖도록 변환

$$E_{RMS} = \sqrt{\frac{2E(w)}{N}}$$




- The Phenomenon of Overfitting ($M=9$):
 - ✓ Observation: $M=9$ 인 경우, 학습 데이터의 모든 점을 완벽하게 지나가서 $E(w) = 0$
 - ✓ Problem: 데이터 사이 공간에서 함수가 크게 진동하며, 새로운 데이터(Test data)에 대한 예측 성능은 저하
 - ✓ Cause: 계수 w 의 절댓값이 비정상적으로 커짐 → 이는 모델이 데이터의 구조가 아닌 '노이즈'까지 억지로 맞추려 했기 때문
 - ✓ Insight: 더 많은 데이터 혹은 정규화는 오버피팅을 완화

03 | Probability Theory

The Sum and Product Rules

- Variables: 확률 변수 X 는 x_i 값을, Y 는 y_j 값을 가짐
- Joint Probability (결합 확률): $p(X = x_i, Y = y_j) \rightarrow X$ 와 Y 가 동시에 발생할 확률
- The Sum Rule (합의 법칙): $p(X = x_i) = \sum_{j=1}^L p(X = x_i, Y = y_j)$
 - ✓ Y 에 대한 모든 경우의 수를 합치면(Marginalize), X 만의 확률(주변 확률)
- The Product Rule (곱의 법칙):
 - ✓ 조건부 확률(Conditional Probability). X 가 주어졌을 때 Y 의 확률
- Bayes' Theorem (베이즈 정리):
 - ✓ 곱의 법칙의 대칭성 $p(X, Y) = p(Y, X)$ 으로부터 유도
$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$
 - ✓ 의미: 결과(X)를 보고 원인(Y)을 추론하는 역확률 문제의 핵심



03 | Probability Theory

Bayes' Theorem in Medical Diagnosis

- Scenario:

- ✓ Prior (사전 확률): 전체 인구 중 암 환자 비율 $p(Cancer) = 0.01$

- ✓ Likelihood (우도 - 검사의 정확도):

- 암 환자가 양성일 확률: $p(+ | Cancer) = 0.9$

- 건강한 사람이 양성(오진)일 확률: $p(+ | Healthy) = 0.1$

- Problem: 어떤 사람이 검사에서 양성(+) 판정을 받았다. 실제로 암일 확률은?

- Calculation (Posterior):

$$p(Cancer | +) = \frac{p(+ | Cancer)p(Cancer)}{p(+)}$$

- 분모 $p(+)$ (정규화 상수) 계산 (합의 법칙):

$$p(+) = p(+|C)p(C) + p(+|H)p(H) = 0.9 \times 0.01 + 0.1 \times 0.99 = 0.009 + 0.099 = 0.108$$

- 최종 계산:

$$p(Cancer | +) = \frac{0.009}{0.108} = 0.083$$

- Conclusion: 양성 판정을 받아도 실제 암일 확률은 8.3%에 불과함 (직관과 다름, 낮은 사전 확률의 영향)

04 | Probability Distributions & MLE

The Gaussian Distribution

- Definition:

- ✓ 연속 변수 x 에 대한 가장 중요한 분포, 자연계의 많은 현상을 설명(중심극한정리)


$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\}$$

- Parameters:

- ✓ μ (Mean): 분포의 중심(Center), 기댓값 $E[x]$
- ✓ σ^2 (Variance): 분산, 분포의 퍼짐 정도
- ✓ $1 / \sigma^2$ (Precision): 정밀도, 분산의 역수

- Properties:

- ✓ 전체 구간 적분 시 1이 됨
- ✓ 주어진 분산에서 엔트로피(Entropy)를 최대화하는 분포



04 | Probability Distributions & MLE

Estimating Parameters from Data

- Likelihood Function (우도 함수):


- ✓ 데이터셋 $\mathbf{x} = (x_1, \dots, x_N)^T$ 가 *i.i.d.* (독립 항등 분포)로 추출되었다고 가정할 때, 파라미터가 데이터를 설명하는 확률

$$p(\mathbf{x}|\mu, \sigma^2) = \prod_{n=1}^N \mathcal{N}(x_n|\mu, \sigma^2)$$

- Log-Likelihood:

- ✓ 계산의 편의(곱셈 → 덧셈)를 위해 로그를 취함
- ✓ 단조 증가 함수이므로 최댓값 위치는 변하지 않음

$$\ln p(\mathbf{x}|\mu, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2 - \frac{N}{2} \ln \sigma^2 - \frac{N}{2} \ln(2\pi)$$



- MLE Solution:

- ✓ μ 에 대해 미분하여 0이 되는 값을 찾음 → Sample Mean (표본 평균) → $\mu_{ML} = \frac{1}{N} \sum_{n=1}^N x_n$
- ✓ σ^2 에 대해 미분하여 풀이 → Sample Variance (표본 분산) → $\sigma_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{ML})^2$

04 | Probability Distributions & MLE

From MLE to Least Squares

- Probabilistic Model:

- ✓ 타겟 값 t 는 결정론적 함수 $y(x, \mathbf{w})$ 에 가우시안 노이즈 ϵ 이 더해진 것

$$t = y(x, \mathbf{w}) + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \beta^{-1})$$

- ✓ 따라서 조건부 분포는:

$$p(t|x, \mathbf{w}, \beta) = \mathcal{N}(t|y(x, \mathbf{w}), \beta^{-1})$$

- Log-Likelihood Maximization:

$$\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta) = \sum_{n=1}^N \ln \mathcal{N}(t_n|y(x_n, \mathbf{w}), \beta^{-1})$$

$$= \frac{N}{2} \ln \beta - \frac{N}{2} \ln(2\pi) - \beta \left(\frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2 \right)$$


- Key Insight:

- ✓ 위 식에서 w 와 관련된 항은 마지막 항
- ✓ 로그 우도(Log-Likelihood)를 최대화하는 것은, 괄호 안의 오차 제곱합(Sum of Squares Error)을 최소화하는 것과 수학적으로 동일
- ✓ 즉, 우리가 직관적으로 사용한 최소제곱법(Least Squares)은 가우시안 노이즈를 가정한 MLE의 특수한 경우

05 | Information Theory

Quantifying Information

- Concept of Information:
 - ✓ 놀라움의 정도(Degree of surprise), 확률 $p(x)$ 가 낮을수록 그 사건이 발생했을 때 정보량은 큼
 - ✓ $h(x) = -\ln p(x)$
- Entropy (H):
 - ✓ 확률 변수 X 가 갖는 정보량의 기댓값(평균 정보량), 무질서도 또는 불확실성의 척도
 - ✓ $H[x] = -\sum_x p(x) \ln p(x)$
- Example:
 - ✓ 균등 분포(Uniform distribution)일 때 엔트로피가 최대(가장 불확실)
 - ✓ 특정 값의 확률이 1일 때 엔트로피는 0(확실)
- Continuous Variable:
 - ✓ 연속 변수의 경우 미분 엔트로피(Differential Entropy)로 정의
 - ✓ $H[x] = -\int p(x) \ln p(x)$



05 | Information Theory

Kullback-Leibler Divergence

- Definition:

- ✓ 실제 분포 $p(x)$ 를 근사 분포 $q(x)$ 로 모델링할 때 발생하는 정보 손실량(Information Loss)
- ✓ 두 확률 분포 간의 거리와 유사한 개념(거리 함수는 아님)


$$KL(p \parallel q) = - \int p(x) \ln\left(\frac{q(x)}{p(x)}\right) dx$$

- Properties:

- ✓ Non-negative: $KL(p \parallel q) \geq 0$ (Jensen 부등식에 의해 증명)
- ✓ 0이 되는 조건: $p(x) = q(x)$ 일 때만 0
- ✓ Asymmetric: $KL(p \parallel q) \neq KL(q \parallel p)$

- Relation to MLE:

- ✓ 데이터의 경험적 분포와 모델 분포 사이의 $KL Divergence$ 를 최소화하는 것은, 모델의 우도(Likelihood)를 최대화하는 것과 동치



05 | Information Theory

Mutual Information

- Conditional Entropy:

- ✓ x 값이 알려졌을 때, y 를 기술하기 위해 추가로 필요한 평균 정보량

$$H[y | x] = - \iint p(y, x) \ln p(y | x) dy dx$$

- ✓ Rule: $H[x, y] = H[x] + H[y | x]$


- Mutual Information (상호 정보량):

- ✓ 변수 x 와 y 가 독립이 아니므로써 공유하는 정보의 양

$$I[x, y] = KL(p(x, y) || p(x)p(y))$$

$$I[x, y] = H[x] - H[x | y] = H[y] - H[y | x]$$

- ✓ Meaning: x 를 알게 됨으로써 y 에 대한 불확실성이 얼마나 줄어드는가?
- ✓ x, y 가 독립이면 $I[x, y] = 0$



06 | Bayesian Methods

Bayesian View of Curve Fitting

- Frequentist vs. Bayesian:
 - ✓ Frequentist (빈도주의): 파라미터 w 는 고정된 값, 데이터가 확률 변수 (MLE 방식)
 - ✓ Bayesian (베이지안): 파라미터 w 자체를 확률 변수로 취급하여 불확실성을 모델링
- Prior Distribution (사전 확률):
 - ✓ 데이터를 보기 전 w 에 대해 우리가 가진 믿음/가정
 - ✓ 보통 평균이 0이고 정밀도가 α 인 가우스 분포를 사용

$$p(\mathbf{w}|\alpha) = \mathcal{N}(\mathbf{w}|\mathbf{0}, \alpha^{-1}\mathbf{I}) = \left(\frac{\alpha}{2\pi}\right)^{\frac{M+1}{2}} \exp\left\{-\frac{\alpha}{2}\mathbf{w}^T\mathbf{w}\right\}$$

- ✓ α (Alpha): Hyperparameter controlling the distribution of weights

06 | Bayesian Methods

Maximum A Posteriori (MAP)

- Posterior Distribution (사후 확률):
 - ✓ 데이터 $D = (x, t)$ 를 관측한 후 업데이트된 w 의 확률 분포
 - ✓ Bayes' Rule:

$$p(w|x, t, \alpha, \beta) \propto p(t|x, w, \beta)p(w|\alpha)$$

$$\text{Posterior} \propto \text{Likelihood} \times \text{Prior}$$

- Finding MAP Estimate:
 - ✓ 사후 확률을 최대화하는 w_{MAP} 를 찾기 위해 로그를 취함

$$\ln p(\mathbf{w} | \mathbf{t}) \iff \min_{\mathbf{w}} \left\{ \frac{1}{2} \sum_{n=1}^N (y(x_n, \mathbf{w}) - t_n)^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2 \right\}$$

06 | Bayesian Methods

Regularization from Probability

- Optimization Objective:

- ✓ MAP 추정을 위해 위 식의 음수(Negative Log Posterior)를 최소화해야 함

$$\frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2 + \frac{\lambda}{2} \mathbf{w}^T \mathbf{w}$$

- ✓ 여기서 $\lambda = \alpha / \beta$ 는 정규화 계수(Regularization coefficient)

- Conclusion:

- ✓ $L2$ Regularization (Ridge Regression):

머신러닝에서 과적합을 막기 위해 사용하는 '가중치 감쇠(Weight Decay)' 항이, 베이زي안 관점에서는 가우시안 사전 확률을 가정한 MAP 추정과 정확히 일치

- ✓ Significance:

확률론은 딥러닝의 손실 함수(Loss Function)와 정규화(Regularization) 기법이 왜 그런 형태를 띠는지에 대한 엄밀한 이론적 토대를 제공

Q&A

감사합니다.