



3. Standard Distributions/ 4. Single-layer Networks: Regression

안재국 / 2026.01.30



Computational Data Science LAB



CONTENTS



1. Multivariate Gaussian
 2. Mixture Gaussian distribution
 3. Nonparametric Methods
 4. Regression
 5. Decision Theory
 6. The Bias–Variance Trade-off
- 
- 

01 | Multivariate Gaussian

Statistical Justification



- 다변량 가우시안의 정의

- ✓ $\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right\}$

- ✓ $\boldsymbol{\mu}$: D 차원의 평균 벡터

- ✓ $\boldsymbol{\Sigma}$: $D \times D$ 의 Covariance Matrix(공분산 행렬)

- ✓ 1차원 가우시안을 고차원으로 확장한 모델



- Why Gaussian?

- ✓ 중심 극한 정리 : 독립적인 확률 변수들의 합은 N 이 커질수록 가우시안에 수렴하기 때문

- ✓ 평균과 분산이 주어졌을 때, 불확실성이 가장 큼

- ✓ 즉, 데이터에 대해 가장 가정을 적게 하는 분포임

01 | Multivariate Gaussian

Geometry of the Gaussian

- Geometrical form

- ✓ $\Delta^2 = (x - \mu)^T \Sigma^{-1} (x - \mu)$



- ✓ $\Delta =$ 마할라노비스 거리

- ✓ 공분산이 대칭행렬임으로 $\Sigma \mathbf{u}_i = \lambda_i \mathbf{u}_i$


- ✓ 공분산 행렬을 고유벡터로 표현 $\Sigma = \sum_{i=1}^D \lambda_i \mathbf{u}_i \mathbf{u}_i^T$

- ✓ 역행렬 $\Sigma^{-1} = \sum_{i=1}^D \frac{1}{\lambda_i} \mathbf{u}_i \mathbf{u}_i^T$

- ✓ 맨위식에 대입 $\Delta^2 = \sum_{i=1}^D \frac{y_i^2}{\lambda_i}$



파란색 점들의 분포를 고려한다면,
노란색 점들 간의 "상대적" 거리는
주황색 점들 간의 거리보다 더 멀다고 판단할 수 있다.



"맥락"을 고려한 데이터 공간의 변형 후에는
"맥락"을 특별히 고려할 필요가 없다.
눈에 보이는 그대로 노란색 점들 간의 거리가
주황색 점들 간의 거리보다 멀다.

01 | Multivariate Gaussian

MLE and Limitaitons

- Likelihood function

- ✓ 가정: 데이터는 하나의 다변량 가우시안에서 i.i.d.

- ✓
$$p(D; \mu, \Sigma) = \prod_{n=1}^N \mathcal{N}(x^{(n)}; \mu, \Sigma)$$

- MLE Solution

- ✓ 표본 평균

$$\hat{\mu} = \frac{1}{N} \sum_{n=1}^N x^{(n)}$$


- ✓ 표본 공분산 행렬

$$\hat{\Sigma} = \frac{1}{N} \sum_{n=1}^N (x^{(n)} - \hat{\mu})(x^{(n)} - \hat{\mu})^\top$$

- Gaussian 분포의 주요 한계

- ✓ 모수(parameter)의 개수: D 개의 차원을 가진 데이터에서 총 $D(D+3)/2$ 개의 독립적인 파라미터, D가 증가하면 제곱으로 증가
- ✓ 분포의 모양이 단봉(unimodal)의 형태

Unimodal example



02 | Gaussian Mixture Model

What Is Gaussian Mixture Model?

- Gaussian Mixture Model


✓
$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k N(\mathbf{x} | \mu_k, \Sigma_k)$$

✓ π_k 는 혼합 가중치로 확률이기 때문에 0과 1 사이이며, 전체 합은 1이 됨

✓ 충분한 개수의 가우시안 분포를 사용함으로써 거의 대부분의 연속 밀도를 임의의 정확도로 근사 가능함

✓ MLE SOLUTION
$$\ln p(\mathbf{X} | \boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right\}$$

✓ Direct MLE는 불가능 → EM Algorithm 사용



03 | Nonparametric Methods

Histogram

- Nonparametric Methods

- ✓ 모수적 방법은 실제 데이터 분포와 가정한 분포가 다를 경우 추정 결과가 왜곡될 수 있음 ex.(multi-modal)
- ✓ 분포 모양을 미리 정하지 않고 데이터 자체로 분포를 추정하는 방법

- Histogram

$$p_i = \frac{n_i}{N\Delta_i}$$


n_i : i 번째 구간에 들어간 데이터 수

N : 전체 데이터 수

Δ_i : bin의 너비(데이터가 들어갈 구간)

- Histogram의 한계

- ✓ Δ 선택에 매우 민감 들쭉날쭉 or 중요한 구조 놓침
- ✓ 차원이 커지면 bin수 폭발 고차원에선 x
- ✓ 불연속



03 | Nonparametric Methods

Kernel density estimators

- Kernel Function

- ✓ 모든 데이터 포인트 하나하나 중심으로 커널이라고 불리는 부드러운 곡선을 그린 후, 곡선들을 더해 전체 pdf 생성


- ✓ 조건

$$\int_{-\infty}^{\infty} K(u) du = 1$$

$$K(u) = K(-u), K(u) \geq 0, \forall u$$

- ✓ 수식

$$p(\mathbf{x}) = \frac{1}{N} \sum_{n=1}^N \frac{1}{h^D} k\left(\frac{\mathbf{x} - \mathbf{x}_n}{h}\right)$$



03 | Nonparametric Methods

Performance Statistics


- Issue : h (대역폭, bandwidth)

- ✓ 커널의 폭(얼마나 넓게 퍼뜨릴지)
- ✓ h 가 작으면 노이즈가 많아지고
- ✓ h 가 크면 구조가 사라짐

- Conclusion

- ✓ 학습이 필요없음
- ✓ 하지만, 데이터가 많아지면 느려짐
- ✓ 고정된 h 를 사용하기 때문에, 데이터 밀도의 지역적 변화에 유연하게 대응하지 못함

Bandwidth: The Critical Choice



- Difference between KDE and GMM

- ✓ “데이터 하나하나” vs “대표 그룹”

04 | Regression

Linear

- Regression is a Decision Problem
 - ✓ 우리는 여러 모델 후보 중 어떤 모델을 쓸지 결정해야 함
 - ✓ 따라서 회귀는 결정 문제
- Criterion
 - ✓ 어떤 모델이 더 좋은 모델인가? - 이에 대한 기준을 로스로 정의
 - ✓ 직관적인 로스 정의 $\text{error}_n = t_n - y(x_n)$
 - ✓ $\rightarrow SSE = \sum_{n=1}^N (t_n - y(x_n))^2$
- Question
 - ✓ 이는 단순히 경험적 기준일까 아니면 확률적으로 정당화될 수 있을까?

04 | Regression

SSE as Maximum Likelihood Estimation

- A Probabilistic Assumption

- ✓ 현실에서는 예측이 항상 정확할 수 없음 $t = y(x) + \epsilon$
- ✓ 따라서 회귀는 하나의 값이 아니라 확률분포를 예측
- ✓ 오차에 대한 가정 $\epsilon \sim N(0, \sigma^2)$
- ✓ 조건부 확률 $p(t | x, w) = N(t | y(x), \sigma^2)$

- MLE Equals Minimizing SSE

- ✓ 각 데이터가 나올 확률의 곱 $p(\mathbf{t} | \mathbf{X}) = \prod_{n=1}^N \mathcal{N}(t_n | y(x_n), \sigma^2)$

- ✓
$$\begin{aligned} \log p(\mathbf{t} | \mathbf{X}) &= \sum_{n=1}^N \log \mathcal{N}(t_n | y(x_n), \sigma^2) \\ &= -\frac{N}{2} \log(2\pi) - \frac{N}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{n=1}^N (t_n - y(x_n))^2 \end{aligned}$$

- ✓
$$\sum_{n=1}^N (t_n - y(x_n))^2$$

- ✓
$$\max \log p(\mathbf{t} | \mathbf{X}) \iff \min \sum_{n=1}^N (t_n - y(x_n))^2$$

- ✓ 즉, 가우시안 오차를 가정하면 SSE 최소화는
MLE와 정확히 같은 문제

- Likelihood 최대화가 항상 최선의 예측인가?

05 | Decision Theory

Expected loss

- Expected Loss


- ✓ 결정이론에서는 훈련 데이터에 대한 오차 합이 아니라 미래 데이터에 대한 기대 손실을 최소화하는 것이 목표

- ✓ 즉, 훈련 데이터가 미래 데이터와 같은 분포에서 i.i.d로 샘플링되었다면, $\frac{1}{N} \sum_{n=1}^N (y_n - f(x_n))^2 \xrightarrow{N \rightarrow \infty} \mathbb{E}[(Y - f(X))^2]$

- ✓ $\text{Test MSE} = \mathbb{E}[(Y - f(X))^2]$

- Optimal Prediction

- ✓ 기대 손실을 최소화하는 예측: $f^*(x) = \arg \min_f \mathbb{E}[(Y - f(x))^2 | x] = \mathbb{E}[Y | x]$




06 | The Bias–Variance Trade-off

MSE Decomposition

- Why Bias–Variance?
 - ✓ 현실에서는 직접 $f^*(x)$ 를 구하지못함
 - ✓ 따라서 서로 다른 데이터셋으로 추정한 함수를 학습 $\hat{f}(x) = \hat{f}(x; D)$
- Test Error (Generalization Error)
 - ✓ 우리가 최소화하고 싶은 것은 학습 데이터가 아닌 새 데이터에서의 오차
 - ✓ $\text{Test MSE} = E[(Y - \hat{f}(X))^2]$

MSE Decomposition

- ✓ 가정 $Y = f(X) + \epsilon, \epsilon \stackrel{iid}{\sim} N(0, \sigma^2)$
- ✓ $E[(Y - \hat{f}(X))^2] = \underbrace{\sigma^2}_{\text{variance}} + \underbrace{\text{Var}(\hat{f}(X)) + (E[\hat{f}(X)] - f(X))^2}_{(\text{bias})^2}$






- Why Trade-off?

06 | The Bias–Variance Trade-off

Underfitting Overfitting

- Underfitting (과소적합) → Bias가 크고 Variance가 작음
 - ✓ 모델이 너무 간단해서 모델로 Y값을 부정확하게 예측하는 현상
- Overfitting (과적합) → Bias가 작고 Variance가 큼
 - ✓ 복잡한 모델을 활용해 학습시 Y값을 잘 예측하나, 테스트시 Y값을 잘 예측하지 못하는 현상



Q&A

감사합니다.