



Deep Learning Foundations and Concepts 3주차

5. Single-layer Networks: Classification

김호중 / 2026.02.13



Computational Data Science LAB

CONTENTS

1. Classification Approaches
2. Discriminant Functions
3. Least Squares for Classification
4. Decision Theory
5. Generative Classifiers
6. Discriminative Classifiers

01 | Classification Approaches

Three Approaches to Classification

- Generative Probabilistic Models (생성 모델)
 - ✓ 목표: 클래스별 분포 $p(x|C_k)$ 와 사전확률 $p(C_k)$ 를 학습
 - ✓ 방법: 베이즈 정리(Bayes' theorem)를 이용해 사후확률 계산

$$p(C_k | \mathbf{x}) = \frac{p(\mathbf{x} | C_k) p(C_k)}{p(\mathbf{x})}$$

- ✓ 특징: 새로운 데이터 생성(Sampling) 및 이상치 탐지(Outlier detection) 가능
- Discriminative Probabilistic Models (판별 모델)
 - ✓ 목표: 사후확률 $p(C_k|x)$ 를 직접 모델링
 - ✓ 방법: 로지스틱 회귀(Logistic Regression) 등 사용
 - ✓ 특징: 생성 모델보다 파라미터 수가 적고, 분류 성능 최적화에 유리
- Discriminant Functions (판별 함수)
 - ✓ 목표: 입력 x 를 클래스로 매핑하는 함수 $f(x)$ 를 직접 학습
 - ✓ 특징: 확률값 없이 결정만 내림

02 | Discriminant Functions

Two Classes: Linear Discriminant

- Model Definition

- ✓ 입력 벡터의 선형 결합:

$$y(x) = w^T x + w_0$$

- Decision Rule

- ✓ $y(x) \geq 0 \Rightarrow \text{Class } C_1$

- ✓ $y(x) < 0 \Rightarrow \text{Class } C_2$

- Geometry of Decision Boundary

- ✓ Decision surface: $y(x) = 0$ 인 초평면(hyperplane)


- ✓ w (weight vector): 경계에 수직(orthogonal) $\Rightarrow$ 방향 결정

- ✓ w_0 (bias): 경계의 위치(location) 결정

- Signed Distance (부호 있는 거리)

- ✓ 점 x 에서 경계까지 거리 r :


$$r = \frac{y(x)}{\|w\|}$$



02 | Discriminant Functions

Multiple Classes: Ambiguity Problems

- Issues with Binary Classifier Combinations
 - ✓ One-versus-the-rest (일대다 방식)
 - 문제점: 두 클래스에 동시에 속하거나, 어디에도 속하지 않는 모호한 영역 발생 (그림 좌측 녹색 영역)
 - $K - 1$ 개의 분류기 사용: C_k vs not C_k
 - ✓ One-versus-one (일대일 방식)
 - $K(K - 1)/2$ 개의 분류기 사용 (모든 쌍 비교)
 - 문제점: 다수결 투표 시 모순 발생 가능 (그림 우측 녹색 영역)



02 | Discriminant Functions

K-Class Discriminant

- Solution: Single K-class Discriminant

- ✓ K 개의 선형 함수:


$$y_k(x) = w_k^T x + w_{k0}$$

- Decision Rule

- ✓ Decision boundary: $y_k(x) = y_j(x)$ 인 초평면

$$(w_k - w_j)x + (w_{k0} - w_{j0}) = 0$$

- ✓ Convexity (볼록성): 결정 영역 R_k 는 단일 연결된 볼록(singly connected and convex) 형태
 - 영역 내 임의의 두 점을 연결한 선분은 영역을 벗어나지 않음



03 | Least Squares for Classification

Least Squares Method

- Approach
 - ✓ Target vector t : 1-of- K coding (one-hot encoding) 사용

- Sum-of-squares Error Function

$$E_D(\widetilde{\mathbf{W}}) = \frac{1}{2} \text{Tr}\{(\widetilde{\mathbf{X}}\widetilde{\mathbf{W}} - \mathbf{T})^T(\widetilde{\mathbf{X}}\widetilde{\mathbf{W}} - \mathbf{T})\}$$

- Closed-form Solution

$$\widetilde{\mathbf{W}} = (\widetilde{\mathbf{X}}^T \widetilde{\mathbf{X}})^{-1} \widetilde{\mathbf{X}}^T \mathbf{T} = \widetilde{\mathbf{X}}^\dagger \mathbf{T}$$

- Property

- ✓ 타깃 벡터가 선형 제약(예: $\sum_k t_k = 1$)을 만족하면 예측값도 동일 제약 만족:



$$\sum_k y_k(\mathbf{x}) = 1$$

- ✓ 하지만 예측값이 $[0, 1]$ 범위를 벗어날 수 있어 확률적 해석 불가

03 | Least Squares for Classification

Limitations of Least Squares

- Lack of Robustness (강건성 부족)
 - ✓ 이상치(outliers)에 매우 민감
 - ✓ 결정 경계에서 멀리 떨어진(이미 잘 분류된) 데이터가 오히려 오차를 증가
 - ✓ 오차를 줄이기 위해 결정 경계가 잘못된 방향으로 기울어짐
- Comparison with Logistic Regression
 - ✓ Least Squares: 이상치 추가 시 결정 경계 크게 변동 (Magenta line)
 - ✓ Logistic Regression: 이상치에 강건하여 경계 유지 (Green line)



04 | Decision Theory

Minimizing Misclassification Rate

- Optimal Decision Rule


- ✓ 오분류 확률:

$$p(\text{mistake}) = \int_{R_1} p(\mathbf{x}, C_2) d\mathbf{x} + \int_{R_2} p(\mathbf{x}, C_1) d\mathbf{x}$$

- ✓ Decision:

Choose C_k if $p(C_k | \mathbf{x})$ is maximized

- ✓ 오류는 $p(C_1 | x)$ 와 $p(C_2 | x)$ 가 교차하는 지점을 기준으로 최소화



04 | Decision Theory

Minimizing Expected Loss

- Loss Function (Cost Function)
 - ✓ 단순 오분류 횟수가 아니라 오류의 비용(cost)을 고려
- Loss Matrix L_{kj}
 - ✓ 실제 클래스가 k , 예측이 j 일 때 손실
- Example (Cancer Diagnosis)
 - ✓ Normal → Cancer (False Positive): Loss 1
 - ✓ Cancer → Normal (False Negative): Loss 1000
- Expected Loss Minimization
 - ✓ 각 입력 $\mathbf{x}$ 에 대해 기대 손실 최소인 클래스 선택:

$$\sum_k L_{kj} p(C_k | \mathbf{x}) \rightarrow \min$$

	normal	cancer
normal	N_{TN}	N_{FP}
cancer	N_{FN}	N_{TP}

normal	0	1
cancer	100	0


04 | Decision Theory

The Reject Option & Inference vs Decision

- The Reject Option (기각 옵션)
 - ✓ 사후확률이 임계값 θ 이하이면 결정을 보류 (Human intervention)

$$\text{Reject if } \max_k p(C_k | \mathbf{x}) \leq \theta$$

- ✓ 오류율과 기각률(rejection rate) 사이 trade-off 존재
- Inference vs Decision
 - ✓ Inference stage: $p(C_k | x)$ 학습
 - ✓ Decision stage: 손실 행렬, 기각 옵션 등을 고려해 최종 결정
 - ✓ 추론과 결정을 분리하면 손실이 변해도 모델 재학습 필요가 줄어들



04 | Decision Theory

Classifier Evaluation

- Confusion Matrix & Metrics

- ✓ Precision:

$$\frac{TP}{TP + FP}$$

- ✓ Recall (Sensitivity):

$$\frac{TP}{TP + FN}$$


- ✓ F1 score: Precision과 Recall의 조화 평균

- ROC Curve

- ✓ Axis: False Positive Rate (X) vs True Positive Rate (Y)

- ✓ 임계값 변화에 따른 성능 변화를 시각화

- ✓ AUC: 1.0에 가까울수록 좋은 성능



05 | Generative Classifiers

Continuous Inputs: Gaussian Distribution

- Gaussian Assumption

- ✓ 클래스 조건부 분포를 가우시안으로 가정:

$$p(\mathbf{x} | C_k) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma})$$



- ✓ 중요 가정: 모든 클래스가 동일 공분산 $\boldsymbol{\Sigma}$ 공유 (shared covariance)

- Linear Boundary Derivation

- ✓ 사후확률은 logistic sigmoid 형태:

$$p(C_1 | \mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + w_0)$$

- ✓ log-odds 전개 시 2차항 $\mathbf{x}^T \boldsymbol{\Sigma}^{-1} \mathbf{x}$ 상쇄
 - 선형 결정 경계(Linear)



05 | Generative Classifiers

Maximum Likelihood & Generalizations

- MLE Solution for Gaussian

- ✓ Priors:



$$\pi_k = \frac{N_k}{N}$$

- ✓ Means:

$$\mu_k = \frac{1}{N_k} \sum_{n \in C_k} \mathbf{x}_n$$

- ✓ Covariance:

$$\Sigma = \sum_k \frac{N_k}{N} \mathbf{S}_k$$



- Generalizations

- ✓ QDA: 공분산을 공유하지 않으면 $\Sigma_k \neq \Sigma_j \rightarrow$ 2차항 남음 $\rightarrow$ 이차 경계
- ✓ Discrete inputs (Naive Bayes): 특징 독립 가정 시 선형 결합 형태로 표현 가능

06 | Discriminative Classifiers

Logistic Regression

- Model

- ✓ 사후확률을 직접 모델링:

$$p(C_1 | \phi) = y(\phi) = \sigma(\mathbf{w}^T \phi)$$

- ✓ 파라미터 수: 입력 차원 M 에 선형 비례 (생성모형은 대략 M^2)

- Maximum Likelihood (Cross-Entropy)

- ✓ Error function (negative log-likelihood):

$$E(\mathbf{w}) = - \sum_{n=1}^N \{t_n \ln y_n + (1 - t_n) \ln(1 - y_n)\}$$

- ✓ Gradient Descent

$$\nabla E(\mathbf{w}) = \sum_{n=1}^N (y_n - t_n) \phi_n$$

- ✓ $\sigma'(a) = \sigma(a)(1 - \sigma(a))$ 성질로 인해 기울기가 (Error $\times$ Input) 형태로 단순화

06 | Discriminative Classifiers

Multi-class Logistic Regression

- Softmax Function

$$p(C_k | \phi) = y_k(\phi) = \frac{\exp(a_k)}{\sum_j \exp(a_j)}, \quad a_k = \mathbf{w}_k^T \phi$$

- Optimization


- ✓ Multi-class cross-entropy:

$$E(\mathbf{w}_1, \dots, \mathbf{w}_K) = - \sum_{n=1}^N \sum_{k=1}^K t_{nk} \ln y_{nk}$$

- ✓ Gradient:

$$\nabla_{\mathbf{w}_j} E = \sum_{n=1}^N (y_{nj} - t_{nj}) \phi_n$$

- 로지스틱 회귀와 동일한 형태의 기울기 공식



06 | Discriminative Classifiers

Canonical Link Functions

- Why simple gradients?
 - ✓ 선형 회귀, 로지스틱 회귀, 소프트맥스 모두 기울기가 $(y - t)\phi$ 형태
- Reason
 - ✓ 타깃 분포(exponential family)와 활성화/링크 함수가 canonical(정준) 관계
 - ✓ log-likelihood 미분 시 활성화 함수의 미분항과 상쇄되어 단순화됨
- Significance
 - ✓ Canonical link 구조($CE + \text{sigmoid/softmax}$)는 딥러닝에서 효율적 역전파(backpropagation)를 가능하게 하는 핵심 원리

Q&A

감사합니다.