



5. Deep Neural Networks

안재국 / 2026.02.27



Computational Data Science LAB



CONTENTS

1. Limitations of Fixed Basis Models
 2. Geometry of High Dimensions & Manifold Hypothesis
 3. Multilayer Networks
 4. DNN
 5. Mixture Density Networks
- 
- 

01 | Limitations of Fixed Basis Models

The curse of dimensionality

- Fixed Basis Function의 한계

- ✓ 전통적 머신러닝 모델은 다음과 같은 구조를 가짐

- ✓ $y(x, w) = f\left(\sum_{j=1}^m w_j \phi_j(x)\right)$

- ✓ 입력 x 를 사람이 설계한 특징 함수 $\phi(x)$ 로 변환한 후
그 위에서 가중치 w 만을 학습

- ✓ 즉, 모델의 표현력은 데이터가 아니라 사람이 설계한
특징 공간에 의해 결정

- ✓ 이 구조는 특징 설계가 성공하면 강력하지만
고차원 데이터에서는 근본적인 한계에 직면

- The curse of dimensionality

- ✓
$$y(x, w) = w_0 + \sum_{i=1}^D w_i x_i + \sum_{i=1}^D \sum_{j=1}^D w_{ij} x_i x_j + \sum_{i=1}^D \sum_{j=1}^D \sum_{k=1}^D w_{ijk} x_i x_j x_k$$

- ✓ 차원이 증가할수록 특징 수가 기하급수적으로 증가

- ✓ 결과적으로


- 필요한 파라미터 수가 폭발하고
- 필요한 데이터 수 역시 급격히 증가

02 | Geometry of High Dimensions & Manifold Hypothesis

High-Dimensional Implications


- Exponential Growth of Regions

- ✓ 입력 차원이 증가하면 공간 분할 수는 지수적으로 증가
- ✓ 하지만 대부분의 영역에는 데이터가 존재하지 않음
- ✓ 그렇다면 실제 데이터는 이 거대한 공간의 어디에 존재하는가?



- Data Manifold Hypothesis

- ✓ 각 이미지는 수천 차원의 픽셀 공간에서 하나의 점
- ✓ 이미지 간 차이는 위치 이동, 회전, 굵기, 스타일 등의 소수의 연속적인 요인에 의해 결정됨
- ✓ 따라서 실제 데이터는 고차원 공간 전체를 채우지 않으며 낮은 유효 차원의 구조(매니폴드) 근처에 집중



02 | Geometry of High Dimensions & Manifold Hypothesis

Evolution of Basis Functions

- Manifold-based Basis Functions (RBF & SVM)
 - ✓ 전체 공간을 채우는 대신, 데이터 매니폴드 위에 기저 함수를 배치하는 전략
 - ✓ Radial Basis Functions (RBF): 각 훈련 데이터 포인트를 기저 함수의 중심으로 설정하여 매니폴드 근처에서만 강하게 반응

$$\phi_n(\mathbf{x}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}_n\|^2}{s^2}\right)$$

- ✓ Support Vector Machines (SVM): 매니폴드를 표현하는 핵심 데이터(Support Vectors)만 선택적으로 사용
- Why we need Deep Learning?
 - ✓ RBF와 SVM은 데이터셋이 커질수록 계산량이 너무 비대해짐
 - ✓ 신경망은 이를 보완하여 대규모 데이터에서도 효율적이며, 계층적 표현을 통해 더 높은 정확도를 달성함
 - ✓ 다시 말해 RBF와 SVM은 매니폴드에 맞추지만, Deep Networks는 매니폴드 구조 자체를 학습

03 | Multilayer Networks

Learning Adaptive & Hierarchical Representations


- Why Neural Networks?

- ✓ 기존 선형 모델은 고정된 basis 위에서 학습
- ✓ 신경망은 basis 함수 자체에 학습 가능한 파라미터를 부여
- ✓ 입력의 선형 결합 후 비선형 변환:

$$a_j^{(1)} = \sum_{i=1}^D w_{ji}^{(1)} x_i + w_{j0}^{(1)} \quad z_j^{(1)} = h(a_j^{(1)}), \quad a_k^{(2)} = \sum_{j=1}^M w_{kj}^{(2)} z_j^{(1)} + w_{k0}^{(2)}$$

$$y(x) = \sum_{j=1}^M w_{kj}^{(2)} h\left(\sum_{i=1}^D w_{ji}^{(1)} x_i + b_j\right) \quad y(x) = \sum_j w_{kj}^{(2)} \phi_j(x; w^{(1)})$$

- ✓ 모든 파라미터는 gradient descent로 공동 최적화
- ✓ 2-layer network는 임의의 연속 함수를 근사 가능
- ✓ 그러나 복잡한 함수는 많은 hidden unit을 필요로 함



03 | Multilayer Networks


Hidden unit activation functions

- Classic vs. Modern Standards

- ✓ Sigmoid & Tanh : 초기 신경망에서 널리 쓰였으나, 입력값이 크거나 작을 때 기울기가 0으로 수렴하는 기울기 소실(Vanishing Gradients) 문제가 발생

$$\sigma(a) = \frac{1}{1 + \exp(-a)} \quad \tanh(a) = \frac{e^a - e^{-a}}{e^a + e^{-a}}$$

- ✓ ReLU : $h(a) = \max(0, a)$
- ✓ 양수 영역에서 기울기가 1로 일정하여 학습 속도가 매우 빠르고 효율적
- ✓ 현재 기본 활성화 함수



04 | DNN


Why Add More Layers?

- Defining Deep Networks

- ✓ 은닉층이 2개 이상인 신경망
- ✓ 각 층은 선형 변환 + 비선형 변환. 여러 층을 쌓으면 → 복잡한 패턴을 더 적은 파라미터로 표현 가능

- Hierarchical Representation Learning




- ✓ Deep Network는 계층적 구조이며, 중간 표현을 재사용
- ✓ **Low-level:** 초기 층에서는 선(Edge)이나 점과 같은 단순한 특징을 포착함
- ✓ **High-level:** 층이 깊어질수록 저수준 특징을 결합하여 눈, 코, 나아가 고양이와 같은 복잡하고 추상적인 객체를 인식
- ✓ 얇은 네트워크처럼 한 번에 모든 것을 표현하려고 할 때보다 더 효율적으로 복잡한 패턴을 표현



04 | DNN

Transfer Learning

- 전이 학습(Transfer Learning)이란?
 - ✓ 이미 대량의 데이터로 학습된 심층 신경망(DNN)을 새로운 데이터셋이나 작업(Task)에 적용
 - ✓ 처음부터 학습시키는 것보다 비교적 빠르고 높은 정확도
- 핵심 원리
 - ✓ Hierarchical Representation Learning
 - ✓ 네트워크는 단계별로 이미지의 보편적인 특징을 학습
- Pre-trained Models
 - ✓ Backbone: AlexNet, VGG, ResNet



04 | DNN

Error Functions

- Regression

- ✓ 가정: $p(t|\mathbf{x}, \mathbf{w}) = \mathcal{N}(t|y(\mathbf{x}, \mathbf{w}), \sigma^2)$

- ✓ Negative Log-Likelihood $\rightarrow E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \|\mathbf{y}(\mathbf{x}_n, \mathbf{w}) - \mathbf{t}_n\|^2$

- ✓ MSE, 연속값 예측 문제에 사용

- Binary classification

- ✓ 가정: $p(t|\mathbf{x}, \mathbf{w}) = y(\mathbf{x}, \mathbf{w})^t \{1 - y(\mathbf{x}, \mathbf{w})\}^{1-t}$

- ✓ Negative Log-Likelihood $\rightarrow E(\mathbf{w}) = - \sum_{n=1}^N \{t_n \ln y_n + (1 - t_n) \ln(1 - y_n)\}$

- ✓ Binary Cross-Entropy

- Multiclass classification

- ✓ 가정: $p(t|x, w) = \prod_{k=1}^K y_k^{t_k}$



- ✓ Negative Log-Likelihood $\rightarrow E(\mathbf{w}) = - \sum_{n=1}^N \sum_{k=1}^K t_{kn} \ln y_k(\mathbf{x}_n, \mathbf{w})$

- ✓ Multiclass Cross-Entropy

05 | Mixture Density Networks

Why Gaussian is Not Enough

- 기존 회귀의 가정
 - ✓ $p(t|\mathbf{x}, \mathbf{w}) = \mathcal{N}(t|y(\mathbf{x}, \mathbf{w}), \sigma^2)$
 - ✓ 하나의 평균, 하나의 분산, unimodal
- Inverse Problem
 - ✓ Forward problem: $(\theta_1, \theta_2) \rightarrow (x_1, x_2)$ 해가 유일
 - ✓ Inverse problem: $(x_1, x_2) \rightarrow (\theta_1, \theta_2)$ 해가 여러 개
 - ✓ 즉, 입력 하나에 대해 출력이 여러 개 가능
- Gaussian 가정의 한계
 - ✓ MSE 기반 회귀는 조건부 평균만 학습
 - ✓ 여러 해가 있으면 평균을 예측하며, 실제 해가 아님



05 | Mixture Density Networks

How to Implement?

- General Framework

- ✓ 단일 Gaussian 대신 Mixture Model 사용
- ✓ 입력 $\mathbf{x}$ 에 따라 분포가 달라짐
- ✓ Multimodal 조건부 분포 모델링 가능

- Conditional Distribution

- ✓
$$p(\mathbf{t}|\mathbf{x}) = \sum_{k=1}^K \pi_k(\mathbf{x}) \mathcal{N}(\mathbf{t}|\boldsymbol{\mu}_k(\mathbf{x}), \sigma_k^2(\mathbf{x}))$$

- ✓ 신경망이 (π_k, μ_k, σ_k) 를 직접 출력

- Output Constraints & Activations

- ✓ $\pi_k \rightarrow \text{Softmax}$ (합 = 1)
- ✓ $\sigma_k \rightarrow \exp()$ (양수 보장)
- ✓ $\mu_k \rightarrow \text{Identity}$

- Training Objective

- ✓
$$E(\mathbf{w}) = - \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k(\mathbf{x}_n, \mathbf{w}) \mathcal{N}(\mathbf{t}_n | \boldsymbol{\mu}_k(\mathbf{x}_n, \mathbf{w}), \sigma_k^2(\mathbf{x}_n, \mathbf{w})) \right\}$$

- ✓ Negative Log-Likelihood 최소화
- ✓ 조건부 확률 분포 전체 학습

- Why Not Widely Used?

- ✓ 구현 복잡 (log-sum-exp 안정화 필요)
- ✓ 최근에는 Flow / Diffusion / VAE 등 대안 모델 등장

05 | Mixture Density Networks

Example

- 자율주행 차량의 미래 경로 예측
 - ✓ 자율주행차가 앞 차량의 미래 위치를 예측해야 함
 - ✓ 입력: 현재 위치, 속도, 도로 구조
 - ✓ 출력: 3초 뒤 차량 위치
- But
 - ✓ 앞 차량은 직진, 좌회전, 우회전 할 수 있음
 - ✓ MSE는 **평균** 위치를 예측 ex(5,5) 하지만 차가 도로 중앙으로 뚫고 가는 꼴이 될 수 있음
- MDN 사용하면?
 - ✓ $\pi_1 = 0.5 \rightarrow$ 직진, $\pi_2 = 0.25$ 좌회전, $\pi_3 = 0.25 \rightarrow$ 우회전 그리고 각 μ_k 는 각각 실제 경로 위치
 - ✓ 즉. 여러 미래 가능성을 동시에 모델링 가능

Q&A

감사합니다.