



Deep Learning Foundations and Concepts 7주차

10. Convolutional Networks

김호중 / 2026.03.19



Computational Data Science LAB



CONTENTS

1. Computer Vision & Data Structure
 2. Convolutional Filters
 3. Visualizing Trained CNNs
 4. Object Detection
 5. Image Segmentation
 6. Neural Style Transfer
- 
- 

01 | Computer Vision & Data Structure

Structured Data vs Unstructured Data

- 기존 기계 학습 모델의 1차원적 한계
 - ✓ 가장 단순한 형태의 기계 학습 모델들은 관측된 데이터 벡터 x 의 요소들을 전혀 구조화되지 않은 독립적 변수로 취급
 - ✓ 이러한 모델에서는 변수들의 순서를 무작위로 섞어 훈련 및 테스트에 일관되게 적용하더라도 성능에 어떠한 차이도 발생하지 않음
- 2차원 공간적 상관관계(Local Correlations)의 반영
 - ✓ 그러나 실제 기계 학습의 주요 응용 분야(예: 컴퓨터 비전)는 입력 변수 간에 강한 부가적 관계가 존재하는 구조화된 데이터(*structured data*)
 - ✓ 특히 이미지의 픽셀들은 2차원 그리드에 정밀하게 배열되어 있으며, 인접한 픽셀들은 매우 높은 상관관계를 지님
- Core Tasks in Computer Vision
 - ✓ 합성곱 신경망(CNN)은 이러한 이미지 분석에 특화되어 다음과 같은 과제를 해결
 - Classification (분류): 이미지가 전체적으로 어떤 클래스(예: 양성/악성 종양)에 속하는지 판별
 - Detection (객체 탐지): 이미지 내 특정 객체의 존재 유무와 그 정확한 위치 좌표를 파악
 - Segmentation (분할): 픽셀 하나하나를 개별적으로 분류하여 영역을 세밀하게 나눔

02 | Convolutional Filters


Feature Detectors & Receptive Fields

- 수용 영역(Receptive Field)을 통한 국소적 접근
 - ✓ 100만 화소 이상의 이미지를 완전 연결망(FC)으로 처리하면 차원의 저주에 빠짐
 - ✓ 이를 극복하기 위해 은닉 유닛은 이미지 전체가 아닌, 작은 직사각형 형태의 국소 영역(패치) 픽셀들만 입력으로 받으며, 이를 수용 영역이라 정의

- 특징 추출기의 수학적 활성화 모델

$$z = \text{ReLU}(w^T x + w_0)$$

- ✓ z : 은닉 유닛의 최종 활성화 출력값 (특징이 강할수록 큰 값 도출)
- ✓ x : 수용 영역 내 픽셀 값들을 평탄화한 입력 벡터
- ✓ w : 가중치 벡터. 이를 2차원 그리드로 재배열하면 특징을 찾는 필터(Filter) 또는 커널(Kernel)이 됨
- ✓ w_0 : 편향(Bias) 임계값. ReLU 함수 특성상 내적 $w^T x$ 가 임계값을 넘을 때만 특징이 검출된 것으로 신호를 보냄
- ✓ 입력 벡터의 노름 $\|x\|^2$ 이 고정되어 있을 때, $x = aw$ (입력과 커널의 형태가 비례 상수 a 배만큼 동일할 때) 활성화 응답이 수학적으로 극대화



02 | Convolutional Filters


Padding & Strided Convolutions

- Padding (가장자리 정보 보존)
 - ✓ 합성곱 연산을 거칠 때마다 원본 이미지의 차원은 필연적으로 축소 → 이를 방지하고 차원을 유지하기 위해 이미지 외곽에 더미 픽셀(주로 0)을 덧대는 기법
 - ✓ Same Convolution: 출력 배열이 입력과 정확히 동일한 크기가 되도록 유도. 필터 크기 M 에 대해 패딩 $P = (M - 1)/2$ 로 설정
- Strided Convolutions (능동적 차원 축소)
 - ✓ 합성곱 특성 맵의 크기를 대폭 축소하여 네트워크 디자인의 유연성을 확보하고 연산량을 줄이려는 목적
 - ✓ 필터를 1픽셀씩 촘촘히 훑는 대신, 크기 $S(Stride)$ 의 넓은 보폭을 적용하여 건너뛰며 스캔
- 차원 계산 공식
 - ✓ : 원본 입력 이미지의 가로/세로 차원
 - ✓ P : 패딩 두께, M : 커널 필터의 차원 크기, S : 스트라이드 보폭
 - ✓ $\lfloor \cdot \rfloor$: 해당 수식 결과값과 같거나 작은 최대 정수를 산출하는 내림 연산자

0	0	0	0	0	0
0	X_{11}	X_{12}	X_{13}	X_{14}	0
0	X_{21}	X_{22}	X_{23}	X_{24}	0
0	X_{31}	X_{32}	X_{33}	X_{34}	0
0	X_{41}	X_{42}	X_{43}	X_{44}	0
0	0	0	0	0	0

02 | Convolutional Filters

Multi-dimensional Convolutions & Pooling




- Multi-dimensional Convolutions

- ✓ 컬러 영상은 *RGB* 3채널을 가지므로 텐서 차원 확장이 필수. 필터 역시 $M \times M \times C$ 차원으로 독립적 깊이를 지녀야 함
- ✓ $C_{(OUT)}$ 개의 출력 채널 생성을 위해, 필터 텐서 차원은 $M \times M \times C \times C_{(OUT)}$ 가 되며 파라미터 수는 총 $(M^2C + 1) C_{(OUT)}$ 개로 정의

- Pooling

- ✓ 특성 맵의 활성화 값은 해당 특징이 얼마나 강하게 검출되었는가를 의미
- ✓ 사물의 세부 위치(예: 눈, 코, 입의 픽셀 단위 엇갈림)가 약간 변하더라도 동일한 클래스로 인식하게 만드는 국소적 이동 불변성 (Local translation invariance)을 주입해야 함
- ✓ Max-pooling : 수용 영역 내 가장 큰 활성화 값만 생존시킴 → 특징의 존재 여부와 강도는 완벽히 보존하면서, 정확한 위치 정보는 의도적으로 폐기하는 차원 축소(Down-sampling) 연산



02 | Convolutional Filters



Deep Architecture & VGG-16 Model

- Effective Receptive Field

- ✓ 한 층의 유닛은 이전 층의 작은 패치만을 바라보며 지역성을 유지
- ✓ 그러나 층을 여러 겹 쌓아 올린 심층망에서는 뒷단 유닛이 앞단의 정보를 연쇄적으로 취합
 - 이미지 원본상에서 바라보는 시야(유효 수용 영역)가 기하급수적으로 거대해짐

- The Standard Model: VGG-16 Architecture



- ✓ 매우 단순한 설계 원칙을 사용하여 하이퍼파라미터 탐색 공간을 최소화한 구조
- ✓ $224 \times 224 \times 3$ 이미지를 입력받아, 모든 합성곱 층은 단일 규격인 3×3 필터, 스트라이드 1, Same 패딩만 사용
- ✓ 공간 차원 축소는 오직 2×2 필터, 스트라이드 2의 최대 풀링으로만 일관되게 수행
- ✓ 풀링으로 인해 공간 해상도가 $1/4$ 로 줄어든 때마다 채널의 수를 $64 \rightarrow 128 \rightarrow 256 \rightarrow 512$ 로 2배씩 늘려 표현력(자유도)의 급격한 소실을 수학적으로 상쇄시킴
- ✓ 전체 1억 3천8백만개의 막대한 파라미터가 16개의 학습 가능 층에 분산 배치된 구조



03 | Visualizing Trained CNNs

Visual Cortex & Gabor Filters

- Mammalian Visual Cortex
 - ✓ 초기 CNN 설계는 포유류 뇌의 시각 피질 연구에서 직접적 모티브를 얻음
 - ✓ 시각 피질의 단순 세포는 전체 이미지가 아닌 특정 각도, 위치에 놓인 단순한 선(Edge) 자극에만 강하게 발화한다는 사실을 생리학적으로 입증
- Learned Features of CNN
 - ✓ 실제 자연 이미지 데이터셋으로 훈련된 AlexNet의 첫 번째 은닉층 가중치를 시각화해 본 결과
 - 생물학적 뉴런 모델인 Gabor 필터(선, 텍스처, 대비 감지)와 완벽히 유사한 형태를 자생적으로 학습해 냈을 증명



03 | Visualizing Trained CNNs

Saliency Maps & Grad-CAM



- Black-box 본질 해석

- ✓ 깊은 층으로 들어갈수록 은닉 유닛은 엣지(1층) → 텍스처 → 사물의 일부(예: 바퀴) → 전체 객체(예: 차) 순으로 의미적 추상화 수준을 고도화
- ✓ 그러나 출력 결과만으로는 네트워크가 이미지의 어느 부위를 핵심 근거로 삼아 분류를 확신했는지 알 수 없음

- Saliency Maps using Grad-CAM

- ✓ 마지막 합성곱 층은 의미적 표현(Semantic representation)이 가장 풍부하면서도 공간적 위치 정보가 아직 파괴되지 않고 살아있는 유일한 지점
- ✓ 특정 타겟 클래스 c 에 대한 분류 점수가 마지막 합성곱 층의 각 활성화 맵 단위에 얼마나 민감하게 반응하는지를 편미분을 통해 정량화

- Mathematical Definition

$$\alpha_k = \frac{1}{M_k} \sum_i \sum_j \frac{\partial a^{(c)}}{\partial a_{ij}^{(k)}}$$

- ✓ $a^{(c)}$: 타겟 클래스 c 의 소프트맥스 적용 이전 최종 점수 (Pre-activation 스칼라 즉, raw 점수)


- ✓ $a_{ij}^{(k)}$: 마지막 합성곱 층 k 번째 채널의 위치 (i,j) 에 있는 활성화 스칼라 값

- ✓ M_k : 채널 내 단위 유닛의 총개수. 기울기의 공간적 평균 가중치 α_k 를 산출

- ✓ $L = \sum_k \alpha_k A^{(k)}$: 계산된 중요도 가중치 α_k 를 바탕으로 각 채널 맵 $A^{(k)}$ 를 선형 결합(가중합)하여 생성한 2차원 열분포(Heatmap) L


03 | Visualizing Trained CNNs

Adversarial Attacks & DeepDream



- Adversarial Attacks (적대적 공격)

- ✓ 육안으로는 감지 불가능한 미세한 수준의 픽셀 노이즈를 전략적으로 삽입하여, 신경망이 엉뚱한 클래스로 매우 높은 확신을 갖고 오분류하도록 유도하는 보안 공격
- ✓ Fast Gradient Sign Method : $x' = x + \varepsilon \text{sign}(\nabla_x E(x, t))$
- ✓ (원본 이미지), $E(x, t)$ (오차 함수), $\nabla_x E$ (입력 픽셀에 대한 오차 기울기)
- ✓ 오차를 줄이는 방향이 아닌, 오차를 증폭시키는 방향으로 미세 조작 상수 ε 만큼 이미지를 오염




- DeepDream (환각 이미지 생성)

- ✓ 네트워크가 학습한 특징을 과장하여 표현하도록, 오차 함수가 아닌 특정 은닉층 활성화 점수 자체를 극대화하는 경사 상승법 적용
- ✓ 최적화 목적식 : $F(I) = \sum_{i,j,k} a_{ijk}(I)^2$ (I : 입력 픽셀, a_{ijk} : 특정 층의 활성화 값)
- ✓ 구름 이미지에서 희미하게 개의 실루엣이 감지되면, 해당 패턴 활성화를 증폭시켜 진짜 개 형상을 사진 위에 인위적으로 덧칠해 나감


04 | Object Detection

Bounding Boxes & Intersection-over-Union



- Task: Object Localization via Bounding Boxes

- ✓ 복수 객체가 존재하는 이미지에서 각 객체의 클래스와 물리적 위치를 동시에 찾아내는 과제
- ✓ 객체의 외곽선을 가장 조밀하게 감싸는 직사각형 형태의 Bounding Box를 예측 변수로 사용
- ✓ 매개변수 표현 벡터:
- ✓ : 직사각형 중심의 X, Y 좌표
- ✓ b_W, b_H : 직사각형의 너비와 높이. 0~1 사이의 연속형 수치로 정규화되어 회귀 오차 함수로 훈련됨



- Evaluation Metric: Intersection-over-Union (IoU 지표)


- ✓ 분류 문제의 정확도(Accuracy)처럼 객체 탐지의 물리적 예측 위치가 정답(Ground Truth)과 얼마나 완벽히 부합하는지 정량적으로 측정하는 지표
- ✓ IoU : 예측된 박스와 정답 박스의 교집합(Intersection) 면적을 두 박스의 합집합(Union) 면적으로 나눈 비율
- ✓ 크기가 제각각인 객체들에 대해 스케일 의존성을 배제하고, 0 ~ 1 사이의 값으로 객관적 중첩도를 평가
 - (통상 0.5 이상을 정답 판정 임계치로 활용)

04 | Object Detection


Sliding Windows Efficiency & Non-max Suppression

- Sliding Window Computation Efficiency

- ✓ 이미지 전체를 촘촘히 훑으며 수많은 위치에서 모델을 통과시키는 나이트 슬라이딩 윈도우 방식은 연산 비용이 극도로 폭발
- ✓ 그러나 완전 연결층(*FC Layer*)을 단일 패치용 합성곱 층(1×1 또는 $M \times M$)으로 구조 변경할 경우, 극적인 효율화가 발생
- ✓ 확장된 입력 이미지에 대해, 인접한 윈도우끼리 중첩되는 피쳐 연산 영역을 병렬로 공유하므로 전체 이미지에 대해 오직 한 번의 Forward Pass만으로 모든 위치의 탐지 결과를 획득



- 슬라이딩 윈도우 시 중복되는 수용 영역의 연산




- 단일 패치 처리용 CNN 망을 더 큰 8x8 이미지상에 그대로 확장 적용했을 때, 파란색 영역의 최소 연산만 추가

04 | Object Detection

Sliding Windows Efficiency & Non-max Suppression

- Non-max Suppression (NMS, 비최대 억제)
 - ✓ 모델이 스캔을 진행하며 동일 객체 주변에 여러 개의 확률 높은 바운딩 박스를 중복으로 난사하는 문제를 통제해야 함
 - ✓ 1단계: 특정 클래스 확률 임계치(예: 0.7) 미만의 낮은 신뢰도 박스 전면 삭제
 - ✓ 2단계: 남은 박스 중 최고 확률(예: 0.95)을 기록한 단 하나의 대표 박스만 정답으로 채택
 - ✓ 3단계: 채택된 대표 박스와 겹치는 비율(IoU)이 0.5를 초과하는 주변 잉여 박스들을 억제하여 쾌적한 최종 탐지 결과만 남김



- ✓ 가장 확률이 높은 붉은색 박스를 살리고, 주변의 겹치는 푸른색 잉여 박스들을 논리적으로 소거하는 NMS의 핵심 절차

05 | Image Segmentation

Semantic Segmentation & Up-sampling Operations

- Semantic Segmentation (의미론적 분할)

- ✓ 바운딩 박스 추정을 초월하여, 원본 이미지 해상도와 동일한 차원 위에서 개별 픽셀 하나하나가 어느 클래스(차, 보행자 등)에 속하는지 라벨링하는 초정밀 비전 과제



- Spatial Resolution Collapse (공간 해상도 붕괴)



- ✓ CNN은 의미론적 특징 추출을 위해 복수의 스트라이드 및 풀링(Pooling) 연산을 거치며 특성 맵의 물리적 크기를 극단적으로 찌그러뜨림 (Down-sampling)
- ✓ 원본 이미지 해상도의 마스크(Mask)를 출력하려면, 반드시 저해상도 텐서를 원상 복구시키는 수학적 업샘플링(Up-sampling) 망이 후반부에 설계되어야 함

05 | Image Segmentation

Semantic Segmentation & Up-sampling Operations

- Max-unpooling (최대 언폴링)

- ✓ 다운샘플링 당시의 위치 정보를 소실시키지 않도록 복원하는 정밀 연산법
- ✓ 최대 풀링(Max-pooling) 당시 각 블록 내 최고값을 가진 픽셀의 원본 위치(Index) 메모리에 별도 캐싱해 둬
- ✓ 업샘플링 계층 도달 시 캐싱된 위치에만 값을 부활시키고 나머지 타일은 0으로 채워, 사물의 날카로운 테두리(Edge) 공간 정보를 기하학적으로 복원




- 다운샘플링과 업샘플링이 결합된 풀 사이클 이미지 분할 네트워크

- 평균/최대 언폴링의 행렬 단위 연산 원리와 위치 인덱스 기록 방식

05 | Image Segmentation

Transpose Convolution & U-Net Architecture


- Transpose Convolution (전치 합성곱)
 - ✓ 언폴링이 정해진 규칙에 의한 복원이라면, 전치 합성곱은 출력 오차를 역전파하며 스스로 업샘플링 패턴을 학습하는 가중치 연산
 - ✓ 입력 텐서의 단일 픽셀 스칼라값이 출력 맵의 넓은 패치 크기에 가중치를 곱하며 브로드캐스팅(퍼짐)됨
 - ✓ 여러 패치들이 겹치는 영역은 합산하여 최종 텐서를 구축
 - ✓ 다운샘플링 합성곱 행렬 A 연산의 정확한 전치 행렬 A^T 을 사용하는 수학적 컬레 구조이므로 Transpose Convolution 이라 명명



- 출력 보폭이 입력 보폭보다 크게 설정된 전치 합성곱의 패치 오버랩 연산

05 | Image Segmentation

Transpose Convolution & U-Net Architecture



- U-net Architecture
 - ✓ 전 층을 합성곱 및 전치 합성곱만으로 도배한 완전 합성곱 신경망(FCN)
 - ✓ 찌그러진 해상도를 억지로 복원하는 과정에서 사물의 위치 및 세밀 윤곽 정보가 필연적으로 흐려지는 딥러닝의 고질적 한계 돌파
 - ✓ 대칭적인 U자 형태(U-shape) 구조를 통해 핵심 혁신 메커니즘 도출
 - ✓ Skip Connections (결합): 압축 과정의 각 층에 살아있는 깨끗한 고해상도 공간 피쳐 맵을 그대로 빼돌려, 복원 과정(Up-sampling)의 대응 층에 직접 이어 붙임
 - ✓ 뒷단 층이 풍부한 원본 픽셀 정보 공간을 Access할 수 있게 되어 초정밀 의료 영상 분할 등에 표준으로 채택

06 | Neural Style Transfer

Mathematical Formulation of Content & Style



- Neural Style Transfer (신경망 스타일 융합)
 - ✓ 입력 사진의 객체 형태는 완벽히 보존하면서, 질감과 화풍만 지정된 명화(예: 빈센트 반 고흐)의 스타일로 다시 렌더링하는 기법
 - ✓ 목적지 이미지 G 픽셀들을 타겟으로 삼고, 다음 오차 함수 $E(G)$ 가 바닥을 칠 때까지 경사 하강법으로 이미지를 직접 업데이트함
 - ✓ $E(G) = E_{(content)}(G, C) + E_{(style)}(G, S)$ (콘텐츠 오차와 스타일 오차의 합)
- Content Error (형태 오차)
 - ✓ : 특정 은닉층 k 채널 위치 (i, j) 의 활성화 응답 점수
 - ✓ 생성 맵 G 와 원본 콘텐츠 사진 C 를 네트워크에 통과시켰을 때, 특정 깊이 은닉층의 활성화 반응 텐서가 완벽히 동일해지도록 제곱 오차를 강제
- Style Error via Gram Matrix (스타일 오차)
 - ✓ 질감(Style)은 사물의 모양이 아니라 색상/패턴들의 동시 발생 통계 분포에 의해 결정
 - ✓ 생성 맵 G 의 스타일 텐서 $F(G)$ 와 명화 S 의 스타일 텐서 $F(S)$ 간의 통계적 차이를 줄이도록 제곱합 에러 $E_{(style)}$ 을 최적화함

$$(E_{(style)} \propto \sum \{F(G) - F(S)\}^2)$$

Q&A

감사합니다.