



11. STRUCTURED DISTRIBUTIONS

안재국 / 2026.03.26



Computational Data Science LAB



CONTENTS



1. Conditional Independence
 2. Three Basic Graph Structures
 3. Explaining Away
 4. D-Separation
 5. Naive Bayes
 6. Generative Models
 7. Sequence Models
- 
- 

01 | Conditional Independence

Definition

- Idea


- ✓ 변수 c 가 주어졌을 때, b 를 추가로 알아도 a 에 대한 정보가 더 늘어나지 않음
- ✓ 즉, a 와 b 는 c 를 조건으로 할 때 독립
- ✓ $p(a | c) = p(a | b, c), \quad p(a, b | c) = p(a | c)p(b | c)$
- ✓ factorization
- ✓ $a \perp\!\!\!\perp b | c$

- Meaning

- ✓ c 를 알고 나면 a 와 b 사이의 정보 연결이 사라짐
- ✓ 결합분포가 두 조건부분포의 곱으로 분해됨

- Importance

- ✓ 확률 그래프 모델에서 독립 구조를 명시적으로 표현 가능
- ✓ 추론과 학습 계산을 줄이는 핵심 개념
- ✓ 이후 d-separation과 Naive Bayes 이해의 출발점



02 | Three Basic Graph Structures

Basic Patterns of Conditional Independence

- Fork structure

- ✓ $p(a, b, c) = p(a|c)p(b|c)p(c)$
- ✓ c 는 a 와 b 의 공통 원인
- ✓ $p(a, b|c) = \frac{p(a, b, c)}{p(c)} = p(a|c)p(b|c)$
- ✓ c 를 관측하면 a 와 b 는 조건부 독립
- ✓ $a \perp\!\!\!\perp b \mid c$

- Chain structure




- ✓ $p(a, b, c) = p(a)p(c|a)p(b|c)$
- ✓ c 는 a 와 b 사이의 매개 변수
- ✓ $p(a, b|c) = \frac{p(a, b, c)}{p(c)} = p(a|c)p(b|c)$
- ✓ c 를 관측하면 a 와 b 는 조건부 독립
- ✓ $a \perp\!\!\!\perp b \mid c$

- Collider structure

- ✓ $p(a, b, c) = p(a)p(b)p(c|a, b)$
- ✓ 형태: $a \rightarrow c \leftarrow b$
- ✓ c 는 두 원인이 만나는 결과 변수
- ✓ $p(a, b|c) = \frac{p(a, b, c)}{p(c)} = \frac{p(a)p(b)p(c|a, b)}{p(c)}$
- ✓ 관측하지 않으면 경로가 막혀 있고, 관측하면 오히려 의존성이 생김
- ✓ $a \perp\!\!\!\perp b \mid c$

- Key point

- ✓ 조건부 독립은 그래프의 연결 여부가 아니라 경로가 열려 있는지 막혀 있는지로 판단
- ✓ 이후 d-separation은 이 세 구조를 일반화한 규칙



03 | Explaining Away


Conditional Dependence Induced by Observation

- Structure

- ✓ 형태: $B \rightarrow G \leftarrow F$
- ✓ B : battery state, F : fuel state, G : fuel gauge reading
- ✓ 두 원인 B, F 가 하나의 결과 G 에 영향을 주는
collider structure

- Before observation

- ✓ G 를 관측하지 않으면 B 와 F 는 서로 독립
- ✓ 즉, 한 원인의 정보가 다른 원인에 영향을 주지 않음



- After observing G

- ✓ G 를 관측하면 B 와 F 는 더 이상 독립이 아님
- ✓ 예를 들어 gauge가 empty라면, 원인은 배터리 문제일 수도 있고 연료 부족일 수도 있음
- ✓ 이때 한 원인이 확인되면 다른 원인의 가능성은 감소

- Key idea

- ✓ 하나의 결과를 설명하는 원인이 여러 개 있을 때
- ✓ 한 원인이 밝혀지면 다른 원인의 가능성이 줄어드는 현상을 **explaining away** 라고 함

04 | D-Separation

Graphical Criterion for Conditional Independence

- Core idea

- ✓ d-separation은 복잡한 그래프에서 조건부 독립을 판단하는 기준
- ✓ 두 변수 사이의 모든 path가 관측 변수에 의해 blocked 되면 조건부 독립이 성립

- Blocking rule 1


- ✓ tail-to-tail 또는 head-to-tail 구조에서는 가운데 노드가 관측되면 경로가 차단됨
- ✓ 따라서 fork와 chain에서는 중간 노드를 조건으로 둘 때 독립

- Blocking rule 2


- ✓ head-to-head 구조에서는 기본적으로 경로가 차단됨
- ✓ 하지만 collider 노드 또는 그 자손이 관측되면 경로가 열림
- ✓ 따라서 collider에서는 관측이 오히려 의존성을 만들 수 있음

- Importance

- ✓ 확률식을 직접 전개하지 않고도 그래프만 보고 독립성 판단 가능



(a) $a \not\perp b \mid c$



(b) $a \perp b \mid f$

05 | Naive Bayes

Conditional Independence in Classification

- Structure

- ✓ 형태: $C_k \rightarrow x^{(1)}, x^{(2)}, \dots, x^{(L)}$ 공통 원인
- ✓ C_k : class label, $x^{(1)}, \dots, x^{(L)}$: observed features
- ✓ C_k : spam / ham, $x^{(l)}$: 단어 포함 여부, 링크 포함 여부

- Conditional independence assumption


- ✓ 클래스 C_k 가 주어지면 각 feature들은 서로 조건부 독립
- ✓ 즉, $x^{(i)} \perp\!\!\!\perp x^{(j)} \mid C_k$

- Factorization

- ✓ $p(C_k \mid x) = \frac{p(x|C_k)p(C_k)}{p(x)}$, $p(x \mid C_k) = \prod_{l=1}^L p(x^{(l)} \mid C_k)$
- ✓ 복잡한 결합분포를 단순한 조건부분포들의 곱으로 표현 가능


- Importance

- ✓ 조건부 독립 개념이 실제 분류 모델에 적용되는 대표적 예시
- ✓ 고차원 데이터에서도 계산이 단순하고 효율적



05 | Generative Models

How Data Is Generated



- idea
 - ✓ 어떤 데이터는 원인이 먼저 정해지고, 그 결과로 만들어진다고 볼 수 있음
 - ✓ 예를 들어 이미지에서는 객체의 종류(class), 위치(position), 크기(scale)가 먼저 정해지고 그 결과로 image가 생성된다고 생각할 수 있음
- Generative view
 - ✓ 화살표 방향은 데이터가 생성되는 방향을 의미함
 - ✓ 이처럼 데이터를 만드는 과정을 모델링한 것을 generative model이라고 함
- Why useful?
 - ✓ 데이터를 단순히 분류하는 것이 아니라 어떻게 만들어졌는지 설명할 수 있음
 - ✓ 학습 후에는 새로운 데이터를 생성하는 데에도 활용 가능
- Before observing image
 - ✓ class, position, scale은 서로 독립이라고 가정할 수 있음
 - ✓ 즉, 이미지가 없으면 각 변수는 따로 생각 가능
- After observing image
 - ✓ image를 관측하면 세 변수는 더 이상 독립이 아님
 - ✓ 예를 들어 이미지 속 물체가 car라는 정보를 알게 되면 가능한 위치나 크기를 추정하는 데 도움이 될 수 있음
- Connection to previous slides
 - ✓ 이 구조는 앞에서 본 collider structure와 같은 형태
 - ✓ 따라서 image를 관측하면 경로가 열리고 의존성이 생김
 - ✓ 즉, generative model에서도 conditional independence가 중요함

06 | Sequence Models

From Independent Observations to Markov Chains

- General autoregressive model

- ✓ 시퀀스의 일반적인 결합분포는 각 시점이 모든 이전 시점에 의존하는 형태로 표현 가능
- ✓ $p(x_1, \dots, x_N) = \prod_{n=1}^N p(x_n | x_1, \dots, x_{n-1})$

- Independent observations


- ✓ 가장 단순한 가정은 각 관측값이 서로 독립이라고 보는 것
- ✓ $p(x_1, \dots, x_N) = \prod_{n=1}^N p(x_n)$
- ✓ 하지만 이 경우 순서 정보와 시퀀스 특성을 반영하지 못함

- First-order Markov chain

- ✓ 현재 관측값은 바로 이전 관측값에만 의존
- ✓ $p(x_1, \dots, x_N) = p(x_1) \prod_{n=2}^N p(x_n | x_{n-1})$
- ✓ 즉, $p(x_n | x_1, \dots, x_{n-1}) = p(x_n | x_{n-1})$

- Extension


- ✓ second-order Markov chain에서는 현재 값이 직전 두 개의 관측값에 의존
- ✓ 차수가 커질수록 파라미터 수가 증가



07 | State-Space Models

Hidden States for Sequential Data

- Idea
 - ✓ 단순한 Markov chain은 표현력이 부족할 수 있고
고차 Markov chain은 복잡도가 너무 커질 수 있음
 - ✓ 이를 보완하기 위해 보이는 데이터 x_n 뒤에 숨은 상태 z_n 이 존재한다고 가정
 - ✓ 숨은 상태는 시간에 따라 변하고, 관측값은 그 상태에서 생성됨
- Structure
 - ✓ hidden states: $z_1 \rightarrow z_2 \rightarrow \dots \rightarrow z_N$
 - ✓ observations: $z_n \rightarrow x_n$
- Interpretation
 - ✓ 보이는 데이터의 복잡한 변화를 hidden state로 설명
 - ✓ 시퀀스를 더 유연하게 모델링 가능
- Examples
 - ✓ z_n : 시장의 숨은 상태 (상승장 / 하락장)
 - ✓ x_n : 실제로 관측되는 값 (주가, 수익률, 거래량)
 - ✓ 시장 상태는 직접 보이지 않지만 시간에 따라 변하고, 그 결과가 관측값에 반영된다고 볼 수 있음



Q&A

감사합니다.