



Deep Learning Foundations and Concepts

14. Sampling

김호중 / 2026.05.14



Computational Data Science LAB



CONTENTS

1. Basic Sampling Algorithms
 2. Markov Chain Monte Carlo
 3. Langevin Sampling
- 
- 



01 | Basic Sampling Algorithms

Why we sampling

- AI의 mathematical background의 모든 핵심 작업이 결국 '기댓값 계산'으로 귀결
- 우리는 손실 함수 / 예측 (베이지안) / 강화학습 (가치 함수) / 생성 모델 학습 (EBM, Diffusion) 등을 위해 p 의 기댓값이 필요하고, 그러려면 p 의 샘플이 필요하다.
- $\tilde{p}$ 의 값은 평가 가능하지만 정규화 상수 Z 는 모르는 상태에서, 어떻게 효율적으로 샘플을 뽑을까?
그 답이 변환 $\rightarrow$ 기각 $\rightarrow$ 중요도 $\rightarrow$ SIR $\rightarrow$ MCMC $\rightarrow$ Langevin 으로 진화

01 | Basic Sampling Algorithms


Expectations & Transformation Method



- 샘플링이 필요한 이유: 기댓값(Expectations)의 수치적 근사
 - ✓ 딥러닝에서 확률 분포 $p(z)$ 에 대한 함수 $f(z)$ 의 기댓값 (우리가 원하는 값 $\rightarrow f(z) = z$ 면 $\rightarrow E[z]$)은 $E[f] = \int f(z)p(z)dz$ 로 정의됨. 그러나 이 적분은 대부분의 실전 문제에서 해석적(Analytic)으로 계산이 불가능함
 - ✓ 핵심 아이디어: $p(z)$ 에서 L 개의 독립 샘플 $z^{(l)}$ 을 추출하여 유한합 $\bar{f} = (1/L)\sum f(z^{(l)})$ 으로 기댓값을 근사함. 여기서 L 이 커질수록 추정치가 참값에 수렴 (대수의 법칙)
 - ✓ 그렇다면 핵심 문제는 원하는 확률 분포 $p(z)$ 에서 어떻게 샘플을 뽑아낼 것인가로 귀결됨
- 가장 단순한 방법: Transformation Method (변환법)
 - ✓ 컴퓨터가 손쉽게 생성하는 균등 분포 $U(0,1)$ 난수 z 를 출발점으로 삼아, 목표 분포 $p(y)$ 의 CDF(누적 분포 함수)의 역함수 h^{-1} 을 적용하면 $y = h^{-1}(z)$ 가 $p(y)$ 를 따르게 됨
 - ✓ Box - Muller 변환: 균등 난수 쌍 (z_1, z_2) 을 $y_1 = z_1(-2\ln r^2/r^2)^{(1/2)}$ 로 변환하면 표준 정규 분포 $N(0,1)$ 샘플 쌍을 동시에 얻음.
 $r^2 = z_1^2 + z_2^2$ (단위원 내 점) - (표준 정규분포 좌표축을 변환한 식 + 원의 방정식 이용 $\rightarrow$ 정규분포 샘플 쌍)
 - ✓ 그러나 이 방법은 CDF의 역함수를 닫힌 형태로 구할 수 있는 단순한 분포에만 적용 가능하다는 근본적 한계가 존재함

01 | Basic Sampling Algorithms

Rejection Sampling



- 문제: 변환법이 적용 불가능한 복잡한 분포

- ✓ 실전의 목표 분포 $\tilde{p}(z)$ 는 CDF 역함수를 구할 수 없을 뿐 아니라, 정규화 상수 Z_p 조차 알 수 없는 비정규화 분포인 경우가 대부분임.


즉, $p(z) = \tilde{p}(z)/Z_p$ 에서 $Z_p = \int \tilde{p}(z)dz$ 계산 불가

- 해결: 기각 샘플링의 '포락선(Envelope)' 원리

- ✓ 샘플링이 쉬운 제안 분포 $q(z)$ 를 도입한 뒤, 상수 k 를 곱하여 모든 z 에서 $kq(z) \geq \tilde{p}(z)$ 를 만족하는 포락선(지붕)을 만듦
- ✓ Step 1: $q(z)$ 에서 후보 z_0 를 추출 → Step 2: $[0, kq(z_0)]$ 구간에서 균등 난수 u_0 를 추출
- ✓ $u_0 \leq \tilde{p}(z_0)$ 이면 채택(Accept), $u_0 > \tilde{p}(z_0)$ 이면 기각(Reject). 기하학적으로 $\tilde{p}(z)$ 곡선 아래에 떨어진 점만 살리는 원리
- ✓ 채택 확률은 $\tilde{p}(z)$ 면적과 $kq(z)$ 면적의 비율이므로, $q(z)$ 가 $\tilde{p}(z)$ 에 가까울수록 높은 채택률을 달성함
- ✓ 한계: 복잡한 분포에서 $q(z)$ 와 k 를 사람이 직접 설계해야 하므로, 분포가 복잡할수록 적합한 포락선을 구하기 점점 더 어려워짐

01 | Basic Sampling Algorithms

Adaptive Rejection Sampling & Curse of Dimensionality



- 포락선 자동 구축: Adaptive Rejection Sampling


- ✓ 기각 샘플링의 포락선 설계 부담을 해소하기 위해, 알고리즘이 런타임에 포락선을 스스로 구축하고 개선해 나가는 자동화 전략
- ✓ 목표 분포가 로그 오목(Log-concave)인 경우, $\ln p(z)$ 위의 초기 격자점들에서 접선을 그어 구간별 선형 포락선을 형성함
- ✓ 기각이 발생할 때마다 해당 z 좌표를 새 격자점으로 추가하여 포락선이 점점 $\tilde{p}(z)$ 에 밀착 → 채택률이 반복할수록 자동으로 상승

- 근본적 한계: Curse of Dimensionality

- ✓ 제안 분포가 목표 분포보다 약간만 커도 샘플 채택률이 급격하게 하락 → 사실상 샘플링 횟수 대비 유효한 샘플을 단 하나도 얻지 못함
- ✓ 결론: 기각 샘플링 계열은 고차원 문제에서 원천적으로 사용 불가 → 완전히 다른 패러다임이 필요함

01 | Basic Sampling Algorithms

Importance Sampling



- 발상의 전환: 샘플 자체가 아닌 기댓값만 정확히 근사하면 된다
 - ✓ 고차원에서 목표 분포의 샘플을 직접 추출하는 것은 차원의 저주로 불가능하지만, 우리의 궁극적 목적은 대부분 기댓값 $E[f]$ 를 구하는 것임
- 핵심 메커니즘: 중요도 가중치 (Importance Weights)
 - ✓ 임의의 제안 분포 $q(z)$ 에서 샘플 $z^{(l)}$ 을 추출한 뒤, 가중치 $r_1 = \tilde{p}(z^{(l)}) / q(z^{(l)})$ 을 부여하여 보정: $E[f] \approx (1/L) \sum r_1 \cdot f(z^{(l)})$
 - ✓ r_1 의 의미: '이 샘플이 $q(z)$ 대비 $p(z)$ 에서 얼마나 더(혹은 덜) 나올 법한가'를 수치화한 밀도 비율. $q(z)$ 의 편향을 수학적으로 정확히 상쇄시킴
- 치명적 한계: 가중치 지배 현상 (Weight Degeneracy)
 - ✓ $q(z)$ 가 $p(z) \cdot f(z)$ 값이 큰 핵심 영역을 충분히 덮지 못하면, 해당 영역에 우연히 걸린 극소수 샘플의 가중치가 나머지 전체를 압도함
 - ✓ 결과적으로 추정치가 한두 개의 샘플에 의해 좌우되어 분산이 폭발하고, 언제 오류가 발생하는지 사전에 감지할 수 없는 위험을 내포함

01 | Basic Sampling Algorithms

Sampling-Importance-Resampling (SIR)

- 기각 샘플링의 상수 k 문제 + 중요도 샘플링의 가중치 문제를 동시에 해결
 - ✓ 기각 샘플링은 상수 k 설정이 필요하고, 중요도 샘플링은 가중치를 곱한 기댓값만 제공하여 분포 자체의 샘플은 얻지 못함.
- SIR은 이 둘의 장점을 결합함
- SIR 3단계 절차
 - ✓ Step 1 (Sampling): 제안 분포 $q(z)$ 로부터 L 개의 후보 샘플 $\{z^{(1)}, \dots, z^{(L)}\}$ 을 대량 추출
 - ✓ Step 2 (Importance): 각 샘플에 가중치 $w_l = \tilde{p}(z^{(l)}) / q(z^{(l)})$ 을 계산 후 전체 합으로 정규화하여 이산 확률 분포를 구성
 - ✓ Step 3 (Resampling): w_l 에 비례하는 확률로 L 개 샘플 중 복원 추출 $\rightarrow \tilde{p}(z)$ 값이 큰 영역의 샘플은 여러 번 선택되고, 작은 영역은 도태됨
 - ✓ $L \rightarrow \infty$ 일 때 재추출된 샘플 집합은 목표 분포 $p(z)$ 를 정확히 따르게 됨. 상수 k 를 전혀 사용하지 않으면서도 목표 분포의 샘플 자체를 획득 가능
- 여전히 남는 근본 문제
 - ✓ 모든 기본 샘플링 기법은 고정된 $q(z)$ 에서 독립적으로 샘플을 추출하는 구조이므로, 고차원에서 $q(z)$ 와 $p(z)$ 의 괴리가 커지면 효율이 급감함 $\rightarrow$ 완전히 새로운 접근이 필요


02 | Markov Chain Monte Carlo

Markov Chain

- 패러다임 전환: '독립 추출'에서 '연쇄 탐색'으로
 - ✓ 기존 방법들의 공통 한계: 고정된 $q(z)$ 에서 매번 독립적으로 샘플을 추출하므로, q 와 p 의 괴리가 고차원에서 기하급수적으로 확대됨
 - ✓ MCMC의 핵심 아이디어: 현재 상태 $z^{(\tau)}$ 주변의 국소적 이웃만 탐색하는 마르코프 체인을 구성하여, 한 걸음씩 목표 분포의 고밀도 영역으로 이동해 나감
- 마르코프 체인이 목표 분포에 수렴하기 위한 조건
 - ✓ 불변 분포(Invariant Distribution): 전이 확률 $T(z', z)$ 를 반복 적용해도 분포가 변하지 않는 상태.
 $\int T(z', z)p^*(z')dz' = p^*(z)$ 를 만족하면 p^* 가 체인의 정상 분포
 - ✓ 상세 균형(Detailed Balance): $p^*(z)T(z, z') = p^*(z')T(z', z)$.
임의의 두 상태 사이 순방향/역방향 확률 질량 흐름이 대칭이면, 불변 분포의 존재가 자동으로 보장됨
 - ✓ 에르고딕성(Ergodicity): 어떤 초기 상태에서 출발하든, 충분한 시간 후 반드시 유일한 평형 분포 p^* 에 도달하는 성질.
초기 과도기(Burn-in) 샘플만 버리면 이후 샘플은 p^* 따름
 - ✓ 따라서 MCMC 알고리즘 설계의 핵심은 '상세 균형을 만족하는 전이 확률 T 를 어떻게 구성할 것인가'에 있음

02 | Markov Chain Monte Carlo

The Metropolis Algorithm



- 가장 기본적인 *MCMC*: 대칭 제안 분포 기반

- ✓ 현재 상태 $z^{(\tau)}$ 에서 대칭적 제안 분포 $q(z^*|z^{(\tau)})$ 를 통해 후보 z^* 를 생성
대칭 조건: $q(z_A|z_B) = q(z_B|z_A)$
(한 걸음 이동할 때 좌우/상하 어느 쪽으로든 같은 확률로 가는 무방향 보행)

- 채택-기각 결정 규칙

- ✓ $A(z^*, z^{(\tau)}) = \min(1, \tilde{p}(z^*) / \tilde{p}(z^{(\tau)}))$. 비정규화 밀도 $\tilde{p}$ 만으로 계산 가능
- ✓ $\tilde{p}(z^*) \geq \tilde{p}(z^{(\tau)})$: 후보가 더 높은 확률 영역이면 무조건 채택 (확률 봉우리로 등반)
- ✓ $\tilde{p}(z^*) < \tilde{p}(z^{(\tau)})$: 밀도 비율만큼의 확률로 확률적 채택 → 낮은 확률 영역도 탐색 가능 (멀티 모달일 시 계곡 탈출 가능)

- 한계: Random Walk Behavior

- ✓ 대칭 제안 분포는 방향 선호가 없어, 체인이 앞뒤로 무작위 배회(Random walk)함
- ✓ 독립적인 유효 샘플 하나를 얻는 데 막대한 반복이 필요 → 비대칭 제안의 필요성 대두

Algorithm 14.1: Metropolis sampling


Input: Unnormalized distribution $\tilde{p}(z)$
Proposal distribution $q(z|\tilde{z})$
Initial state $z^{(0)}$
Number of iterations T

Output: $z \sim \tilde{p}(z)$

```
 $z_{\text{prev}} \leftarrow z^{(0)}$   
// Iterative message-passing  
for  $\tau \in \{1, \dots, T\}$  do  
     $z^* \sim q(z|z_{\text{prev}})$  // Sample from proposal distribution  
     $u \sim \mathcal{U}(0, 1)$  // Sample from uniform  
    if  $\tilde{p}(z^*) / \tilde{p}(z_{\text{prev}}) > u$  then  
         $z_{\text{prev}} \leftarrow z^*$  //  $z^{(\tau)} = z^*$   
    else  
         $z_{\text{prev}} \leftarrow z_{\text{prev}}$  //  $z^{(\tau)} = z^{(\tau-1)}$   
    end if  
end for  
return  $z_{\text{prev}}$  //  $z^{(T)}$ 
```

02 | Markov Chain Monte Carlo

The Metropolis-Hastings Algorithm



- 메트로폴리스의 일반화: 비대칭 제안 분포 허용

- ✓ 메트로폴리스 알고리즘의 대칭 제약을 제거하여, 목표 분포의 특성에 맞는 비대칭적 제안 분포 $q_k(z^* | z^{(\tau)})$ 를 자유롭게 사용할 수 있게 확장함

- 수정된 채택 확률

- ✓ $A_k(z^*, z^{(\tau)}) = \min(1, [\tilde{p}(z^*) \cdot q_k(z^{(\tau)} | z^*)] / [\tilde{p}(z^{(\tau)}) \cdot q_k(z^* | z^{(\tau)})])$
- ✓ 분자의 $q_k(z^{(\tau)} | z^*)$: 후보→현재 역방향 제안 확률. 분모의 $q_k(z^* | z^{(\tau)})$: 현재→후보 순방향 제안 확률
- ✓ 제안 분포의 비대칭 편향을 역방향/순방향 비율로 보정함으로써, 상세 균형 조건을 수학적으로 강제하여 목표 분포 수렴을 보장

- 실전적 한계: 스텝 크기의 딜레마

- ✓ 제안 스케일 ρ 가 크면 → 넓게 탐색하지만 채택률 급락 (특히 좁은 축 방향에서 대부분 기각)
- ✓ 제안 스케일 ρ 가 작으면 → 채택률은 높지만 *Random walk* 배치가 심화
- ✓ 상관관계가 강한 길쭉한 타원형 분포에서 독립 샘플 하나를 얻으려면 많은 반복이 필요 → 좌표별 조건부 추출이라는 대안 등장

Algorithm 14.2: Metropolis-Hastings sampling

Input: Unnormalized distribution $\tilde{p}(z)$
 Proposal distributions $\{q_k(z|\tilde{z}) : k \in 1, \dots, K\}$
 Mapping from iteration index to distribution index $M(\cdot)$
 Initial state $z^{(0)}$
 Number of iterations T

Output: $z \sim \tilde{p}(z)$

```

 $z_{\text{prev}} \leftarrow z^{(0)}$ 
// Iterative message-passing
for  $\tau \in \{1, \dots, T\}$  do
     $k \leftarrow M(\tau)$  // get distribution index for this iteration
     $z^* \sim q_k(z|z_{\text{prev}})$  // sample from proposal distribution
     $u \sim \mathcal{U}(0, 1)$  // sample from uniform
    if  $\tilde{p}(z^*)q(z_{\text{prev}}|z^*) / \tilde{p}(z_{\text{prev}})q(z^*|z_{\text{prev}}) > u$  then
         $z_{\text{prev}} \leftarrow z^*$  //  $z^{(\tau)} = z^*$ 
    else
         $z_{\text{prev}} \leftarrow z_{\text{prev}}$  //  $z^{(\tau)} = z^{(\tau-1)}$ 
    end if
end for
return  $z_{\text{prev}}$  //  $z^{(T)}$ 
    
```

02 | Markov Chain Monte Carlo

Gibbs Sampling

- 좌표별 조건부 추출: *MH*의 특수 형태

- ✓ 전체 D 차원을 동시에 이동시키는 대신, 한 번에 변수 하나 z_i 만 선택하여 나머지가 고정된 조건부 분포 $p(z_i | z^1, \dots, z_i^{-1}, z_i^{+1}, \dots, z_D)$ 에서 직접 추출함
- ✓ 이 조건부 추출을 모든 변수에 대해 순환적으로 반복하면 전체 결합 분포 $p(z)$ 에서의 샘플을 얻게 됨
- ✓ 다변수이며

- 기각 없는 100% 채택

- ✓ 제안된 샘플이 단 한 번의 기각 없이 항상 채택되므로 연산 낭비가 없음

- 한계와 보완


- ✓ 변수 간 상관관계가 강한 경우, 각 축 방향으로만 계단식 이동하여 대각선 방향 탐색이 불가능 → 수렴 속도 저하
- ✓ 그러나 *MCMC* 전체 계열의 공통 과제는 여전히 존재
 - 분포의 기울기 정보를 전혀 활용하지 않는 '맹목적 탐색'이라는 구조적 비효율 → 기울기 기반 샘플링의 필요성

Algorithm 14.3: Gibbs sampling

Input: Initial values $\{z_i : i \in 1, \dots, M\}$
Conditional distributions $\{p(z_i | \{z_{j \neq i}\}) : i \in 1, \dots, M\}$
Number of iterations T

Output: Final values $\{z_i : i \in 1, \dots, M\}$

```
for  $\tau \in \{1, \dots, T\}$  do
  for  $i \in \{1, \dots, M\}$  do
     $z_i \sim p(z_i | \{z_{j \neq i}\})$ 
  end for
end for
return  $\{z_i : i \in 1, \dots, M\}$ 
```



03 | Langevin Sampling

Energy-based Models (EBM)

- 배경: 정규화 제약이 모델 자유도를 제한하는 문제
 - ✓ 확률 생성 모델은 $\int p(x|w)dx = 1$ (정규화 조건)을 만족해야 하므로, 신경망 아키텍처 선택이 극도로 제한됨 (예: 출력을 *Softmax*로 제한)
 - ✓ 에너지 기반 모델(EBM)은 이 제약을 우회하여 모델 자유도를 극대화하는 프레임워크
- EBM의 수학적 구조
 - ✓ 에너지 함수 $E(x, w)$: 임의의 신경망이 입력 x 에 대해 출력하는 무제한 스칼라 값. w 는 학습 파라미터
 - ✓ 확률 밀도 정의: $p(x|w) = \exp\{-E(x, w)\} / Z(w)$
 - 에너지를 확률 비례량으로 변환. 에너지가 낮을수록 확률이 높음. 열역학에서 "낮은 에너지 상태가 더 안정적이고 자주 관찰된다"는 볼츠만 분포(Boltzmann distribution)와 정확히 같은 형태이며 쉽게 말하면 우도의 역할을 해줌
 - ✓ 파티션 함수: $Z(w) = \int \exp\{-E(x, w)\}dx$
 - 정규화 상수로서 확률의 총합을 1로 맞추는 역할이나, 전체 입력 공간에 대한 적분이므로 계산 불가
- 핵심 난관
 - ✓ $Z(w)$ 가 전체 입력 공간에 대한 적분 이라서 예를 들어 x 가 이미지라면 모든 가능한 이미지에 대한 적분이어서 $Z(w)$ 를 계산할 수 없으므로 $p(x|w)$ 를 직접 평가하거나 *MLE* 로그 우도의 기울기를 바로 구할 수 없음 $\rightarrow Z(w)$ 를 우회하는 학습법이 필요
- *MLE* 학습에 기댓값이 필요하고, 기댓값에 샘플링이 필요함 $\rightarrow$ 모든 샘플링 기법이 EBM과 만나는 지점(훈련 데이터가 실제로 잘 나오게 하는 w 를 찾기)

03 | Langevin Sampling

EBM의 우도 극대화 메커니즘

- 로그 우도 기울기의 분해(실제 훈련데이터에 대한 로그 우도 기댓값)


- ✓ $\nabla_w E_{(pD)}[\ln p(x | w)] = -E_{(pD)}[\nabla_w E(x, w)] + E_{(pM)}[\nabla_w E(x, w)]$
- ✓ (pD) : 실제 훈련 데이터 분포. (pM) : 현재 모델이 정의하는 분포. ∇_w : 파라미터 w 에 대한 기울기
- ✓ 놀랍게도 $Z(w)$ 의 직접 계산 없이, 두 기댓값의 차이만으로 로그 우도 기울기를 완전히 표현 가능

- 직관적 해석: Push-Down & Pull-Up 역학 → (pM) 업데이트

- ✓ 1항 (음의 부호-빨간점): 실제 데이터 위치에서 에너지를 낮춤(Push down) → 해당 영역의 확률 밀도 상승. '이 데이터가 나올 확률을 높여라'
- ✓ 2항 (양의 부호-파란점): 모델이 현재 생성하는 가짜 샘플 위치에서 에너지를 높임(Pull up) → 해당 영역의 확률 밀도 하강. '가짜 데이터가 나올 확률을 낮춰라'
- ✓ 두 힘이 평형에 도달하면 $pM = pD$, 즉 모델 분포가 데이터 분포와 일치하여 학습 완료

- 남은 문제

- ✓ 2항의 $E_{(pM)}[\nabla_w E(x, w)]$ 을 계산하려면 현재 모델 분포 pM 즉, $p(x|w)$ 에서 샘플을 추출해야 하는데, $Z(w)$ 를 모르므로 기존 MCMC를 바로 적용하기 어려움 → Langevin Dynamics로 해결



03 | Langevin Sampling

Langevin Dynamics

- **돌파구: Score Function**으로 $Z(w)$ 를 완전히 제거
 - ✓ 스코어 함수: $s(x, w) = \nabla_x \ln p(x|w) = -\nabla_x E(x, w)$.
 - 여기서 ∇_x 는 파라미터가 아닌 데이터 x 에 대한 기울기
 - 즉, 현재 샘플 x 가 있을 때, 이 샘플을 어느 방향으로 움직이면 확률 밀도 $p(x|w)$ 가 증가하는지를 알려주는 벡터
 - ✓ 핵심: $\ln p(x|w) = -E(x, w) - \ln Z(w)$ 이므로, x 로 미분하면 $Z(w)$ 는 x 와 무관한 상수라서 완전히 소거됨 → 에너지 함수의 기울기만으로 샘플링 가능
- **Langevin 샘플링 업데이트 규칙**(score 방향으로 가는 x 를 샘플링)
 - ✓ $x^{(\tau+1)} = x^{(\tau)} + \eta \cdot \nabla_x \ln p(x^{(\tau)}, w) + \sqrt{2\eta} \cdot \epsilon^{(\tau)}$
 - ✓ $x^{(\tau)}$: 현재 샘플 위치, η : 스텝 크기(학습률), $\epsilon^{(\tau)} \sim N(0, I)$: 표준 가우시안 노이즈
 - ✓ $\eta \cdot \nabla_x \ln p$: 스코어 함수를 따라 확률 밀도가 높은 봉우리 방향으로 결정론적 상승 (기울기 정보를 적극 활용)
 - ✓ $\sqrt{(2\eta)} \cdot \epsilon$: 확률적 노이즈 주입으로 국소 극대(Local maxima)에 갇히는 것을 방지하고, 다중 모드 분포의 여러 봉우리를 탐험
- **MCMC 대비 핵심 장점**
 - ✓ 기존 MCMC는 분포의 기울기를 전혀 사용하지 않는 맹목적 *Random walk*이었으나, *Langevin*은 $\nabla_x \ln p$ 라는 '나침반'을 활용하여 목표 분포의 고밀도 영역으로 효율적으로 수렴

Algorithm 14.4: Langevin sampling

Input: Initial value $\mathbf{x}^{(0)}$
Probability density $p(\mathbf{x}, \mathbf{w})$
Learning rate parameter η
Number of iterations T

Output: Final value $\mathbf{x}^{(T)}$

```
 $\mathbf{x} \leftarrow \mathbf{x}_0$ 
for  $\tau \in \{1, \dots, T\}$  do
   $\epsilon \sim \mathcal{N}(\epsilon | \mathbf{0}, \mathbf{I})$ 
   $\mathbf{x} \leftarrow \mathbf{x} + \eta \nabla_{\mathbf{x}} \ln p(\mathbf{x}, \mathbf{w}) + \sqrt{2\eta} \epsilon$ 
end for
return  $\mathbf{x}$  // Final value  $\mathbf{x}^{(T)}$ 
```

Q&A

감사합니다.