



Deep Learning Foundations and Concepts

15. Discrete Latent Variables

김호중 / 2026.05.28



Computational Data Science LAB

CONTENTS

1. K-means Clustering
2. Mixtures of Gaussians
3. Expectation-Maximization Algorithm
4. Evidence Lower Bound (ELBO)

Discrete Latent Variables

About Discrete Latent Variables

- 잠재변수(Latent Variable)란?
 - ✓ 데이터에 직접 적혀 있지는 않지만, 데이터를 설명하려고 모델 내부에서 있다고 가정하는 숨은 변수
 - ✓ 예: 점 x_n 을 봤을 때 “이 점이 1·2·3번 군집 중 어디서 왔는가”는 원본 데이터에 없는 정보 — 우리가 추정해야 할 숨은 정보
 - ✓ 그 중에서도 유한한 선택지 중 하나를 고르는 이산(discrete) 잠재변수를 다룸
- 왜 K-means → GMM → EM → ELBO 인가?
 - ✓ K-means : 각 점을 가장 가까운 군집 하나에 딱 잘라 넣음 — 0 또는 1 의 hard 할당
 - ✓ GMM : hard 할당의 한계를 풀기 위해 “k번 군집에서 왔을 확률”로 부드럽게 표현 → 책임도(responsibility)
 - ✓ EM : GMM 은 한 번에 닫힌 해가 안 나옴 → E step ↔ M step 을 번갈아 도는 반복 학습 알고리즘이 필요
 - ✓ ELBO : EM 이 매 cycle 마다 로그우도를 떨어뜨리지 않는다는 사실을 이론적으로 증명해주는 도구

01 | K-means Clustering

Problem Setup and Algorithm

- **군집화 문제 : 어디에 속하는지 모르는 점들에 라벨 붙이기**

- ✓ N 개 데이터 $\{x_1, \dots, x_N\}$ (각 $x_n \in \mathbb{R}^D$) 를 K 개 군집으로 나누는 비지도 학습 — K 는 사용자가 미리 정함
- ✓ 각 군집은 그 군집의 대표값인 prototype 벡터 $\mu_k \in \mathbb{R}^D$ 하나로 요약
- ✓ “각 점이 어느 군집인가”는 데이터에 없는 숨겨진 정보 $\rightarrow$ 1-of- K 인코딩 지시변수 $r_{nk} \in \{0,1\}$ 로 표현 (한 점은 정확히 하나의 군집, $\sum_k r_{nk} = 1$)
- ✓ 변수 : $x_n \in \mathbb{R}^D$ (n 번째 데이터), $\mu_k \in \mathbb{R}^D$ (k 번째 군집 중심 = prototype), $r_{nk} \in \{0,1\}$ (1-of- K 인코딩 지시변수), K (사전 지정 군집 수)

- **목적함수 J : 자기가 속한 군집 중심까지의 거리 제곱합 (= 왜곡 측도)**

- ✓ $J = \sum_n \sum_k r_{nk} \|x_n - \mu_k\|^2$
— $r_{nk}=1$ 인 항(자기 군집)만 손실에 들어감
- ✓ 모든 점이 자기 중심에 최대한 가까이 가도록 J 를 줄이는 게 학습의 목표
- ✓ r_{nk} 와 μ_k 를 동시에 풀어야 하는데 비볼록 $\rightarrow$ 닫힌 해 불가, 두 변수를 번갈아가며 최적화
- ✓ 변수 : J (왜곡 측도 = K-means 손실함수), $\|\cdot\|^2$ (제곱 L2 거리)

- **교대 최적화 : E step (할당) $\leftrightarrow$ M step (중심 갱신)**

- ✓ E step : 중심 μ_k 고정 $\rightarrow$ 각 점을 가장 가까운 중심에 hard 할당
- ✓ M step : 할당 r_{nk} 고정 $\rightarrow$ 새 중심은 그 군집에 속한 점들의 산술 평균 $\mu_k = (\sum_n r_{nk} x_n) / N_k$
- ✓ 할당이 더 이상 변하지 않을 때까지 반복 $\rightarrow$ 유한 단계에 수렴 (우측 그림처럼 결정 경계가 점점 안정)
- ✓ 변수 : $N_k = \sum_n r_{nk}$ (군집 k 의 점 개수)


Algorithm 15.1: K-means algorithm

```

Input: Initial prototype vectors  $\mu_1, \dots, \mu_K$ 
Data set  $x_1, \dots, x_N$ 
Output: Final prototype vectors  $\mu_1, \dots, \mu_K$ 


 $\{r_{nk} \leftarrow 0\}$  // Initially set all assignments to zero
repeat
   $\{r_{nk}^{(old)}\} \leftarrow \{r_{nk}\}$ 
  // Update assignments
  for  $N \in \{1, \dots, N\}$  do
     $k \leftarrow \arg \min_j \|x_n - \mu_j\|^2$ 
     $r_{nk} \leftarrow 1$ 
     $r_{nj} \leftarrow 0, \quad j \in \{1, \dots, K\}, j \neq k$ 
  end for
  // Update prototype vectors
  for  $k \in \{1, \dots, K\}$  do
     $\mu_k \leftarrow \sum_n r_{nk} x_n / \sum_n r_{nk}$ 
  end for
until  $\{r_{nk}\} = \{r_{nk}^{(old)}\}$  // Assignments unchanged
return  $\mu_1, \dots, \mu_K, \{r_{nk}\}$ 

```



01 | K-means Clustering


Image Segmentation



- **이미지 분할 : 같은 K-means 를 색상 공간에 그대로 적용**
 - ✓ 이미지의 각 픽셀을 RGB 벡터 $(R,G,B) \in [0,1]^3$ 으로 보고, 이를 데이터 점 x_n 으로 삼아 K-means 실행
 - ✓ 끝나면 각 픽셀은 자기와 가장 가까운 prototype 벡터 색상 μ_k 로 치환됨 → 이미지가 K개 대표 색상만으로 재구성
 - ✓ 우측 결과 : K=2 면 거칠고 단조, K=10 이면 원본에 가까움 — K 가 “화질 ↔ 압축률” trade-off 를 결정
 - ✓ 변수 : $x_n \in [0,1]^3$ (픽셀 RGB), μ_k (k번째 codebook 색상), K (대표 색상 개수)
- **손실 압축으로의 확장 : 픽셀 RGB 대신 prototype 벡터 인덱스만 저장**
 - ✓ 원래는 픽셀마다 (R,G,B) 세 값을 저장해야 함 → 가장 가까운 μ_k 의 인덱스 k 하나만 저장하면 됨
 - ✓ 복원할 때는 인덱스 → μ_k 로 매핑해서 이미지를 다시 만들 — K 가 “저장량 ↔ 복원 품질”의 다이얼
 - ✓ 변수 : 인덱스 $k \in \{1, \dots, K\}$ (prototype 벡터 인덱스, 저장 단위)
- **Hard assignment 의 한계 → 왜 GMM 이 필요한가**
 - ✓ $r_{nk} \in \{0,1\}$ 은 두 중심 사이의 “애매한 경계 점”도 무조건 한쪽에 넣어야 함 → 불확실성을 표현 불가
 - ✓ 거리 $\|x_n - \mu_k\|^2$ 만 사용 → 군집의 모양·방향·크기를 무시 (길쭉한·겹친·크기 다른 군집에 취약)
 - ✓ 해결책 : r_{nk} 를 $[0,1]$ 확률값으로 완화 + 거리 대신 컴포넌트별 가우시안 사용 → GMM 으로 자연스럽게 확장
 - ✓ 변수 : hard $r_{nk} \in \{0,1\}$ vs soft $\gamma(z_{nk}) \in [0,1]$ (GMM 에서 도입할 책임도)

02 | Mixtures of Gaussians

Latent-Variable Formulation



- 이산 잠재변수 z 로 mixture 만들기 — “이 데이터를 어느 컴포넌트가 생성했는가?”
 - ✓ 각 데이터의 생성 컴포넌트를 1-of-K 이진 벡터 $z = (z_1, \dots, z_K)$, $z_k \in \{0,1\}$, $\sum_k z_k = 1$ 로 명시
 - ✓ 사전(각 컴포넌트가 선택될 확률) : $p(z_k = 1) = \pi_k$
— 혼합 계수, $\sum_k \pi_k = 1$, $0 \leq \pi_k \leq 1$
 - ✓ 조건부(그 컴포넌트가 데이터를 만드는 분포) : $p(x | z_k = 1) = \mathcal{N}(x | \mu_k, \Sigma_k)$
— 변수 z 가 “몇 번 컴포넌트에서 만들지”를 고르고 k 번 컴포넌트가 선택되면, x 는 평균 μ_k , 공분산 Σ_k 를 가진 가우시안에서 나온다고 생각
— 공분산 Σ_k 가 있어 군집 모양·방향까지 표현 (K-means와 차별점)
 - ✓ 변수 : z (1-of-K 이산 잠재 벡터), π_k (혼합 계수 = k 번 컴포넌트 사전 확률), $\mu_k \cdot \Sigma_k$ (k 번 컴포넌트의 평균·공분산)
- z 를 합으로 없앤(marginalization) mixture 분포 $p(x)$
 - ✓ $P(x) = \sum_z p(z) p(x|z) = \sum_k \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$ — x 가 나올 전체 확률은, 각 컴포넌트가 x 를 만들 가능성을 전부 더한 것(K 개 가우시안의 가중합)
 - ✓ 단일 가우시안(타원 하나)으로 못 그리는 복잡한 분포도 GMM 으로 표현 가능
 - ✓ 변수 : $\mathcal{N}(\cdot | \mu, \Sigma)$ (다변량 가우시안 밀도함수), $p(x)$ (잠재변수를 제거한 marginal 분포)
- 사후확률 = 책임도 (responsibility) $\gamma(z_{nk})$
 - ✓ 데이터 x_n 을 본 뒤 “이 점이 k 번 컴포넌트에서 왔을 확률”을 베이즈 정리로 계산한 값
 - ✓ $\gamma(z_{nk}) = p(z_{nk} = 1 | x_n) = \pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k) / \sum_j \pi_j \mathcal{N}(x_n | \mu_j, \Sigma_j)$ — 한 점에 대해 $\sum_k \gamma(z_{nk}) = 1$
 - ✓ K-means 의 hard $r_{nk} \in \{0,1\}$ 가 $\rightarrow$ 확률값 $\gamma(z_{nk}) \in [0,1]$ 로 일반화된 soft assignment
 - ✓ 변수 : $\gamma(z_{nk}) \in [0,1]$ (책임도 = k 컴포넌트가 x_n 을 생성했을 사후 확률)

02 | Mixtures of Gaussians

Maximum Likelihood

• 분포의 파라미터 학습을 위한 GMM 의 로그우도 — MLE 가 어려운 두 가지 이유

- ✓ 전체 데이터의 우도는 $p(X|\theta) = \prod_{n=1}^N p(x_n|\theta) = \sum_k \pi_k \mathcal{N}(x_n|\mu_k, \Sigma_k)$
- ✓ $\ln p(X|\theta) = \sum_n \ln \{\sum_k \pi_k \mathcal{N}(x_n|\mu_k, \Sigma_k)\}$ — 로그 안에 합 → 컴포넌트별 분리·미분으로 닫힌 해를 얻을 수 없음
- ✓ 예를 들어 μ_k 에 대해 미분하면 결과가 $\rightarrow \mu_k = \frac{\sum_n \gamma(z_{nk})x_n}{\sum_n \gamma(z_{nk})}$
- ✓ 그런데 문제는 여기 들어가는 책임도 $\gamma(z_{nk})$ 가 다시 현재 파라미터에 의존 $\rightarrow \gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(x_n|\mu_k, \Sigma_k)}{\sum_j \pi_j \mathcal{N}(x_n|\mu_j, \Sigma_j)}$
- ✓ 즉 평균 μ_k 를 구하려면 책임도 γ 가 필요하고, 책임도 γ 를 구하려면 다시 μ_k, Σ_k, π_k 가 필요(닭과 달걀 구조)
- ✓ 변수 : $X = \{x_n\}_{n=1}^N$ (관측 데이터 전체), $\theta = (\pi, \mu, \Sigma)$ (전체 모델 파라미터)

• 반복이 필연적 = EM


- ✓ 그래서 “E step (현재 파라미터로 책임도 계산) ↔ M step (책임도로 파라미터 갱신)”을 번갈아 도는 EM 이 필요
- ✓ 매 cycle 마다 로그우도가 단조 비감소. 그러나, EM 초기값 특성상 전역 최적해 보장은 아님
- ✓ 변수 : E step (책임도 계산 단계), M step (파라미터 갱신 단계), cycle (한 번의 E → M 쌍)

Algorithm 15.2: EM algorithm for a Gaussian mixture model

Input: Initial model parameters $\{\mu_k\}, \{\Sigma_k\}, \{\pi_k\}$
 Data set $\{x_1, \dots, x_N\}$
Output: Final model parameters $\{\mu_k\}, \{\Sigma_k\}, \{\pi_k\}$

```

repeat
  // E step
  for  $n \in \{1, \dots, N\}$  do
    for  $k \in \{1, \dots, K\}$  do
       $\gamma(z_{nk}) \leftarrow \frac{\pi_k \mathcal{N}(x_n|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_n|\mu_j, \Sigma_j)}$ 
    end for
  end for
  // M step
  for  $k \in \{1, \dots, K\}$  do
     $N_k \leftarrow \sum_{n=1}^N \gamma(z_{nk})$ 
     $\mu_k \leftarrow \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) x_n$ 
     $\Sigma_k \leftarrow \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (x_n - \mu_k)(x_n - \mu_k)^T$ 
     $\pi_k \leftarrow \frac{N_k}{N}$ 
  end for
  // Log likelihood
   $\mathcal{L} \leftarrow \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k \mathcal{N}(x_n|\mu_k, \Sigma_k) \right\}$ 
until convergence
return  $\{\mu_k\}, \{\Sigma_k\}, \{\pi_k\}$ 
  
```



03 | Expectation-Maximization Algorithm

General EM Algorithm

- 일반 설정 — GMM의 어려움은 모든 잠재변수 모델의 공통 난점

- ✓ 관측 X , 잠재 Z , 파라미터 θ — 목표는 $\ln p(X|\theta) = \ln \{\sum_z p(X, Z|\theta)\}$ 의 최대화
- ✓ “로그 안의 합” 구조는 GMM만의 문제가 아니라 잠재변수 모델에서 일반적으로 발생 (닫힌 해 어려움)
- ✓ 다행히 Z 가 알려져 있다고 가정하면 데이터 로그우도 $\ln p(X, Z|\theta)$ 는 보통 다루기 쉬움
- ✓ 변수: X (관측), Z (잠재변수·보통 관측 불가), $\ln p(X|\theta)$ (marginal 로그우도 = EM의 최적화 목표)

- EM의 핵심 트릭 — 알 수 없는 Z 를 “현재 모델 기준의 사후 기댓값”으로 대체

- ✓ E step: 현재 파라미터 θ^{old} 에서 사후분포 $p(Z|X, \theta^{\text{old}})$ 를 계산(GMM에서의 책임도 개념)
- ✓ 보조함수 정의: $Q(\theta, \theta^{\text{old}}) = E[\ln p(X, Z|\theta)] = \sum_z p(Z|X, \theta^{\text{old}}) \ln p(X, Z|\theta)$
- ✓ 현재 모델 θ^{old} 이 추정한 잠재변수 Z 의 사후확률을 가중치로 사용해서, 완전데이터 로그우도 $\ln p(X, Z|\theta)$ 의 평균을 낸 함수
- ✓ 관측 불가능한 Z 를 실제 값으로 못 넣으니, 현재 모델이 생각하는 사후로 평균을 내서 대체
- ✓ 변수: θ^{old} (현재 추정값), $p(Z|X, \theta^{\text{old}})$ (E step의 사후분포), $Q(\theta, \theta^{\text{old}})$ (보조함수 = 완전데이터 우도의 사후 기댓값)

- M step — 보조함수를 최대화하는 새 파라미터로 갱신, GMM과의 일관성

- ✓ $\theta^{\text{new}} = \operatorname{argmax}_{\theta} Q(\theta, \theta^{\text{old}})$ — 로그가 결합분포에 직접 작용하므로 보통 닫힌 해
- ✓ E-step에서 계산한 잠재변수의 확률분포를 고정하고, 그 기준에서 완전데이터 로그우도의 기대값 Q 를 가장 크게 만드는 새 파라미터를 찾음
- ✓ 결론: GMM-EM은 일반 EM 알고리즘의 특수 사례
- ✓ 변수: $\theta^{\text{new}} = \operatorname{argmax}_{\theta} Q$ (M step 결과), $E[z_{nk}] = \gamma(z_{nk})$ (사후분포 하 z 의 기댓값 = 책임도)

Algorithm 15.3: General EM algorithm

Input: Joint distribution $p(\mathbf{X}, \mathbf{Z}|\theta)$

Initial parameters θ^{old}

Data set $\mathbf{x}_1, \dots, \mathbf{x}_N$

Output: Final parameters θ

repeat

$Q(\theta, \theta^{\text{old}}) \leftarrow \sum_z p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}}) \ln p(\mathbf{X}, \mathbf{Z}|\theta)$ // E step

$\theta^{\text{new}} \leftarrow \operatorname{argmax}_{\theta} Q(\theta, \theta^{\text{old}})$ // M step

$\mathcal{L} \leftarrow p(\mathbf{X}|\theta^{\text{new}})$ // Evaluate log likelihood

$\theta^{\text{old}} \leftarrow \theta^{\text{new}}$ // Update the parameters

until convergence

return θ^{new}

03 | Expectation-Maximization Algorithm

K-means Limit

- 공유 등방 공분산 가정과 $\varepsilon \rightarrow 0$ 극한 — K-means의 진짜 정체


- ✓ 모든 컴포넌트의 공분산을 같은 등방 $\Sigma_k = \varepsilon I$ 로 고정 (ε 는 학습하지 않는 스칼라)
- ✓ GMM의 책임도 수식에 $\Sigma_k = \varepsilon I$ 를 대입 시에
기우시안 밀도는 $\mathcal{N}(x_n | \mu_k, \varepsilon I) \propto \exp(-\|x_n - \mu_k\|^2 / 2\varepsilon) \rightarrow$ 책임도는 $\gamma(z_{nk}) = \frac{\pi_k \exp\left(-\frac{\|x_n - \mu_k\|^2}{2\varepsilon}\right)}{\sum_j \pi_j \exp\left(-\frac{\|x_n - \mu_j\|^2}{2\varepsilon}\right)}$ 즉, 책임도 γ 가 “거리 제곱에 대한 softmax” 형태로 정리
- ✓ $\varepsilon \rightarrow 0$: 거리 차이가 엄청 크게 증폭하며, 가장 가까운 중심의 항만 압도적으로 커짐
 $\rightarrow \gamma \rightarrow 1$ (가장 가까운 컴포넌트만 선택하는 형태), 나머지 $\rightarrow 0 \Rightarrow$ hard 할당 (like K-means)
- ✓ 변수 : ε (공유 등방 공분산의 스칼라 계수, 학습하지 않음), $\Sigma_k = \varepsilon I$ (등방 공분산)

- 이 극한에서 Q 최대화 = K-means J 최소화

- ✓ $\varepsilon \rightarrow 0$ 극한에서 GMM-EM의 Q 최대화가 $J = \sum_n \sum_k r_{nk} \|x_n - \mu_k\|^2$ 최소화와 정확히 동치
- ✓ 즉 K-means는 “공분산 구조를 완전히 무시한 + 책임도를 0/1로 hard 할당하는” 비확률적 GMM-EM
- ✓ “이산 잠재변수 모델의 가장 단순·비확률적 형태가 K-means”라는 해석
- ✓ 변수 : $J = \sum_n \sum_k r_{nk} \|x_n - \mu_k\|^2$ (K-means 왜곡 측도 = GMM-EM의 $\varepsilon \rightarrow 0$ 극한)

04 | Evidence Lower Bound

ELBO Decomposition



남은 질문 — “왜” EM 이 로그우도를 안 떨어뜨리는가?

- ✓ 지금까지의 도출은 알고리즘이 “잘 작동함”은 보여줬지만, $\ln p(X|\theta^{\text{new}}) \geq \ln p(X|\theta^{\text{old}})$ 의 엄밀 증명은 아니었음
- ✓ 답: 잠재변수 위에 임의의 자유 분포 $q(Z)$, $q(Z) = p(Z|X, \theta)$ 를 도입해 로그우도를 두 항으로 분해 가능 — 그 결과로 자연스럽게 단조성이 따름
- ✓ $q(Z)$ 는 진짜 사후일 필요 없음. 어떤 q 든 성립하는 항등식이라서 자유롭게 고를 수 있음
- ✓ 변수: $\ln p(X|\theta)$ (목표인 marginal 로그우도), $q(Z)$ (잠재변수 위의 임의의 분포 = 변분 자유 변수)

항등식(수학적 트릭과 베이즈 정리에 의해): $\ln p(X|\theta) = \ln \sum p(X, Z | \theta) = \mathcal{L}(q, \theta) + KL(q \parallel p(Z|X, \theta))$ →

- ✓ ELBO: $\mathcal{L}(q, \theta) = \sum_Z q(Z) \ln \{ p(X, Z | \theta) / q(Z) \} = \mathbb{E}_q [\ln p(X, Z | \theta)] + H(q)$
- ✓ KL 항: $KL(q \parallel p) = - \sum_Z q(Z) \ln \{ p(Z | X, \theta) / q(Z) \}$ — q 와 진짜 사후 사이의 거리
- ✓ 두 항을 더하면 q 가 깔끔히 사라지고 정확히 로그우도 — 임의의 q 에 대해 성립
- ✓ 변수: $\mathcal{L}(q, \theta)$ (ELBO = 로그우도의 하한 후보), $KL(q \parallel p)$ (q 와 진짜 사후 사이 KL divergence), $H(q)$ (q 의 엔트로피)

Lower bound 보장 & tightness 조건 — 왜 “Lower Bound” 인가

- ✓ Gibbs 부등식 $KL(q \parallel p) \geq 0$ 은 항상 성립 $\Rightarrow \mathcal{L}(q, \theta) \leq \ln p(X|\theta)$ — $\mathcal{L}$ 이 진짜 하한 (Evidence Lower Bound)
- ✓ 등호 조건: $q(Z) = p(Z | X, \theta)$ 일 때만 $KL = 0$, 그때만 ELBO 가 로그우도에 딱 닿음 (tight)
- ✓ 즉 q 를 진짜 사후로 두면 lower bound 가 정확해짐 — 바로 이 점이 EM 의 출발점

ELBO는:

$$\mathcal{L}(q, \theta) = \sum_Z q(Z) \ln \frac{p(X, Z | \theta)}{q(Z)}$$

KL은:

$$KL(q \parallel p(Z|X, \theta)) = \sum_Z q(Z) \ln \frac{q(Z)}{p(Z|X, \theta)}$$

두 개를 더해보자.

$$\begin{aligned} & \mathcal{L}(q, \theta) + KL(q \parallel p(Z|X, \theta)) \\ &= \sum_Z q(Z) \ln \frac{p(X, Z | \theta)}{q(Z)} + \sum_Z q(Z) \ln \frac{q(Z)}{p(Z|X, \theta)} \end{aligned}$$

로그는 더하면 곱으로 합쳐져.

$$= \sum_Z q(Z) \ln \left[\frac{p(X, Z | \theta)}{q(Z)} \cdot \frac{q(Z)}{p(Z|X, \theta)} \right]$$

여기서 $q(Z)$ 가 약분돼.

$$= \sum_Z q(Z) \ln \frac{p(X, Z | \theta)}{p(Z|X, \theta)}$$

그런데 베이즈 정리에 의해

$$p(Z|X, \theta) = \frac{p(X, Z | \theta)}{p(X | \theta)}$$

따라서:

$$\frac{p(X, Z | \theta)}{p(Z|X, \theta)} = p(X | \theta)$$

그래서:

$$= \sum_Z q(Z) \ln p(X | \theta)$$

여기서 $\ln p(X | \theta)$ 는 Z 와 무관한 상수야. 밖으로 뺄 수 있어.

$$= \ln p(X | \theta) \sum_Z q(Z)$$

그리고 $q(Z)$ 는 확률분포니까 전체 합이 1이야.

$$\sum_Z q(Z) = 1$$

결국:

$$\mathcal{L}(q, \theta) + KL(q \parallel p(Z|X, \theta)) = \ln p(X | \theta)$$

이게 슬라이드의 항등식이야.



04 | Evidence Lower Bound

EM Revisited

- EM 을 ELBO 관점에서 다시 보기 — 두 step 모두 “ELBO 를 최대화하는 행위”

- ✓ E step = q 에 대한 ELBO 최대화 / M step = θ 에 대한 ELBO 최대화

- E step 의 재해석 : q 에 대한 ELBO 최대화 → 결과는 사후분포




- ✓ $\theta = \theta^{\text{old}}$ 고정 → $\ln p(X|\theta^{\text{old}})$ 는 q 와 무관한 상수 → $\mathcal{L}$ 최대화 $\equiv$ KL 최소화
- ✓ 최적해 $q^*(Z) = p(Z | X, \theta^{\text{old}})$ — 즉 E step 의 본질은 “사후분포를 q 에 그대로 넣기” (GMM 에서는 책임도 γ 계산)
- ✓ 직후 : $KL = 0$, $\mathcal{L}(q^*, \theta^{\text{old}}) = \ln p(X|\theta^{\text{old}})$ → ELBO 가 로그우도까지 끌어올려짐 (tight)
- ✓ 변수 : $q^*(Z) = p(Z | X, \theta^{\text{old}})$ (E step 의 최적해 = 정확한 사후분포), $KL = 0$ (E step 직후 상태)

- M step 의 재해석 : θ 에 대한 ELBO 최대화 = General EM 의 Q 최대화

- ✓ q^* 고정된 채 $\mathcal{L}(q^*, \theta) = \sum_z q^*(Z) \ln p(X, Z | \theta) + \text{const}(\theta \text{ 무관})$ — 엔트로피 항은 무시
- ✓ 남는 항이 정확히 일반 EM 의 $Q(\theta, \theta^{\text{old}})$ — 두 관점 (보조함수 vs ELBO) 이 완전히 일치함을 확인
- ✓ 변수 : $\theta^{\text{new}} = \text{argmax}_{\theta} \mathcal{L}(q^*, \theta) = \text{argmax}_{\theta} Q$ (두 관점의 M step 이 동일한 결과)

- 단조 비감소성의 깔끔한 증명 — 세 부등식의 연결

- ✓ E step 직후 $\mathcal{L}(q^*, \theta^{\text{old}}) = \ln p(X|\theta^{\text{old}})$, M step 에서 $\mathcal{L}(q^*, \theta^{\text{new}}) \geq \mathcal{L}(q^*, \theta^{\text{old}})$
- ✓ $\ln p(X|\theta^{\text{new}}) \geq \mathcal{L}(q^*, \theta^{\text{new}}) \geq \mathcal{L}(q^*, \theta^{\text{old}}) = \ln p(X|\theta^{\text{old}})$
- ✓ EM = “직접 못 올리는 $\ln p$ 를 매 cycle 마다 tight 한 하한으로 갈아 끼우며 올리는 알고리즘”
- ✓ 변수 : $\theta^{\text{old}} \rightarrow \theta^{\text{new}}$ (EM 한 cycle), $\ln p(X|\theta^{\text{new}}) \geq \ln p(X|\theta^{\text{old}})$ (단조 비감소 보장)



Q&A

감사합니다.