



Probabilistic Machine Learning

김무진 / '26.01.23



Computational Data Science LAB



CONTENTS



1. Machine Learning (기계학습)
 2. Preprocessing (전처리)
 3. Probability (확률)
- 
- 

01 | Machine Learning

교사학습

- Machine Learning
 - ✓ 컴퓨터 프로그램의 과제 T 에서의 성능이 P 로 측정되며 경험 E 에 따라 개선된다면, 이 프로그램은 경험 E 로부터 어떠한 종류의 과제 T 그리고 성능 측정치 P 측면에서 학습된다고 말함
- 교사학습
 - ✓ 과제 T 는 입력 $x \in X$ 에서 출력 $y \in Y$ 로의 매핑을 학습
 - ✓ 분류와 회귀로 구분 됨
- 분류
 - ✓ 입력이 주어졌을 때 클래스 라벨을 예측하는 문제
 - ✓ 성능을 측정하는 일반적인 방법은 훈련집합에서의 오분류율을 측정하는 것

01 | Machine Learning

교사학습

- 오분류율


✓ 수식 : $\mathbb{I}(e) = \begin{cases} 1 & \text{if } e \text{ is true} \\ 0 & \text{if } e \text{ is false} \end{cases}$, $\mathcal{L}(\theta) \triangleq \frac{1}{N} \sum_{n=1}^N \mathbb{I}(y_n \neq f(x_n; \theta))$

- 비대칭 손실함수

		Estimate		
		Setosa	Versicolor	Virginica
Truth	Setosa	0	1	1
	Versicolor	1	0	1
	Virginica	10	10	0

Table 1.2: Hypothetical asymmetric loss matrix for Iris classification.

✓ 수식 : $\mathcal{L}(\theta) \triangleq \frac{1}{N} \sum_{n=1}^N \mathbb{I}(y_n \neq f(x_n; \theta))$



01 | Machine Learning

교사학습

- 회귀 (Regression)
 - ✓ 클래스 라벨 $y \in \{1, \dots, C\}$ 대신 실수 값의 $y \in \mathbb{R}$
 - ✓ 단순선형회귀, 다중선형회귀, 다항회귀
- 특성공학 (Feature Engineering)
 - ✓ Feature 값들을 추가/제외하거나 각 값들을 학습에 유리하게 가공
 - ✓ $\phi(x) = \{1, x, x^2, x^3, \dots, x^D\}$ 입력으로부터 유도된 특성벡터
 - ✓ $f(x; \omega) = \omega^T \phi(x)$




Figure 1.6: Linear and polynomial regression applied to 2d data. Vertical axis is temperature, horizontal axes are location within a room. Data was collected by some remote sensing motes at Intel's lab in Berkeley, CA (data courtesy of Romain Thibaux). (a) The fitted plane has the form $\hat{f}(\mathbf{x}) = w_0 + w_1x_1 + w_2x_2$. (b) Temperature data is fitted with a quadratic of the form $\hat{f}(\mathbf{x}) = w_0 + w_1x_1 + w_2x_2 + w_3x_1^2 + w_4x_2^2$. Generated by `linreg_2d_surface_demo.ipynb`.

01 | Machine Learning

비교사학습

- 비교사학습

- ✓ 확률적 관점에서 비교사학습 과제는 새로운 데이터 x 를 생성하는 $p(x)$ 형식의 무조건부 모델을 적합 시키는 것
- ✓ 반면 교사 학습은 입력이 주어졌을 때 출력에 대한 분포를 구체화하는 조건부 모델 $p(y|x)$ 의 적합을 수반
- ✓ 군집화, 자기 지도 학습(Self-Supervised Learning) 등이 있음

- 비교사학습 평가

- ✓ 비교사학습의 경우 정답이 없기 때문에 출력의 질을 평가하기는 매우 어려움
- ✓ 모델이 본 적 없는 테스트 예제에 적용한 확률을 측정
- ✓ 수식 : $L(\theta; D) = -\frac{1}{|D|} \sum_{x \in D} \log p(x|\theta)$

02 | Preprocessing

One-Hot Encoding과 특성교차(Feature Cross)

- One-Hot Encoding

- ✓ x_1 : 차량의 종류(SUV, 트럭, 자가용) , x_2 : 원산지(일본, 미국)
- ✓ $\phi(x) = [1, I(x_1 = S), I(x_1 = T), I(x_1 = F), I(x_2 = U), I(x_2 = J)]$
- ✓ 특성 사이의 의존성을 포착하지 못함
- ✓ 트럭의 연료 효율성이 낮을 것이라 예상하지만, 미국의 트럭이 일본의 트럭보다 효율성이 낮을 수 있음

- 특성교차(Feature Cross)

- ✓ 수식: $f(x; w) = w^T \phi(x)$
$$\begin{aligned} &= w_0 + w_1 \mathbb{I}(x_1 = S) + w_2 \mathbb{I}(x_1 = T) + w_3 \mathbb{I}(x_1 = F) \\ &+ w_4 \mathbb{I}(x_2 = U) + w_5 \mathbb{I}(x_2 = J) \\ &+ w_6 \mathbb{I}(x_1 = S, x_2 = U) + w_7 \mathbb{I}(x_1 = T, x_2 = U) + w_8 \mathbb{I}(x_1 = F, x_2 = U) \\ &+ w_9 \mathbb{I}(x_1 = S, x_2 = J) + w_{10} \mathbb{I}(x_1 = T, x_2 = J) + w_{11} \mathbb{I}(x_1 = F, x_2 = J) \end{aligned}$$

02 | Preprocessing

결측 데이터 다루기

- MCAR (Missing Completely At Random)
 - ✓ $p(M|X_v, X_h, Y) = p(M)$
 - ✓ 결측은 완전 우연, 데이터 값과 독립
 - ✓ 삭제, 평균, 중앙값, 최빈값 등으로 대체
- MAR (Missing At Random) → 교재의 가정
 - ✓ $p(M|X_v, X_h, Y) = p(M|X_v, Y)$
 - ✓ 결측은 다른 관측된 변수와 연관
 - ✓ 다른 변수를 활용하여 결측치를 예측하여 대체
- NMAR (Not Missing At Random)
 - ✓ $p(M|X_v, X_h, Y) \neq p(M|X_v, Y)$
 - ✓ 결측은 결측값 그 자체와 연관
 - ✓ 모델링, 도메인 지식 활용
- 결측 마스크 행렬 M
 - ✓ $M \in \{0,1\}^{N \times D}$
 - ✓ $M_{nd} = 1 \rightarrow n$ 번째 샘플의 d 번째 feature가 결측
 - ✓ $M_{nd} = 0 \rightarrow$ 관측됨
 - ✓ X_v : Visible (관측치) → 나이
 - ✓ X_h : Hidden (결측치) → 실제 연봉
 - ✓ Y : 라벨 → 직업
- 구분
 - ✓ 다른 변수들과의 상관관계 파악
 - ✓ MCAR → 아무 변수도 유의하지 않음
 - ✓ MAR → 특정 변수들이 유의
 - ✓ NMAR → 유의 변수 없어도 결측이 특정 값에서만 많음

03 | Probability

베이지 정리와 Likelihood

- 베이지 정리
 - ✓ 불확실한 상황에서 새로운 데이터를 얻었을 때, 기존의 믿음을 어떻게 수정해야 하는가에 대한 수학적 공식
 - ✓ 알기 쉬운 확률을 이용해 알기 어려운 확률을 업데이트 하는데 의의가 있음
- *Likelihood* (가능도, 우도) $\neq$ *Probability* (확률)
 - ✓ 이미 일어난 데이터가 특정 가설을 얼마나 지지하는가?
 - ✓ 확률은 가설이 고정, 가능도는 데이터가 고정
 - ✓ 가설이 고정된 상태(H)에서 가능한 데이터(Y)들의 확률 $P(Y|H)$ 을 더하면 1
 - ✓ 데이터(Y)가 고정된 상태에서 서로 다른 가설들($H_1, H_2, \dots$)에 대해 $P(Y|H)$ 각각을 구하는 것이기 때문에 합쳐서 1이 아닐 수 있음
 - ✓ 즉, 가설들 사이의 상대적인 우위를 정하기 위한 지표

03 | Probability

베이즈 정리의 수식과 의미

- 베이즈 정리

- ✓ 수식 : $P(H = h|Y = y) = \frac{P(H=h)p(Y=y|H=h)}{P(Y=y)}$

- ✓ 이유 불충분의 원리 : 하나의 사건을 기대할만한 어떤 이유가 없는 경우에는 가능한 모든 사건에 동일한 확률을 할당해야 한다는 원칙

- ✓ 50%(사전확률) $\rightarrow \frac{0.2}{0.35} = 57\%$ (사후확률 업데이트)



03 | Probability

Soft Max함수와 Log-Sum-Exp Trick

- Soft Max함수

- ✓ 수식 : $p_c = \frac{e^{a_c}}{Z(\mathbf{a})} = \frac{e^{a_c}}{\sum_{c'=1}^C e^{a_{c'}}}$

- ✓ Soft Max를 사용하는 이유

- 지수함수를 사용하여 logit값 중 음수를 양수로 변환하여 음수도 표현 가능
 - 지수함수를 사용하여 큰 차이를 더 크게 강조
 - 모든 결과의 합을 1로 만들어 확률적 해석을 가능하게 만듦

- Log-Sum-Exp Trick

- ✓ $\text{logit } a = (0, 1, 0) \rightarrow z = e^0 + e^1 + e^0 = 4.71$, $\text{logit } a = (1000, 1001, 1000)$ 이라면 ?.. Inf..

- ✓ Soft Max에서 중요한 것은 logit의 절대적인 크기가 아니라, logit값들 사이의 상대적인 차이

- ✓ 수식 : $\log \sum_{c=1}^C \exp(a_c) = m + \log \sum_{c=1}^C \exp(a_c - m)$

- ✓ m 은 logit값 중 가장 큰 값 $\rightarrow$ 가장 큰 값을 기준으로 데이터를 재정렬 하여 지수함수의 폭주를 막으면서 원래 데이터가 가진 상대적인 확률 분포를 유지

03 | Probability

확률변수의 변환

- 확률변수의 변환

- ✓ 현실의 데이터는 매우 복잡하지만, 우리가 다룰 수 있는 수학적 도구는 한정적 → 확률변수의 변환이 필요
- ✓ $x \sim p()$ 가 어떠한 확률변수, $y = f(x)$ 는 변환 Ex) 카이제곱분포

- 이산형 확률변수

- ✓ 수식: $p_y(y) = \sum_{x:f(x)=y} p_x(x)$ For example, if $f(X) = 1$ if X is even and $f(X) = 0$ otherwise, and $p_x(X)$ is uniform on the set $\{1, \dots, 10\}$, then $p_y(1) = \sum_{x \in \{2,4,6,8,10\}} p_x(x) = 0.5$, and hence $p_y(0) = 0.5$ also. Note that in this example, f is a many-to-one function.
- ✓ p 는 PDF(확률밀도함수), P 는 CDF(누적분포함수) 의미

- 연속형 확률변수


- ✓ x 가 연속적이라면, 특정 지점에서의 확률 = 0이므로 CDF로 우회하여 분포를 파악
- ✓ 수식: $P_y(y) \triangleq \Pr(Y \leq y) = \Pr(f(X) \leq y) = \Pr(X \in \{x|f(x) \leq y\})$
- ✓ 역함수가 존재하는 경우 → CDF를 미분하여 y 의 PDF를 유도 가능
- ✓ 역함수가 존재하지 않는 경우 → 몬테카를로 근사 이용

03 | Probability

확률변수의 변환

• 가역변환

- ✓ x 를 $y = f(x)$ 로 변환하더라도 확률 질량은 반드시 같음
- ✓ 수식 : $p(x)dx = p(y)dy \rightarrow p(y) = p(x) \left| \frac{dx}{dy} \right|$
 - $dy > dx \rightarrow$ 공간이 늘어날 때
 - $dy < dx \rightarrow$ 공간이 줄어듦 때



• 일반화

- ✓ 임의의 $p(x)$ 를 위한 일반적인 경우 및 임의의 단조증가 함수 $f: \mathbb{R} \rightarrow \mathbb{R}$, $g = f^{-1}$ 라고 가정
- ✓ 수식 : $P_y(y) = \Pr(f(X) \leq y) = \Pr(X \leq f^{-1}(y)) = P_x(f^{-1}(y)) = P_x(g(y))$
- ✓ CDF를 미분하여 PDF 도출
- ✓ 수식 : $p_y(y) \triangleq \frac{d}{dy} P_y(y) = \frac{d}{dy} P_x(g(y)) = \frac{dx}{dy} \frac{d}{dx} P_x(g(y)) = \frac{dx}{dy} p_x(g(y))$

$$p_y(y) = p_x(g(y)) \left| \frac{d}{dy} g(y) \right|$$

03 | Probability

몬테카를로 근사

- 몬테카를로 근사

- ✓ 수치 결과를 얻기 위해 반복적인 무작위 샘플링을 기반으로 하는 광범위한 계산 알고리즘 (위키피디아)

- ✓ 수식 : $x_s \sim p(x), y_s = f(x_s)$ $\delta(x) = \begin{cases} +\infty & \text{if } x = 0 \\ 0 & \text{if } x \neq 0 \end{cases}, \int_{-\infty}^{+\infty} \delta(x) dx = 1, p_S(y) \triangleq \frac{1}{N_s} \sum_{s=1}^{N_s} \delta(y - y_s)$

- ✓ y 는 y 가 정확히 y_s 일때의 점 질량




Figure 2.24: Computing the distribution of $y = x^2$, where $p(x)$ is uniform (left). The analytic result is shown in the middle, and the Monte Carlo approximation is shown on the right. Generated by `change_of_vars_demo1d.ipynb`.

Q&A

감사합니다.