



Probabilistic Machine Learning

박준수 / 2026.01.30



Computational Data Science LAB

CONTENTS

1. The Multivariate Gaussian (Normal) Distribution
2. Maximum Likelihood Estimation (MLE)
3. Empirical Risk Minimization (ERM)
4. Marginals and Conditionals of an MVN
5. Gaussian Mixture Models

01 | The Multivariate Gaussian (Normal) Distribution

Multivariate Gaussian Assumption

- 다변량 가우스 분포의 정의

- ✓ 연속형 데이터의 분포를 평균과 공분산으로 모델링하는 가정

$$y \sim \mathcal{N}(\mu, \Sigma)$$

$$\mathcal{N}(y | \mu, \Sigma) \triangleq \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (y - \mu)^T \Sigma^{-1} (y - \mu) \right]$$


- 왜 다변량 가우스 분포를 가정하는가?

- ✓ 공분산 행렬 Σ 를 통해 변수 간 선형 상관관계를 자연스럽게 모델링 가능함
- ✓ Log-likelihood의 데이터 의존 핵심 항이 평균으로부터의 거리 형태로 단순화됨

$$-\frac{1}{2} (y - \mu)^T \Sigma^{-1} (y - \mu)$$

- ✓ 확률 밀도가 평균과 공분산으로 기하학적으로 해석 가능

⇒ 이후 평균과 공분산을 추정하는 문제로 이어짐



02 | Maximum Likelihood Estimation (MLE)

Likelihood & Log-likelihood

- Likelihood와 Log-Likelihood

- ✓ Likelihood $p(\mathcal{D} \mid \theta) = \prod_{n=1}^N p(y_n \mid x_n, \theta)$

- ✓ Log-likelihood $\log p(\mathcal{D} \mid \theta) = \log \prod_{n=1}^N p(y_n \mid x_n, \theta)$
 $= \sum_{n=1}^N \log p(y_n \mid x_n, \theta)$

- ✓ 곱 형태를 합 형태로 변환하여 계산과 최적화가 쉬워짐

- 가우스 분포를 가정하면?

$$y_n \sim \mathcal{N}(\mu, \Sigma), n = 1, \dots, N \text{ (i.i.d)}$$

- ✓ $\log p(\mathcal{D} \mid \mu, \Sigma) = \sum_{n=1}^N \log \mathcal{N}(y_n \mid \mu, \Sigma)$
 $= \sum_{n=1}^N \left[-\frac{D}{2} \log(2\pi) - \frac{1}{2} \log |\Sigma| - \frac{1}{2} (y_n - \mu)^T \Sigma^{-1} (y_n - \mu) \right]$
 $= -\frac{N}{2} \log |\Sigma| - \frac{1}{2} \sum_{n=1}^N (y_n - \mu)^T \Sigma^{-1} (y_n - \mu) + \text{const.}$

- ✓ 파라미터에 의존하지 않는 항들은 무시 가능하며 최적화에 영향을 주는 핵심 항만 남음

⇒ 핵심 항만 남아 최적화 문제로 정리됨

02 | Maximum Likelihood Estimation (MLE)

MLE for Multivariate Gaussian

- MLE의 정의

$$y_1, \dots, y_n \sim \mathcal{N}(\mu, \Sigma) \text{ (i.i.d)} \quad \hat{\theta}_{mle} \triangleq \underset{\theta}{\operatorname{argmax}} p(\mathcal{D} | \theta)$$

- 평균의 MLE

✓ Log-likelihood를 μ 에 대해 미분하면 $\sum_n (y_n - \mu) = 0$ 이 되는 지점이 최적해

$$\frac{\partial}{\partial \mu} \sum_{n=1}^N (y_n - \mu)^T \Sigma^{-1} (y_n - \mu) = -2 \Sigma^{-1} \sum_{n=1}^N (y_n - \mu) \Rightarrow \sum_{n=1}^N (y_n - \mu) = 0$$

$$\hat{\mu} = \frac{1}{N} \sum_{n=1}^N y_n = \bar{y}$$

✓ 모든 데이터가 평균 주변에 가장 잘 모이도록 하는 μ

- 공분산 행렬의 MLE

✓ 평균으로부터의 편차를 구조를 가장 잘 설명하는 공분산

$$\ell(\Sigma) = -\frac{N}{2} \log |\Sigma| - \frac{1}{2} \operatorname{tr}(\Sigma^{-1} S), \quad S := \sum_{n=1}^N (y_n - \mu)(y_n - \mu)^T$$

$$\frac{\partial}{\partial \Sigma^{-1}} = \frac{1}{2} (N \Sigma - S) = 0$$

$$\hat{\Sigma} = \frac{1}{N} \sum_{n=1}^N (y_n - \bar{y})(y_n - \bar{y})^T$$

03 | Empirical Risk Minimization (ERM)

Expected Risk vs Empirical Risk

- Expected Risk (True Risk)

- ✓ 이론적으로 최소화하고 싶은 ‘진짜 목표’

$$\mathcal{R}(\theta) = \mathbb{E}_{(x,y) \sim p^*(x,y)}[\ell(y_n, \theta; x_n)]$$

- Empirical Risk


- ✓ 관측 데이터로 계산 가능한 근사 위험

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_{n=1}^N \ell(y_n, \theta; x_n)$$

- Empirical Risk Minimization (ERM)

$$\hat{\theta} = \underset{\theta}{\operatorname{argmin}} \frac{1}{N} \sum_{n=1}^N \ell(y_n, \theta; x_n)$$

- ✓ 표본 수가 충분할 때 Empirical Risk가 Expected Risk를 잘 근사
- ✓ 모르는 분포에서의 평균 손실을 관측한 데이터의 평균 손실로 대체함



03 | Empirical Risk Minimization (ERM)

MLE is a Special Case of ERM

- Negative Log-likelihood as Loss

$$\ell(y, x; \theta) = -\log p(y | x, \theta)$$

- ✓ 확률을 최대화(MLE)하는 문제는 NLL을 최소화하는 문제와 동등함

- Gaussian MLE의 경우


$$-\log p(y | \mu, \Sigma) \propto (y - \mu)^T \Sigma^{-1} (y - \mu)$$

- ✓ 평균으로부터의 마할라노비스 거리 형태의 loss

- 핵심 관계

$$\text{MLE} \subset \text{ERM}$$


- ✓ MLE는 특정 loss를 선택한 ERM의 특수한 경우
- ✓ 확률적 모델 학습 $\Leftrightarrow$ loss 최소화 문제



03 | Empirical Risk Minimization (ERM)

Choice of Loss Function

- Loss 선택 = 가정
 - ✓ 사용하는 loss 함수는 데이터 생성 과정에 대한 가정을 반영함
 - ✓ 서로 다른 loss는 서로 다른 확률 모델을 암시함 (노이즈 가정)
- Squared Loss ↔ Gaussian Noise
$$\ell(y, \hat{y}) = (y - \hat{y})^2$$
 - ✓ 출력 오차가 Gaussian noise를 따른다고 가정
 - ✓ Gaussian NLL과 동등 $\Rightarrow$ 평균 중심, 대칭적 오차를 가정함
- 분포 가정과 손실 함수의 대응 관계



확률 분포 가정	대응되는 손실 함수
가우시안 분포 (Gaussian)	제곱 오차 손실 (Squared loss)
라플라스 분포 (Laplace)	절대 오차 손실 (Absolute loss)
베르누이 / 범주형 분포 (Bernoulli / Categorical)	교차 엔트로피 손실 (Cross-entropy)

04 | Marginals and Conditionals of an MVN

Closed-form Marginals and Conditionals of a Gaussian

- Multivariate Gaussian 가정

$$y = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \sim \mathcal{N}(\mu, \Sigma)$$

$$\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$$

- ✓ 정밀도 행렬 (precision matrix)

$$\Lambda = \Sigma^{-1}$$

- Marginal Distributions

$$p(y_1) = \mathcal{N}(y_1 \mid \mu_1, \Sigma_{11})$$

$$p(y_2) = \mathcal{N}(y_2 \mid \mu_2, \Sigma_{22})$$

- ✓ 주변분포는 공분산 행렬의 해당 block 만으로 결정됨

- Posterior Conditional Distribution

$$p(y_1 \mid y_2) = \mathcal{N}(y_1 \mid \mu_{1|2}, \Sigma_{1|2})$$

$$\mu_{1|2} = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(y_2 - \mu_2)$$

$$\Sigma_{1|2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} = \Lambda_{11}^{-1}$$

- ✓ 조건부분포 역시 Gaussian
- ✓ 평균은 관측값의 선형 함수
- ✓ 공분산은 관측값과 무관

⇒ Gaussian은 부분 관측 하에서도 닫힌 형태의 추론이 가능함

04 | Marginals and Conditionals of an MVN

Conditioning a 2D Gaussian: Intuition


- 2D Gaussian 설정

- ✓ 두 변수 y_1, y_2 가 jointly Gaussian
- ✓ 상관계수 ρ 가 0이 아닌 경우

$$(y_1, y_2) \sim \mathcal{N}(\mu, \Sigma), \quad \rho \neq 0$$

- Conditional Distribution $p(y_1 | y_2)$

- ✓ 한 변수를 관측하면 다른 변수에 대한 조건부분포 형성
- ✓ 조건부분포 역시 Gaussian



〈Conditional Slice of a 2D Gaussian〉

- Mean Shift (평균 이동)

$$\mathbb{E}[y_1 | y_2] = \mu_1 + \rho(y_2 - \mu_2)$$

- ✓ 관측값이 평균에서 벗어난 정도에 비례하여 이동
- ✓ ρ 가 클수록 영향이 큼

- Variance Reduction (불확실성 감소)

$$\mathbb{V}[y_1 | y_2] = \sigma^2(1 - \rho^2)$$


- ✓ 관측을 통해 분산 감소
- ✓ $\rho = 0$ 인 경우, 관측은 추가 정보 제공하지 않음

05 | Gaussian Mixture Models

Limitation of a Single Gaussian

- Single Gaussian Assumption
 - ✓ 데이터가 하나의 평균과 하나의 공분산 구조로 생성된다고 가정
 - ✓ 모든 데이터가 하나의 중심(cluster)에 속한다고 가정
- 실제 데이터의 특징
 - ✓ 여러 개의 clusters가 동시에 존재
 - ✓ 분포가 비대칭이거나 multimodal한 경우가 많음
 - ✓ 서로 다른 생성 메커니즘이 섞여 있음
- 일반적인 단일 Gaussian의 한계
 - ✓ 하나의 평균 $\Rightarrow$ 서로 다른 cluster의 중간에 위치
 - ✓ 하나의 공분산 $\Rightarrow$ 각 cluster의 방향성과 scale을 동시에 설명 불가
 - ✓ 결과적으로 데이터 구조를 과도하게 단순화

$\Rightarrow$ 여러 개의 Gaussian을 결합한 더 유연한 확률 모델이 필요함



〈여러 개의 cluster가 공존하는 multimodal 데이터 예시〉

05 | Gaussian Mixture Models

Gaussian Mixture Model

- Gaussian Mixture Model의 기본 아이디어

- ✓ 데이터는 여러 개의 Gaussian 분포가 혼합되어 생성되었다고 가정
- ✓ 각 데이터 포인트는 하나의 Gaussian component로부터 생성되지만, 어떤 component에서 생성되었는지는 관측되지 않음

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$$

- ✓ K : Gaussian component 개수
- ✓ π_k : 혼합 가중치(mixing coefficient), $\sum_k \pi_k = 1$

- Log-likelihood

$$\log p(D | \theta) = \sum_{n=1}^N \log(\sum_{k=1}^K \pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k))$$

- ✓ 각 데이터는 여러 Gaussian component의 가중합으로 표현됨

- Single Gaussian과의 차이

- ✓ 단일 Gaussian $\Rightarrow$ 하나의 평균, 공분산
- ✓ GMM
 - $\Rightarrow$ cluster마다 서로 다른 평균과 공분산 사용
 - $\Rightarrow$ multimodal한 분포 표현 가능
 - $\Rightarrow$ 복잡한 데이터 구조 모델링 가능

05 | Gaussian Mixture Models

Why MLE Becomes Hard

- 왜 MLE가 어려운가

- ✓ 각 데이터가 어느 Gaussian에서 생성됐는지 관측되지 않음
- ✓ 그 결과, log 안에 component에 대한 합이 남아 있음

⇒ 단일 Gaussian처럼 closed-form MLE 불가

- Latent Variable 관점

- ✓ 각 데이터 x_n 에 대한 잠재 변수(latent variable) z_n 도입
- ✓ $z_n = k: \Rightarrow x_n$ 이 k 번째 Gaussian에서 생성됨을 의미


$$Z_n \sim \text{Categorical}(\pi_1, \dots, \pi_k)$$

$$x_n \mid \mu_k = k \sim \mathcal{N}(\mu_k, \Sigma_k)$$

- ✓ component (cluster) assignment가 숨겨져 있음

- 정리

- ✓ GMM은 단일 Gaussian보다 훨씬 유연한 모델
- ✓ 하지만 그 대가로 MLE 문제가 구조적으로 복잡해짐 $\Rightarrow$ 실제로는 반복적 추정 방법(EM)이 사용됨



〈Observed Data vs Latent Component Assignment〉

Q&A

감사합니다.