



Probabilistic Machine Learning

김무진 / '26.02.13



Computational Data Science LAB



CONTENTS

1. Statistics (4.5 ~)
 2. Decision Theory
- 
- 

01 | Statistics

MLE & MAP

- MLE의 한계

- ✓ $\hat{\theta}_{mle} \triangleq \operatorname{argmax}_{\theta} p(D|\theta)$

- ✓ 과적합 : 관측된 N개 데이터의 집합에 모든 확률질량을 부여하여 미래의 새로운 데이터에 어떠한 확률도 남겨놓지 않게 되는 상황

- ✓ 해결책 : 정칙화 항을 추가

- 최대 사후 추정 (Maximum a posterior estimation)

- ✓ $L(\theta; \lambda) = -\frac{1}{N} \sum_{n=1}^N \log p(y_n|x_n, \theta) - \lambda \log p(\theta)$

- ✓ $= -[\sum_{n=1}^N \log p(y_n|x_n, \theta) + \log p(\theta)] = -[\log p(D|\theta) + \log p(\theta)]$

- ✓ $\hat{\theta} = \operatorname{argmax}_{\theta} \log p(\theta|D) = \operatorname{argmax}_{\theta} [\log p(D|\theta) + \log p(\theta) - \text{const}]$

- ✓ MLE는 데이터를 가장 잘 맞추는 θ

- ✓ MAP는 데이터를 잘 맞추면서 원래도 그럴듯한 θ

01 | Statistics

베르누이 분포의 MAP 추정 – 베타분포

- 베타분포

- ✓ 성공($\alpha-1$)과 실패($\beta-1$)의 횟수를 통해 진짜 **확률**이 어디쯤 있을 지 추정하는 분포

- ✓ 베이زي안 통계학에서 **사전확률**을 나타낼 때 주로 활용

- ✓
$$\text{Beta}(x|\alpha, \beta) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}$$


- ✓
$$B(\alpha, \beta) \triangleq \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$$

- ✓
$$\Gamma(\alpha) \triangleq \int_0^\infty x^{\alpha-1} e^{-x} dx$$

- 이항분포와의 차이

- ✓ 이항분포는 p가 정해져 있을 때 데이터가 나올 확률을 계산

- ✓ 베타분포는 반대로 데이터가 있을 때 p가 무엇일지 추측하는 분포



01 | Statistics

베르누이 분포의 MAP 추정

- 베르누이 분포의 MAP 추정

- ✓ 동전 던지기 예시에서 앞을 오직 세 번 관측한다면 MLE는 $\theta = 1$
- ✓ 베타 분포를 사전 분포 $p(\theta) = \text{Beta}(\theta|a, b)$ 로 사용
- ✓ $\ell(\theta) = \log p(D|\theta) + \log p(\theta)$
 $= [N_1 \log \theta + N_0 \log(1 - \theta)] + [(a - 1) \log(\theta) + (b - 1) \log(1 - \theta)]$
 $\therefore \theta_{\text{map}} = \frac{N_1 + a - 1}{N_1 + N_0 + a + b - 2}$

- 블랙스완 역설(≈과적합)

- ✓ 전혀 예상할 수 없던 일들이 실제로 나타나는 경우를 뜻함 (위키피디아)
- ✓ 17세기 이전 유럽인들은 모든 백조가 흰색이라는 고대 서구의 관념을 믿음
- ✓ 호주대륙이 발견되면서 검은 백조가 존재함이 밝혀짐
- ✓ “내가 지금까지 보지 못했다고 해서, 그것이 존재하지 않는 것이 아니다.”
- ✓ 즉, 데이터에 없다고 해서 확률을 0으로 두면 안됨

- Add-One Smoothing (Laplace Smoothing)

- ✓ $a = b = 2$ 일때의 추정 값 $\rightarrow \theta_{\text{map}} = \frac{N_1 + 1}{N_1 + N_0 + 2}$
- ✓ 모든 사건 발생 횟수에 모두 1을 더해줌
- ✓ 극단적인 확률(0이나 1)을 막기 위해 가짜 데이터를 하나씩 추가



02 | Decision Theory

베이지안 결정이론

- 결정이론

- 통계학적으로 **불확실**한 가운데 어떤 가치와 이에 관련된 결정문제들을 밝혀내어 합리적인 최적의 결정을 내리는 방법에 대한 이론 (위키피디아)
 - 상태 : $h \in H$
 - 행동 : $a \in A$
 - 손실함수 : $l(h, a)$

State	Nothing	Drugs
No COVID-19, young	0	8
COVID-19, young	60	8
No COVID-19, old	0	8
COVID-19, old	10	8

Table 5.1: Hypothetical loss matrix for a decision maker, where there are 4 states of nature, and 2 possible actions.

- 베이즈 정리

- 불확실성** 하에서 의사결정 문제를 수학적으로 다룰 때 이용 (위키피디아)

test	age	pr(covid)	cost-noop	cost-drugs	action
0	0	0.01	0.84	8.00	0
0	1	0.01	0.14	8.00	0
1	0	0.80	47.73	8.00	1
1	1	0.80	7.95	8.00	0

Table 5.2: Optimal policy for treating COVID-19 patients for each possible observation.

- 최적 정책 (베이즈 추정량)

- 가정 : 위험중립(risk neutral)
- 원칙 : 기대손실이 **더 작은** 행동을 고름
- 사후 기대 손실 : $R(a|x) \triangleq \sum_{h \in H} l(h, a)p(h|x)$
- 최적 정책 : $\pi^*(x) = \underset{a \in A}{\operatorname{argmin}} E_{p(h|x)}[\ell(h, a)]$

for each possible action a given all the relevant evidence, which may be a single datum $\mathbf{x}$ or an entire data set $\mathcal{D}$, depending on the problem:

분류문제 (클래스 결정)

02 | Decision Theory

‘올바른’ 모델 결정

- 베이지스 가설 검정

- ✓ M_0 : 모델0(귀무가설), M_1 : 모델1(대립가설)

- ✓ If, $P(M_1|D) > P(M_0|D) \rightarrow M_0$ 기각

- ✓
$$\frac{P(M_1|D)}{P(M_0|D)} = \frac{P(D|M_1)}{P(D|M_0)} \times \frac{P(M_1)}{P(M_0)}$$

- ✓ 베이지스 인자 : $B_{1,0} \triangleq \frac{P(D|M_1)}{P(D|M_0)}$

- 베이지스 모델 결정

- ✓ 여러 개의 모델 집합 $M = \{m_1, m_2, \dots\}$ 중 어떤 모델이 제일 그럴 듯 한가?

- ✓
$$\hat{m} = \underset{m \in \mathcal{M}}{\operatorname{argmax}} p(m|D)$$

$$p(m|D) = \frac{p(D|m)p(m)}{\sum_{m \in \mathcal{M}} p(D|m)p(m)}$$

$$\hat{m} = \underset{m \in \mathcal{M}}{\operatorname{argmax}} p(D|m)$$

$$p(D|m) = \int p(D|\theta, m)p(\theta|m)d\theta$$

- ✓ likelihood를 prior로 평균 낸 것

- ✓ 특정 θ 하나만 잘 맞는 게 아닌, 웬만한 θ 에서도 데이터를 잘 설명하는 모델

- ✓ 복잡한 모델은 모든 것을 설명할 수 있지만, 그만큼 어떤 것도 ‘강하게’ 지지하지는 못함

02 | Decision Theory

오컴의 면도날 (Occam's razor)

- 오컴의 면도날 (위키피디아)
 - ✓ “많은 것들을 필요 없이 가정해서는 안된다.” (Pluralitas non est ponenda sine neccesitate.)
 - ✓ “더 적은 수의 논리로 설명이 가능한 경우, 많은 수의 논리를 세우지 말라.” (Frustra fit per plura quod potest fieri per pauciora.)
 - ✓ 즉, 같은 현상을 설명하는 두 개의 주장이 있다면, 간단한 쪽을 선택
- 확률 질량의 보존 원칙
 - ✓ 복잡한 모델은 반드시 예측된 확률 밀도를 얇게 퍼뜨려야 하며, 단순한 모델만큼 주어진 데이터에 대한 확률을 얻지 못함
 - ✓ 단순한 모델 → 많이 예측하지는 않지만 예측하는 것에 확신이 있음
 - ✓ 복잡한 모델 → 무엇이든 설명할 수 있지만 무엇 하나도 강하게 믿지는 못함




Figure 5.7: A schematic illustration of the Bayesian Occam's razor. The broad (green) curve corresponds to a complex model, the narrow (blue) curve to a simple model, and the middle (red) curve is just right. Adapted from Figure 3.13 of [Bis06]. See also [MG05, Figure 2] for a similar plot produced on real data.

02 | Decision Theory

빈도주의 결정이론

- 빈도주의 결정이론

- ✓ 진짜 θ 에서 데이터를 여러 번 얻는 상황을 가정(*i.i.d*)하고, 평균적으로 가장 덜 손해보는 추정 규칙($\delta(x)$)을 찾는 이론
- ✓ θ (모수) $\rightarrow$ 고정된 값, 알 수는 없지만 확률변수가 아님
- ✓ D (데이터) $\rightarrow$ 확률변수, 동일한 θ 에서 반복 관측 가능

- 빈도주의 결정이론 vs 베이즈 결정이론

- ✓ 빈도주의 결정이론
 - θ 는 이미 정해져 있음
 - 데이터를 계속 다시 뽑을 수 있음
 - 확률을 장기적으로 일어나는 사건의 빈도라고 주장
- ✓ 베이즈 결정이론
 - θ 에 대해 믿음(prior)이 있음
 - 뽑아낸 데이터를 보고 믿음을 갱신
 - 확률을 사건 발생에 대한 믿음 또는 척도라고 주장

02 | Decision Theory

빈도주의 추정량

- 추정량의 위험

- ✓ 알려지지 않은 자연 상태 θ 가 주어졌을 때, 추정량의 빈도주의 위험은 가능도 함수 $P(x|\theta)$ 로 부터 추출한 데이터 x 에 추정량을 적용할 때의 기대 손실로 정의
- ✓ 수식 : $R(\theta) \triangleq \mathbb{E}_{p(x|\theta)} [l(\theta, \delta(x))]$

- 일치 추정량

- ✓ 데이터 개수가 **무한히 커질 때**, 내가 계산한 추정치 $\hat{\theta}$ 가 진짜 정답 θ 에 확률적으로 수렴하는 성질
- ✓ 수식 : $x = (x_1, x_2, \dots, x_N)$, $X_n \sim iid p(x|\theta)$, $\forall \epsilon > 0$, $\lim_{N \rightarrow \infty} P(|\hat{\theta}_N - \theta| > \epsilon) = 0$
- ✓ 예시 : MLE (Why?)

02 | Decision Theory

MLE와 일치 추정량의 관계

- MLE

- ✓ 수식 : $\arg \max_{\theta} \sum_{n=1}^N \log p(x_n | \theta)$

- ✓ 목적함수

$$\arg \min_{\theta} \text{KL}(p(\cdot | \theta^*) \| p(\cdot | \theta))$$

$$\text{KL}(p_{\theta^*} \| p_{\theta}) = \mathbb{E}_{x \sim p_{\theta^*}} [\log p_{\theta^*}(x)] - \mathbb{E}_{x \sim p_{\theta^*}} [\log p_{\theta}(x)]$$

$$\arg \min_{\theta} \text{KL}(p_{\theta^*} \| p_{\theta}) \iff \arg \max_{\theta} \mathbb{E}_{x \sim p_{\theta^*}} [\log p_{\theta}(x)]$$

$$\mathbb{E}_{x \sim p_{\theta^*}} [\log p_{\theta}(x)] \approx \frac{1}{N} \sum_{n=1}^N \log p_{\theta}(x_n)$$

$$\arg \max_{\theta} \frac{1}{N} \sum_{n=1}^N \log p_{\theta}(x_n)$$

- KL발산

- ✓ 수식 : $\text{KL}(p \| q) = \mathbb{E}_{x \sim p} \left[\log \frac{p(x)}{q(x)} \right]$

- $\text{KL} \geq 0$

- $\text{KL} = 0 \rightarrow p = q$ (완전히 같은 분포)

- 큰 수의 법칙(law of large numbers)

- ✓ 큰 모집단에서 무작위로 뽑은 표본 평균이 전체 모집단의 평균과 가까울 가능성이 높음 (위키피디아)

- ✓ N이 커지면 데이터 평균 로그 가능도는 진짜 기대 로그 가능도로 수렴

- ✓ 진짜 기대 로그 가능도는 $\theta = \theta^*$ 에서 최대(=KL 최소)

Q&A

감사합니다.