



Probabilistic Machine Learning

박준수 / 2026.02.27



Computational Data Science LAB

CONTENTS

1. Problem Setting
2. Entropy (Brief)
3. KL Divergence
4. Mutual Information
5. Linear Algebra Perspective

01 | Problem Setting

Information-theoretic view of learning problems

- 학습 문제를 확률 분포 추정 문제로 정의
 - ✓ 관측 데이터는 미지의 실제 분포 $p_{data}(x, y)$ 에서 생성됨
 - ✓ 모델은 파라미터화된 분포 $p_{\theta}(x, y)$ 로 이를 근사
- 학습의 목표를 분포 간 차이 최소화 문제로 설정
 - ✓ 데이터 분포와 모델 분포의 불일치(discrepancy)를 최소화
 - ✓ likelihood 기반 학습은 분포 근사의 한 형태
- 정보 이론적 측정량을 목적 함수(objective function)로 사용
 - ✓ Cross entropy
 - ✓ KL divergence
 - ✓ Mutual information

⇒ 이후 Information Theory에서 분포 간 관계를 정의함

⇒ Linear Algebra를 통해 계산 가능한 형태로 연결함

02 | Entropy (Brief)

Entropy & cross entropy as a functional of distributions

- 엔트로피를 확률 분포에 정의된 함수(functional)로 해석

- ✓ 확률변수 자체가 아니라 분포 $p(x)$ 의 성질을 측정
- ✓ 분포가 갖는 불확실성(uncertainty)의 정량적 측정량

$$H(p) = -\mathbb{E}_p[\log p(x)]$$

- 엔트로피의 역할

- ✓ 분포 간 비교를 위한 기준 (절대값보다 상대적 크기가 중요)
- ✓ 이후 cross entropy, KL divergence의 기반

- Cross entropy의 정의

- ✓ 실제 데이터 분포 $p(x)$ 와 모델 분포 $q(x)$ 사이의 불일치 측정량
- ✓ $H(p, q) = -\mathbb{E}_p[\log q(x)]$


- 최적화 관점에서의 역할

- ✓ Cross entropy 최소화는 log-likelihood 최대화와 동치
- ✓ 분포 근사 문제를 계산 가능한 최적화 문제로 변환

02 | Entropy (Brief)

Joint and conditional entropy (for decomposition)

- Joint entropy
 - ✓ 두 확률변수의 공동 불확실성을 측정
 - ✓ $H(X, Y)$: 결합 분포 $p(x, y)$ 의 엔트로피
- Conditional entropy
 - ✓ $H(X | Y)$: Y 가 주어졌을 때 X 의 불확실성
 - ✓ 관측 정보가 불확실성을 얼마나 줄였는지 측정
- 엔트로피 분해 관점
 - ✓ $H(X, Y) = H(X) + H(Y | X)$
 - ✓ 전체 불확실성을 개별 항으로 분해 가능
- 이후 전개에서의 역할
 - ✓ $I(X; Y) = H(X) - H(X | Y)$ 로 자연스럽게 연결



Intuitive schematic illustration

03 | KL Divergence


KL divergence as a log-likelihood ratio

- KL divergence의 정의
 - ✓ 두 확률 분포 $p(x), q(x)$ 사이의 상대적 엔트로피(relative entropy)
 - ✓ $KL(p||q) = \mathbb{E}_p[\log \frac{p(x)}{q(x)}]$
- Log-likelihood ratio 관점
 - ✓ 데이터가 p 에서 생성되었다는 가정 하에서의 평균 log-likelihood ratio
 - ✓ q 가 p 를 얼마나 잘 근사하는지를 측정
- Cross entropy와의 관계
 - ✓ $KL(p||q) = H(p, q) - H(p)$
 - ✓ $H(p)$ 는 고정 $\Rightarrow$ KL 최소화 $\equiv$ cross entropy 최소화
- 기본 성질
 - ✓ $KL(p||q) \neq KL(q||p)$
 - ✓ $KL(p||q) \geq 0$

03 | KL Divergence

Asymmetry: forward vs. reverse KL

- KL divergence의 비대칭성
 - ✓ 일반적으로 $KL(p||q) \neq KL(q||p)$
 - ✓ 두 방향의 KL은 서로 다른 의미를 가짐
- Forward KL: $KL(p||q)$
 - ✓ 데이터 분포 p 의 질량을 넓게 덮도록 유도
 - ✓ $p(x) > 0$ 인 영역에서 $q(x) = 0$ 이면 큰 페널티 발생
 - ✓ Mode-covering 성향
- Reverse KL: $KL(q||p)$
 - ✓ 확률 질량이 큰 영역에 집중하도록 유도
 - ✓ q 가 선택한 영역에서의 p 를 중시
 - ✓ Mode-seeking 성향



03 | KL Divergence

Non-negativity and geometric interpretation

- KL divergence의 비음수성(non-negativity)
 - ✓ 항상 $KL(p||q) \geq 0$
 - ✓ $KL(p||q) = 0 \Leftrightarrow p = q$ (거의 모든 곳에서)
- 의미적 해석
 - ✓ 두 분포가 동일할 때만 KL이 0
 - ✓ 분포 간 거리처럼 보이지만 metric은 아님
 - ✓ 값의 크기는 분포 불일치(discrepancy) 정도를 정량화
- 기하학적 관점 (geometric interpretation)
 - ✓ KL divergence는 분포족 내에서 어떤 분포를 다른 분포로 근사할 때의 오차를 측정하는 양으로 해석할 수 있음
 - ✓ 특정 분포족 내에서의 최적 근사 문제와 연결
 - ✓ 선택한 분포족에 따라 서로 다른 최적 근사가 도출됨

03 | KL Divergence

KL minimization and its equivalence to MLE

- 문제 설정 (분포 근사 문제)
 - ✓ 실제 데이터 분포 $p_{data}(x)$ 는 알 수 없음
 - ✓ 모델 분포 $p_{\theta}(x)$ 로 이를 근사하는 것이 목표
- KL 최소화 관점
 - ✓ $\min_{\theta} KL(p_{data} || p_{\theta})$
 - ✓ 데이터 분포를 기준으로 모델 분포를 가장 가깝게 근사
- Cross entropy 및 log-likelihood와의 관계
 - ✓ $KL(p_{data} || p_{\theta}) = H(p_{data}, p_{\theta}) - H(p_{data})$
 - ✓ $H(p_{data})$ 는 고정 $\Rightarrow$ KL 최소화 $\equiv$ cross entropy 최소화
 - ✓ Cross entropy 최소화 $\equiv$ negative log-likelihood 최소화
 - ✓ 실제로는 p_{data} 를 모르므로, empirical distribution(샘플 평균)으로 기댓값을 근사하여 계산
- Maximum Likelihood Estimation (MLE)
 - ✓ 데이터에 대한 likelihood를 최대화하는 파라미터 θ 추정
 - ✓ KL 최소화의 실제 계산 가능한 구현 형태

03 | KL Divergence

Example: KL divergence between Gaussians

- 설정

- ✓ $p(x) = \mathcal{N}(\mu_p, \Sigma_p), q(x) = \mathcal{N}(\mu_q, \Sigma_q)$
- ✓ 두 다변량 가우시안 분포 간 KL divergence 계산

- 결과 형태


- ✓ $KL(\mathcal{N}(\mu_p, \Sigma_p) || \mathcal{N}(\mu_q, \Sigma_q)) = \frac{1}{2} [tr(\Sigma_q^{-1} \Sigma_p) + (\mu_q - \mu_p)^T \Sigma_q^{-1} (\mu_q - \mu_p) - d + \log \frac{|\Sigma_q|}{|\Sigma_p|}]$

- 해석

- ✓ 평균 차이: 위치(location) 차이에 대한 페널티
- ✓ 공분산 항: 분산/상관구조 차이에 대한 페널티
- ✓ determinant 항: 분포의 전체 스케일 차이 반영

- 의미


- ✓ KL 계산에 inverse, trace, determinant가 필수적으로 등장
- ✓ 선형대수 개념 없이는 각 항의 기하학적 의미 해석이 어려움



04 | Mutual Information

Interpretation as a dependence measure

- Mutual information의 정의
 - ✓ 두 확률변수 X, Y 사이의 의존성(dependence)을 측정
 - ✓ $I(X; Y)$: 한 변수를 알 때 다른 변수에 대해 얻는 정보량
 - ✓ Y 를 알면 X 의 불확실성이 얼마나 감소하는가
- KL divergence로서의 해석
 - ✓ $I(X; Y) = KL(p(x, y) || p(x)p(y))$
 - ✓ 실제 결합 분포와 독립 가정 분포 간의 차이
- Mutual information의 핵심 성질
 - ✓ $I(X; Y) \geq 0$, 대칭적: $I(X; Y) = I(Y; X)$
 - ✓ 두 변수가 독립적일 때만 0이 됨
 - ✓ 선형/비선형 관계를 모두 포착
 - ✓ 변수 변환에 불변(invariant under reparameterization)





Intuitive schematic illustration

- 상관계수와와의 비교
 - ✓ 상관계수: 선형 의존성만 측정
 - ✓ MI: 일반적인 확률적 의존성을 측정

04 | Mutual Information

Mutual information vs. correlation


- 상관계수 (correlation)
 - ✓ 선형 의존성만 측정
 - ✓ 평균과 분산에 기반한 2차 통계량
 - ✓ 비선형 관계는 포착 불가
- Mutual information
 - ✓ 일반적인 확률적 의존성을 측정
 - ✓ 선형 · 비선형 관계 모두 포착
 - ✓ 독립일 때만 0
- 직관적 예시
 - ✓ 상관계수는 0이지만 MI는 양수인 경우 존재
 - ✓ 비선형 함수 관계에서도 MI는 의존성 감지함



04 | Mutual Information

Conditional mutual information


- Conditional mutual information의 정의
 - ✓ 조건 변수 Z 가 주어졌을 때 X 와 Y 사이의 의존성
 - ✓ $I(X; Y | Z)$: Z 를 알고 난 뒤에도 남는 $X - Y$ 정보량
- 엔트로피 관점의 표현
 - ✓ $I(X; Y | Z) = H(X | Z) - H(X | Y, Z) = H(Y | Z) - H(Y | X, Z)$
 - ✓ 조건부 불확실성 감소량으로 해석 가능
- KL divergence로서의 해석
 - ✓ $I(X; Y | Z) = \mathbb{E}_Z[KL(p(X, Y | Z) || p(X | Z)p(Y | Z))]$
 - ✓ 조건부 결합 분포와 조건부 독립 가정 분포의 차이
- Mutual information과의 관계
 - ✓ $I(X; Y | Z) = I(X; Y, Z) - I(X; Z)$
 - ✓ Z 가 설명하는 정보를 제거한 후 남는 순수 $X - Y$ 의존성



04 | Mutual Information

Data processing inequality

- Data processing inequality (DPI)의 정의
 - ✓ 확률변수의 통계적 처리(processing)는 mutual information을 증가시키지 못함
 - ✓ $X \Rightarrow Z \Rightarrow Y$ 가 Markov chain일 때, $I(X; Y) \leq I(X; Z)$
- 직관적 의미
 - ✓ 원본 데이터 X에서 처리(processing)를 거칠수록 정보 손실 발생
 - ✓ 중간 표현 Z는 X가 가진 정보의 일부만 보존
 - ✓ 가공은 정보 압축이지 정보 추가가 아님
- Mutual information 관점
 - ✓ Z는 X의 함수 $\Rightarrow$ Z가 X보다 더 많은 정보를 가질 수 없음
 - ✓ Y와의 의존성도 처리 이후 증가하지 않음
 - ✓ Mutual information은 정보 흐름의 상한(upper bound)을 제공



05 | Linear Algebra Perspective

Information geometry of learning

- 정보이론적 목적함수의 구조
 - ✓ 학습은 분포 근사(distribution approximation) 문제
 - ✓ KL divergence, mutual information은 log 확률비의 기댓값
 - ✓ Gaussian 가정 시 목적함수는 행렬 연산 구조로 귀결
- Gaussian 가정 하에서의 계산 구조
 - ✓ 평균 벡터 μ , 공분산 행렬 Σ 로 분포 표현
 - ✓ KL divergence는 다음과 같은 항으로 구성됨
 - quadratic form (평균 차이 항)
 - trace form (분산 구조 차이)
 - log determinant term (전체 스케일 차이)
 - ✓ inverse, trace, determinant가 핵심 연산으로 등장
- 학습 문제에서의 의미
 - ✓ 정보이론적 목적함수는 행렬 최적화 문제로 표현됨
 - ✓ 고차원 확률 문제를 선형대수 연산으로 단순화
 - ✓ 실제 최적화 알고리즘 구현의 수학적 기반

Q&A

감사합니다.