



Probabilistic Machine Learning

9. Linear Discriminant Analysis

박준수 / 2026.03.12



Computational Data Science LAB



CONTENTS

1. **Gaussian Discriminant Analysis**
 2. **Linear Discriminant Analysis**
 3. **Fisher's Linear Discriminant Analysis**
 4. **Naïve Bayes**
 5. **Generative vs Discriminative Classifiers**
- 
- 

01 | Gaussian Discriminant Analysis

Generative approach to classification

- 생성적 분류 모델 (Generative classifier)
 - ✓ 클래스 레이블과 데이터의 결합분포 $p(x, y)$ 를 모델링
 - ✓ 클래스 prior $p(y)$ 와 class-conditional density $p(x|y)$ 모델링
 - ✓ 데이터 생성 과정 가정

$$y \sim p(y), \quad x|y \sim p(x|y)$$

- 베이지 정리를 이용한 분류모델 구성 요소

$$p(y = c|x, \theta) = \frac{p(x|y = c, \theta)p(y = c|\theta)}{\sum_{c'} p(x|y = c', \theta)p(y = c'|\theta)}$$

- ✓ posterior probability가 가장 큰 클래스 c 선택
 - 모델 구성 요소
 - ✓ $p(y = c|\theta)$: 클래스 레이블의 prior
 - ✓ $p(x|y = c, \theta)$: 클래스 c 일 때 데이터 x 의 분포
- ⇒ class-conditional density (클래스 조건부 밀도)

01 | Gaussian Discriminant Analysis

Class-conditional Gaussian model

- Class-conditional Gaussian model

- ✓ 각 클래스 c 에 대해 입력 벡터 x 의 분포를 가우시안 분포로 가정

$$p(x|y = c) = \mathcal{N}(x|\mu_c, \Sigma_c)$$





- ✓ μ_c : 클래스 c 의 평균 벡터

- ✓ Σ_c : 클래스 c 의 공분산 행렬

- Quadratic decision boundary

- ✓ 클래스마다 다른 공분산 행렬 Σ_c

- ✓ 결정경계: quadratic function of x



- Linear decision boundary

- ✓ 모든 클래스가 동일한 공분산 $\Sigma_c = \Sigma$

- ✓ 결정경계: linear function of x

02 | Linear Discriminant Analysis

Linear classifier formulation

- Linear Discriminant Analysis (LDA)

- ✓ 모든 클래스가 동일한 공분산 행렬을 가진다고 가정 $\Sigma_c = \Sigma$
- ✓ 이 가정 하에서 class posterior의 로그는 x 의 선형 함수가 됨
- ✓ $\log p(y = c|x) \propto \log p(x|y = c) + \log \pi_c$
- ✓ $= -\frac{1}{2}(x - \mu_c)^T \Sigma^{-1}(x - \mu_c) + \log \pi_c$
- ✓ $= -\frac{1}{2}x^T \Sigma^{-1}x + x^T \Sigma^{-1}\mu_c - \frac{1}{2}\mu_c^T \Sigma^{-1}\mu_c + \log \pi_c$
- ✓ $= w_c^T x + b_c$

- 선형 판별 함수 (Linear discriminant function)

- ✓ 각 클래스 c 에 대해 다음과 같은 판별 함수 정의

$$g_c(x) = w_c^T x + b_c$$

- ✓ $w_c = \Sigma^{-1}\mu_c$
- ✓ $b_c = -\frac{1}{2}\mu_c^T \Sigma^{-1}\mu_c + \log \pi_c$

- 분류 규칙

- ✓ 입력 x 에 대해 모든 $g_c(x)$ 계산
- ✓ 가장 큰 값을 갖는 클래스로 분류

$$y^* = \operatorname{argmax}_c g_c(x)$$

02 | Linear Discriminant Analysis

Parameter estimation and covariance assumptions

- Maximum likelihood estimation (MLE)

- ✓ class prior: $\pi_c = \frac{N_c}{N}$

- ✓ class mean: $\mu_c = \frac{1}{N_c} \sum_{n:y_n=c} x_n$

- ✓ class covariance: $\Sigma_c = \frac{1}{N_c} \sum_{n:y_n=c} (x_n - \mu_c)(x_n - \mu_c)^T$

- Tied covariance assumption

- ✓ 모든 클래스가 동일한 공분산 공유: $\Sigma_c = \Sigma$

- ✓ 더 안정적인 추정 가능

- ✓ Linear decision boundary (LDA)

- Diagonal covariance assumption

- ✓ 공분산을 대각행렬로 제한

- ✓ 파라미터 수 감소 $O(CD^2) \Rightarrow O(CD)$

- ✓ Naïve Bayes independence assumption

- MAP estimation (regularization)

- ✓ 공분산 행렬에 정규화 적용

- ✓ MLE 공분산과 대각 공분산을 결합

$$\hat{\Sigma}_{map} = \lambda \text{diag}(\hat{\Sigma}_{mle}) + (1 - \lambda) \hat{\Sigma}_{mle}$$

- ✓ Regularized Discriminant Analysis (RDA)

02 | Linear Discriminant Analysis

Nearest centroid classifier

- Nearest centroid classifier

- ✓ 각 클래스의 평균 벡터(centroid)를 계산

$$\mu_c = \frac{1}{N_c} \sum_{n:y_n=c} x_n$$

- ✓ 입력 x 와 각 centroid 사이의 거리를 계산

- 분류 규칙

- ✓ 가장 가까운 centroid를 갖는 클래스로 분류

$$y^* = \underset{c}{\operatorname{argmin}} (x - \mu_c)^2$$

- ✓ Euclidean distance 기반 분류





- LDA와의 관계

- ✓ 공분산이 $\Sigma = I$ 인 경우 LDA는 nearest centroid classifier와 동일
- ✓ 결정경계는 centroid 사이의 중간선으로 형성됨

03 | Fisher's Linear Discriminant Analysis

Fisher's Linear Discriminant: motivation

- Fisher's Linear Discriminant: motivation
 - ✓ 고차원 데이터에서 클래스 분리가 잘 되는 방향 찾기
 - ✓ 데이터를 1차원 선형 투영(linear projection)으로 변환
- 투영 벡터 w
 - ✓ 입력 데이터를 $w^T x$ 로 투영
 - ✓ 투영된 공간에서 클래스 간 분리 최대화 목표
- Fisher의 아이디어
 - ✓ 클래스 간 분산 (between-class variance) 최대화
 - ✓ 클래스 내부 분산 (within-class variance) 최소화
 - ✓ 두 기준의 비율을 최대화하는 최적의 투영 방향 w 찾기



03 | Fisher's Linear Discriminant Analysis

Between-class vs within-class variance

- Class means
 - ✓ 각 클래스의 평균 벡터: μ_1, μ_2
 - ✓ 클래스 평균의 위치를 정의
- Within-class variance
 - ✓ 각 클래스 내부 데이터의 분산

$$S_W = \sum_{i:y_i=1} (x_i - \mu_1)(x_i - \mu_1)^T + \sum_{i:y_i=2} (x_i - \mu_2)(x_i - \mu_2)^T$$

- ✓ 클래스 내부 데이터의 scatter 측정
- Between-class variance
 - ✓ 두 클래스 평균 사이의 분산

$$S_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$$

- ✓ 클래스 간 separation 측정

03 | Fisher's Linear Discriminant Analysis

Optimal projection direction

- Fisher Linear Discriminant
 - ✓ 클래스 간 분산은 크게, 클래스 내 분산은 작게 하는 투영 방향 w 찾기
 - ✓ 다음 비율을 최대화

$$J(w) = \frac{w^T S_B w}{w^T S_W w}$$

- 최적화 문제
 - ✓ $J(w)$ 를 최대화하는 w 계산
 - ✓ Between-class variance / within-class variance 최대화
- 최적 투영 방향

$$w \propto S_W^{-1}(\mu_1 - \mu_2)$$

- ✓ 데이터를 $z = w^T x$ 로 투영하여 분류 수행

04 | Naïve Bayes

Conditional independence assumption

- Naïve Bayes classifier
 - ✓ 베이지 정리를 이용한 generative classification model
 - ✓ posterior 확률 $p(y|x)$ 가 최대가 되는 클래스로 분류

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

- ✓ 분류 시

$$p(y|x) \propto p(x|y)p(y)$$

- Naïve independence assumption
 - ✓ feature들이 y 에 대해 조건부 독립이라고 가정

$$p(x|y) = \prod_{j=1}^D p(x_j|y)$$

- ✓ 계산 복잡도 감소

04 | Naïve Bayes

Naïve Bayes parameter estimation

- Training objective

$$p(D|\theta) = \prod_{n=1}^N \left[\text{Cat}(y_n|\pi) \prod_{d=1}^D p(x_{nd}|y_n, \theta_d) \right]$$

⇒ 데이터 likelihood 최대화

- Label prior estimation

$$\hat{\pi}_c = \frac{N_c}{N}$$

✓ 클래스 c 데이터 비율

- Discrete feature

$$\hat{\theta}_{dck} = \frac{N_{dck}}{N_c}$$

✓ 클래스 c에서 feature d가 값이 k인 비율

- Real feature (Gaussian)

$$\checkmark \quad \hat{\mu}_{dc} = \frac{1}{N_c} \sum_{n:y_n=c} x_{nd}$$

$$\checkmark \quad \hat{\sigma}_{dc}^2 = \frac{1}{N_c} \sum_{n:y_n=c} (x_{nd} - \hat{\mu}_{dc})^2$$

05 | Generative vs Discriminative

Generative classifiers

- Generative classifiers

- ✓ $p(x|y), p(y)$ 를 모델링
- ✓ 베이지 정리를 이용해 posterior probability $p(y|x)$ 계산

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

- ✓ 데이터 생성 과정까지 모델링

- Advantages of generative classifiers

- ✓ 모델 적합이 비교적 용이함
 - 모델 구조가 단순하여 파라미터 추정이 비교적 안정적
- ✓ 결측된 입력 특성 처리 가능
 - 일부 feature가 관측되지 않아도 확률 모델을 이용해 추론 가능
- ✓ 클래스별로 독립적으로 학습 가능
 - 새로운 클래스가 추가될 때 해당 클래스만 추가 학습 가능
- ✓ 라벨이 없는 데이터 활용 가능
 - unlabeled data를 활용한 semi-supervised 학습에 적용 가능

05 | Generative vs Discriminative

Discriminative classifiers

- Discriminative classifiers
 - ✓ Posterior probability $p(y|x)$ 또는 decision boundary를 직접 학습
 - ✓ 데이터 생성 과정은 모델링 하지 않음
- Advantages of discriminative classifiers
 - ✓ 높은 예측 정확도
 - 충분한 데이터가 있을 때 generative model보다 더 높은 성능 가능
 - ✓ 특성 전처리(feature preprocessing)를 유연하게 활용 가능
 - feature selection, feature transformation 등 다양한 전처리 기법 적용 가능
 - ✓ 잘 보정된 확률 추정 (well-calibrated probabilities)
 - posterior probability $p(y|x)$ 를 직접 모델링하여 확률 추정이 안정적

Q&A

감사합니다.