



Probabilistic Machine Learning

Logistic Regression(10)

김무진 / '26.03.19



Computational Data Science LAB



CONTENTS

1. Logistic Regression
 2. Robust Logistic Regression
 3. Bayesian Logistic Regression
- 
- 

01 | Logistic Regression






Logistic Regression

- Logistic Regression

- ✓ 로지스틱 회귀는 널리 쓰이는 판별 분류 모델
- ✓ $p(y|x; \theta) = \text{Ber}(y|\sigma(w^T x + b))$
- ✓ $a = w^T x + b$ 는 로그 오즈 ($\log\left(\frac{p}{1-p}\right)$)
- ✓ 확률의 비율을 선형으로 모델링

- 선형 분류기

- ✓ sigmoid는 클래스 라벨이 $y = 1$ 인 확률을 제공하지만 실제로 최종 분류 경계는 $w^T x + b = 0$ 형태의 선형 경계
- ✓ $f(x) = \mathbb{I}(p(y = 1|x) > p(y = 0|x)) = \mathbb{I}(\log \frac{p(y = 1|x)}{p(y = 0|x)} > 0) = \mathbb{I}(a > 0)$
- ✓ 따라서 예측 함수는 $f(x; \theta) = b + w^T x = b + \sum_{d=1}^D w_d x_d$
- ✓ 법선 벡터 $w \in \mathbb{R}^d$ 그리고 원점으로부터의 단차 $b \in \mathbb{R}$ 를 갖는 초평면을 정의



01 | Logistic Regression

Binary logistic regression

- 비선형 분류기
 - ✓ 현실 데이터는 직선 하나로 깔끔하게 나뉘지 않는 경우가 많음
 - ✓ $\phi(x)$ 는 원래 feature를 가공해서 만든 새로운 feature vector
 - ✓ $\phi(x_1, x_2) = [1, x_1^2, x_2^2]$, $w = [-R^2, 1, 1]$, $w^T \phi(X) = x_1^2 + x_2^2 - R^2$
 - ✓ 입력을 feature transformation $\phi(x)$ 로 변환한 뒤, 그 변환된 공간에서 선형 초평면으로 분류
 - ✓ 비선형적으로 분포한 데이터라도 입력을 적절한 feature space로 변환하면, 그 공간에서 로지스틱 회귀는 선형 초평면을 이용해 분류할 수 있음




Figure 10.3: Illustration of how we can transform a quadratic decision boundary into a linear one by transforming the features from $\mathbf{x} = (x_1, x_2)$ to $\phi(\mathbf{x}) = (x_1^2, x_2^2)$. Used with kind permission of Jean-Philippe Vert.

01 | Logistic Regression

MLE

- Objective Function

- ✓ $\mu_n = \sigma(a_n)$ 은 클래스 1의 확률, $a_n = w^T x_n$ 은 logit, $\mathbb{H}_{ce}(p, q) = -[p \log q + (1 - p) \log(1 - p)]$

- ✓ $NLL(w) = -\frac{1}{N} \log p(D|w) = -\frac{1}{N} \log \prod_{n=1}^N \text{Ber}(y_n | \mu_n)$

- ✓ $= -\frac{1}{N} \sum_{n=1}^N \log[\mu_n^{y_n} \times (1 - \mu_n)^{1-y_n}]$

- ✓ $= -\frac{1}{N} \sum_{n=1}^N [y_n \log \mu_n + (1 - y_n) \log(1 - \mu_n)]$

- ✓ $= \frac{1}{N} \sum_{n=1}^N \mathbb{H}_{ce}(y_n, \mu_n)$

- Optimizing the objective

- ✓ $\nabla_w NLL(w) = g(w) = 0$

01 | Logistic Regression

MLE

- Optimizing the objective

- ✓ Chain Rule의 필요성 : $w \rightarrow a_n \rightarrow \mu_n \rightarrow \log(\mu_n)$

- ✓ $\frac{d\mu_n}{da_n} = \sigma(a_n)(1 - \sigma(a_n))$

- ✓ $\frac{d}{dw_d} \mu_n = \frac{d}{da_n} \sigma(a_n) \frac{da_n}{dw_d} = \mu_n(1 - \mu_n)x_n$

- ✓ $\nabla_w \log(\mu_n) = \frac{1}{\mu_n} \nabla_w \mu_n = (1 - \mu_n)x_n$, 마찬가지로 $\nabla_w \log(1 - \mu_n) = -\mu_n x_n$

- ✓ $\nabla_w NLL(w) = -\frac{1}{N} \sum_{n=1}^N [y_n(1 - \mu_n)x_n - (1 - y_n)\mu_n x_n]$

- ✓ $= -\frac{1}{N} \sum_{n=1}^N [y_n x_n - y_n x_n \mu_n - x_n \mu_n + y_n x_n \mu_n]$

- ✓ $= \frac{1}{N} \sum_{n=1}^N (\mu_n - y_n) x_n$

- 직관적 의미

- ✓ $e_n = (\mu_n - y_n)$ 을 오차신호로 해석하면, gradient는 각 입력 x_n 을 그 오차로 가중한 뒤 평균 낸 것

01 | Logistic Regression

MAP

- MAP
 - ✓ MLE는 데이터 점들 사이를 휘는 경계를 찾을 수 있어서 과적합을 유발
 - ✓ Decision Boundary를 미세하게 휘게 만들려면 w 를 크게 잡아야 함
 - ✓ Gaussian prior로 $p(w) = N(w|0, CI)$ 사용 후 MAP추정
 - ✓ $\mathcal{L}(w) = NLL(w) + \lambda \|w\|_2^2$
 - ✓ $\|w\|_2^2 = \sum_{d=1}^D w_d^2$




Figure 10.4: Polynomial feature expansion applied to a two-class, two-dimensional logistic regression problem. (a) Degree $K = 1$. (b) Degree $K = 2$. (c) Degree $K = 4$. (d) Train and test error vs degree. Generated by [logreg_poly_demo.ipynb](#).

$$\hat{w} = [0.51291712, 0.11866937]$$

$$\hat{w} = [2.27510513, 0.05970325, 11.84198867, 15.40355969, 2.51242311]$$

$$\hat{w} = [-3.07813766, \dots, -59.03196044, 51.77152431, 10.25054164]$$

02 | Robust Logistic Regression

Robust Logistic Regression

- Background

- ✓ 데이터에는 이상치가 있으며 이는 라벨 잡음이라 부르는 라벨링 오류 때문인 경우가 많음
- ✓ 이러한 오염에 영향을 받지 않도록 하기 위해 Robust Logistic Regression을 사용

- Robust Logistic Regression

- ✓ Idea : “일부 라벨은 랜덤일 수도 있다.”
- ✓ $p(y|x) = \pi \text{Ber}(y|0.5) + (1 - \pi) \text{Ber}(y|\sigma(w^T x))$
 - 확률 π 로는 랜덤 라벨 생성기를 사용
 - 확률 $1-\pi$ 로는 원래 로지스틱 생성기를 사용
 - 즉, 라벨 y 를 만드는 생성 메커니즘을 두 개를 사용

- Example

- ✓ 어떤 x 에 대해 로지스틱 모델이 $\sigma(w^T x) = 0.9$, $\pi = 0.2$
- ✓ $p(y = 1|x) = 0.2 \times 0.5 + 0.8 \times 0.9 = 0.1 + 0.72 = 0.82$
- ✓ 즉, 클래스 1 확률이 $0.9 \rightarrow 0.82$




Figure 10.10: (a) Logistic regression on some data with outliers (denoted by x). Training points have been (vertically) jittered to avoid overlapping too much. Vertical line is the decision boundary, and its posterior credible interval. (b) Same as (a) but using robust model, with a mixture likelihood. Adapted from Figure 4.13 of [Mar18]. Generated by `logreg_iris_bayes_robust_1d_pymc3.ipynb`.

03 | Bayesian Logistic Regression

Conjugacy

- Background

- ✓ 베이지에서 구하고자 하는 것은 $p(w|D) = \frac{p(D|w)p(w)}{p(D)}$
- ✓ 선형회귀에서는 $p(y|X, w) = N(y|Xw, \sigma I)$, prior 또한 Gaussian
- ✓ Gaussian $\times$ Gaussian = Gaussian $\rightarrow$ conjugacy (켈레성)
- ✓ 즉, $p(w|D) = N(w|\mu_N, \Sigma_N)$

- Logistic Regression's likelihood

- ✓ $p(y_n|x_n, w) = \text{Ber}(y_n|\sigma(w^T x_n)) \rightarrow$ posterior를 닫힌 형태로 계산 불가능
- ✓ Approximation이 필요 $\rightarrow$ Laplace approximation 이용
- ✓ 데이터 적음 $\rightarrow w$ 어디든 가능 $\rightarrow$ 사후확률 분포 넓음 $\rightarrow$ 불확실성 큼
- ✓ 데이터 많음 $\rightarrow$ 특정 w 만 설명 가능 $\rightarrow$ 사후확률 분포 좁아짐 $\rightarrow$ 불확실성 감소

03 | Bayesian Logistic Regression

Laplace approximation

- Background


- ✓ 데이터가 separable이면 $|w| \rightarrow \infty$, MLE 발산
- ✓ Posterior를 Gaussian으로 근사
- ✓ $p(w|D) \approx N(w|\hat{w}, H^{-1})$

- Magnitude


- ✓ w 를 바꿔도 posterior가 큰 변화가 없음
- ✓ 그 방향의 변화는 데이터가 별로 강하게 제약 못 함
- ✓ 그 방향에 불확실성이 큼

- Orientation


- ✓ 그 방향으로 조금만 움직여도 posterior가 확 떨어짐
- ✓ 데이터가 그 방향은 강하게 제약함
- ✓ 그 방향에 불확실성이 적음




(a)



(b)



(c)



(d)

03 | Bayesian Logistic Regression

Approximating the posterior predictive

- Conclusion

- ✓ 머신러닝에서 관심사는 파라미터 자체가 아닌 새 입력 x 가 들어왔을 때 출력 y 를 예측하는 것
- ✓ $p(y|\mathbf{x}, \mathcal{D}) = \int p(y|\mathbf{x}, \mathbf{w})p(\mathbf{w}|\mathcal{D})d\mathbf{w}$
- ✓ 가능한 모든 w 에 대해 예측을 해보고, 그 w 가 그럴듯한 정도로 평균을 내는 것
- ✓ Posterior predictive 적분도 exact하게는 어려움 → Monte Carlo와 같은 근사 필요

- Monte Carlo approximation

- ✓ 복잡한 적분이나 기댓값을 랜덤하게 여러 번 뽑아서 평균내는 방식
- ✓ 사후분포 $w_s \sim p(w|\mathcal{D})$ 로부터 S 개 표본을 추출한 후 다음을 계산
- ✓ $p(y = 1|\mathbf{x}, \mathcal{D}) \approx \frac{1}{S} \sum_{s=1}^S \sigma(\mathbf{w}_s^T \mathbf{x})$

Q&A

감사합니다.