



Probabilistic Machine Learning

11. Linear Regression

박준수 / 2026.03.26

12. Generalized Linear Models



Computational Data Science LAB



CONTENTS

1. Linear Regression
 2. Regularization
 3. Extensions of Linear Models
 4. Generalized Linear Models
- 
- 

01 | Linear Regression

Least Squares Linear Regression

- Least Squares Linear Regression 정의

- ✓ 입력 $x \in \mathbb{R}^D$ 와 출력 $y \in \mathbb{R}$ 사이의 선형 관계를 가정
- ✓ $y = w^T x + \epsilon$
- ✓ 오차: $\epsilon \sim \mathcal{N}(0, \sigma^2)$

- Negative Log-Likelihood (NLL)

- ✓ $p(y_n | x_n, w) = \mathcal{N}(y_n | w^T x_n, \sigma^2)$
- ✓
$$\begin{aligned} NLL(w, \sigma^2) &= -\sum_{n=1}^{N_D} \log \left[\left(\frac{1}{2\pi\sigma^2} \right)^{\frac{1}{2}} \exp \left(-\frac{1}{2\sigma^2} (y_n - w^T x_n)^2 \right) \right] \\ &= \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - \hat{y}_n)^2 + \frac{N_D}{2} \log(2\pi\sigma^2) \end{aligned}$$

- Maximum Likelihood Estimation (MLE)

- ✓ NLL 최소화 $\Leftrightarrow$ RSS 최소화
- ✓ $w_{MLE} = (X^T X)^{-1} X^T y$

01 | Linear Regression

Measuring Goodness of Fit

- Residual Sum of Squares (RSS)

- ✓ 예측값과 실제값의 차이(잔차)를 제곱하여 합한 값
- ✓ $RSS = \sum_{n=1}^N (y_n - \hat{y}_n)^2$
- ✓ 값이 작을수록 모델이 데이터를 잘 설명

- Root Mean Squared Error (RMSE)

- ✓ 평균 제곱 오차의 제곱근 $\Rightarrow$ 실제 단위로 해석 가능
- ✓ $RMSE = \sqrt{\frac{1}{N} RSS(w)}$

- Coefficient of Determination (R^2)

- ✓ 데이터 분산 대비 모델 설명력
- ✓ $R^2 = 1 - \frac{\sum_{n=1}^N (\hat{y}_n - y_n)^2}{\sum_{n=1}^N (\bar{y} - y_n)^2} = 1 - \frac{RSS}{TSS}$
- ✓ 1에 가까울수록 좋은 모델

02 | Regularization

Ridge Regression

- Ridge Regression 정의

- ✓ MLE는 overfitting 발생 가능
- ✓ Gaussian prior를 사용한 MAP estimation
- ✓ $p(w) = \mathcal{N}(w|0, \tau^2 I)$

- MAP Objective

- ✓
$$\hat{w}_{MAP} = \operatorname{argmin} \frac{1}{2\sigma^2} (y - Xw)^T (y - Xw) + \frac{1}{2\tau^2} w^T w$$
$$= \operatorname{argmin} RSS(w) + \lambda ||w||_2^2$$

- ℓ_2 Regularization

- ✓ $||w||_2^2 = w^T w$
- ✓ 큰 가중치 억제 $\Rightarrow$ overfitting 방지

02 | Regularization

Ridge Regression

- Penalized Objective

- ✓ $J(w) = (y - Xw)^T(y - Xw) + \lambda \|w\|_2^2$


- ✓ $\nabla_w J(w) = 2(X^T X w - X^T y + \lambda w)$

- MAP Solution

- ✓ $\hat{w}_{MAP} = (X^T X + \lambda I)^{-1} X^T y$
 $= (\sum_n x_n x_n^T + \lambda I_D)^{-1} (\sum_n y_n x_n)$

- Ridge Regression 효과

- ✓ 가중치를 0 방향으로 수축 (shrinkage)
 - ✓ Prior mean(0)에 가까워짐
 - ✓ 작은 eigenvalue 방향 $\Rightarrow$ 더 강하게 감소
 - ✓ 노이즈 방향 제거 $\Rightarrow$ 일반화 성능 향상



02 | Regularization

Lasso Regression

- Lasso Regression 정의

- ✓ Ridge는 가중치를 작게 만들
- ✓ Lasso는 가중치를 0으로 만들어 sparse 모델 생성
- ✓ Feature selection 효과
- ✓ $\Rightarrow w_d = 0$ 이면 해당 feature 제거

- L_0 Norm (Sparse 목표)

- ✓ $\|w\|_0 = \sum_{d=1}^D \mathbb{I}(|w_d| > 0)$
- ✓ 0이 아닌 가중치 개수
- ✓ 직접 최소화는 non-convex $\Rightarrow$ 어려움

- Laplace Prior (MAP)

- ✓ Gaussian 대신 Laplace prior 사용
- ✓ $p(w|\lambda) \propto \prod_{d=1}^D e^{-\lambda|w_d|}$

- ℓ_1 Regularization (Lasso)

- ✓ 최종 목적함수
- ✓ $PNLL(w) = \|Xw - y\|_2^2 + \lambda \|w\|_1$
- ✓ $\|w\|_1 = \sum_{d=1}^D |w_d|$
- ✓ 일부 가중치가 정확히 0이 됨

02 | Regularization

L1 vs L2 Comparison

- Constraint Formulation

- ✓ Lasso (ℓ_1): $\min NLL(w) \text{ s.t. } ||w||_1 \leq B$

- ✓ Ridge (ℓ_2): $\min NLL(w) \text{ s.t. } ||w||_2^2 \leq B$

- ✓ $B \downarrow \Leftrightarrow \lambda \uparrow$ (강한 규제)

- Geometric Interpretation

- ✓ ℓ_1 constraint $\Rightarrow$ diamond (모서리 존재)

- ✓ ℓ_2 constraint $\Rightarrow$ circle (smooth)


- Sparsity 발생 이유

- ✓ ℓ_1 : corner에서 해가 결정될 확률 높음

- ✓ $\Rightarrow$ 일부 $w_d = 0$

- ✓ ℓ_2 : 모든 방향이 동일

- ✓ $\Rightarrow$ 모든 weight 유지



02 | Regularization

Model Selection Comparison

- Comparison of Regression Methods

- ✓ 모든 feature가 orthonormal ($X^T X = I$) 가정
- ✓ 각 weight w_d 를 독립적으로 분석 가능

- MLE (Least Squares)

- ✓ $\hat{w}_d^{MLE} = x_{:d}^T y$
- ✓ 모든 feature 사용
- ✓ overfitting 가능

- Ridge Regression (ℓ_2)


- ✓ $\hat{w}_d^{ridge} = \frac{\hat{w}_d^{MLE}}{1+\lambda}$
- ✓ 모든 weight 축소 (shrinkage)
- ✓ 0이 되지는 않음

- Lasso Regression (ℓ_1)

- ✓ $\hat{w}_d^{lasso} = \text{sign}(\hat{w}_d^{MLE})(|\hat{w}_d^{MLE}| - \lambda)_+$
- ✓ soft thresholding
- ✓ 일부 weight = 0 $\Rightarrow$ sparse

- Subset Selection

- ✓ $\hat{w}_d^{ss} = \begin{cases} \hat{w}_d^{MLE} & \text{if top } K \\ 0 & \text{otherwise} \end{cases}$
- ✓ hard thresholding
- ✓ 가장 강한 feature selection



03 | Extensions of Linear Models

Elastic Net

- Objective Function

- ✓ $L(w) = ||y - Xw||_2^2 + \lambda_2 ||w||_2^2 + \lambda_1 ||w||_1$

- Grouping Effect

- ✓ 상관된 변수들은 비슷한 weight를 가짐

- ✓ $X_{:j} = X_{:k} \Rightarrow \hat{w}_j = \hat{w}_k$

- ✓ Lasso와 달리 변수 선택이 더 안정적

- Lasso vs Elastic Net

- ✓ Lasso $\Rightarrow$ 일부 변수만 선택 (불안정 가능)

- ✓ Elastic Net $\Rightarrow$ correlated 변수들을 함께 선택

- ✓ $D > N$ 일때

- ✓ $\Rightarrow$ Lasso는 최대 N개 선택

- ✓ $\Rightarrow$ Elastic Net은 더 많은 변수 선택 가능

03 | Extensions of Linear Models


Regression Splines

- Regression Splines 개념
 - ✓ polynomial은 전체 구간을 하나로 근사 (global)
 - ✓ spline은 구간별로 나누어 근사 (local approximation)
 - ✓ $f(x; \theta) = \sum_{i=1}^m w_i B_i(x)$
 - ✓ $B_i(x)$: basis function
- B-spline
 - ✓ 구간을 나누는 knots 기준으로 piecewise polynomial 구성
 - ✓ 보통 cubic spline (D=3) 사용
 - ✓ 함수 + 1차, 2차 미분까지 연속 $\Rightarrow$ 부드러운 곡선
- 특징
 - ✓ 비선형 관계를 유연하게 표현 가능
 - ✓ 일부 basis만 활성화 $\Rightarrow$ 계산 효율적
 - ✓ knot 많아질수록 $\Rightarrow$ 표현력 $\uparrow$ / overfitting 위험 $\uparrow$

03 | Extensions of Linear Models

Regression Splines



- 모델 학습 (Model fitting)
 - ✓ design matrix B 생성 후 선형회귀 적용
 - ✓ $y \approx Bw$
 - ✓ 보통 ridge regularization 함께 사용
- Smoothing Splines
 - ✓ 데이터 개수만큼 knot 사용 (non-parametric)
 - ✓ ℓ_2 regularization으로 과적합 방지
- Generalized Additive Model (GAM)
 - ✓ $f(x) = \sum_d f_d(x_d)$
 - ✓ 각 f_d : spline 함수
 - ✓ 변수별로 따로 모델링 $\Rightarrow$ 해석 쉬움
 - ✓ backfitting으로 반복 학습
 - ✓ GLM처럼 link function 적용 가능



03 | Extensions of Linear Models

Robust Linear Regression

- Robust Linear Regression
 - ✓ Least Squares 는 outlier에 민감
 - ✓ $\Rightarrow$ 제곱 오차(ℓ_2)로 큰 오차가 더 크게 반영됨
- 해결 방법 (2가지 접근)
 - ✓ Loss / Distribution 변경
 - Laplace (ℓ_1): $|y - w^T x|$
 - Huber loss: 작은 오차 ℓ_2 / 큰 오차 ℓ_1
 - Student-t: heavy-tail 분포
 - ✓ Outlier 제거 방법
 - RANSAC: 이상치 제거 후 학습



04 | Generalized Linear Models

Linear Regression

- Generalized Linear Model (GLM)

- ✓ 지수족 분포 기반 모델

- ✓ $p(y_n|x_n, w, \sigma^2) = \exp(\frac{y_n\eta_n - A(\eta_n)}{\sigma^2} + \log h(y_n, \sigma^2))$

- ✓ $\eta = w^T x$

- Linear Regression

- ✓ $p(y_n|x_n, w, \sigma^2) = \mathcal{N}(y_n|w^T x_n, \sigma^2)$

- GLM Form으로 변환

- ✓ $p(y_n|x_n, w, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp(-\frac{1}{2\sigma^2} (y_n - w^T x_n)^2)$

- ✓ $\log p(y_n|x_n, w, \sigma^2) = -\frac{1}{2\sigma^2} (y_n - \eta_n)^2 - \frac{1}{2} \log(2\pi\sigma^2)$

- ✓ $\Rightarrow \log p(y_n|x_n, w, \sigma^2) = \frac{y_n\eta_n - \frac{1}{2}\eta_n^2}{\sigma^2} - \frac{1}{2} (\frac{\eta_n^2}{\sigma^2} + \log(2\pi\sigma^2))$

04 | Generalized Linear Models

Binomial & Poisson Regression

- Binomial Regression

- ✓ $p(y_n|x_n, N_n, w) = \text{Bin}(y_n|\sigma(w^T x_n), N_n)$

- GLM Form 변환

- ✓ $p(y_n|x_n, N_n, w) = \binom{N_n}{y_n} \mu_n^{y_n} (1 - \mu_n)^{N_n - y_n}$

- ✓ $\log p(y_n|x_n, N_n, w) = y_n \log \mu_n + (N_n - y_n) \log(1 - \mu_n) + \log \binom{N_n}{y_n}$
 $= y_n \log\left(\frac{\mu_n}{1 - \mu_n}\right) + N_n \log(1 - \mu_n) + \log \binom{N_n}{y_n}$

- ✓ $\Rightarrow \log p(y_n|x_n, N_n, w) = y_n \eta_n - A(\eta_n) + h(y_n)$

- Poisson Regression

- ✓ $p(y_n|x_n, w) = \text{Poi}(y_n|\exp(w^T x_n))$

- GLM Form 변환

- ✓ $\log p(y_n|x_n, w) = y_n \log \mu_n - \mu_n - \log(y_n!)$

- ✓ $\Rightarrow \log p(y_n|x_n, w) = y_n \eta_n - A(\eta_n) + h(y_n)$

- 모델별 차이

- ✓ Linear Regression

- $\Rightarrow \mu_n = \eta_n$ (identity link)

- ✓ Binomial Regression

- $\Rightarrow \mu_n = \text{sigmoid}(\eta_n)$ (logit link)

- ✓ Poisson Regression

- $\Rightarrow \mu_n = e^{\eta_n}$ (log link)



Q&A

감사합니다.