



Probabilistic Machine Learning

19. Learning with Fewer Labeled Examples

김무진 / '26.05.07



Computational Data Science LAB



CONTENTS

1. Data Augmentation
 2. Transfer Learning
 3. Self-Supervised Learning
 4. Semi-Supervised Learning
- 
- 

01 | Data Augmentation

Why Learning with Fewer Labels?

- Background

- ✓ 많은 머신러닝 방법, 특히 신경망은 라벨링된 훈련 데이터보다 더 많은 모수를 가짐
- ✓ 총이 50개인 Resnet CNN은 2,300만 개의 모수를 가짐
- ✓ 이러한 모수가 많은 큰 모델은 라벨 데이터가 적으면 과적합 되기 쉬움
- ✓ 따라서 적은 라벨로도 잘 학습하는 전략이 필요함

- Data Augmentation

- ✓ 무작위 잘라내기, 줌, 미러 이미지 뒤집기 등
- ✓ 사전지식을 알고리즘적으로 주입하는 방식
- ✓ $R(f) = \int l(f(x), y) p^*(x, y) dx dy$
- ✓ $P_D(x, y) = \frac{1}{N} \sum_{n=1}^N \delta(x - x_n) \delta(y - y_n)$
- ✓ $P_D(x, y) = \frac{1}{N} \sum_{n=1}^N p(x|x_n, A) \delta(y - y_n)$



Figure 19.1: Illustration of random crops and zooms of the image on the left. Generated by `image_augmentation_jax.ipynb`.

02 | Transfer Learning


Transfer Learning

- Transfer Learning
 - ✓ 라벨이 적은 Target Task를 처음부터 학습하지 않음
 - ✓ 큰 Source data set에서 먼저 Pre-training 후 학습된 feature extractors를 target model에 복사
- Fine Tuning
 - ✓ Source model은 큰 데이터셋에서 이미 학습됨
 - ✓ 입력 공간은 비슷하다고 가정 : $X_q \approx X_p$
 - ✓ 출력 라벨은 보통 다름 : $Y_q \neq Y_p$
 - ✓ 기존 output layer를 제거
 - ✓ target label에 맞는 새 output head 추가
 - ✓ feature extractor는 freeze하거나 작은 learning rate로 조정

02 | Transfer Learning

Fine Tuning

- Source Model $\rightarrow$ Target Model 변환
 - ✓ $p(y|x, \theta_p) = \text{softmax}(y|W_2h(x; \theta_1) + b_2)$
 - ✓ $q(y|x, \theta_q) = \text{softmax}(y|W_3h(x; \theta_1) + b_3)$
- 무엇을 가져오고, 무엇이 바뀌는가?
 - ✓ $h(x; \theta_1)$: feature extractor $\rightarrow$ 재사용
 - ✓ W_2, b_2 : source label용 output head $\rightarrow$ 제거
 - ✓ W_3, b_3 : target label용 새 output head $\rightarrow$ 새로 학습
 - ✓ θ_1 은 freeze하거나 작은 learning rate로 미세 조정



03 | Self-Supervised Learning

Pre-training: Supervised vs Self-Supervised

- Supervised pre-training
 - ✓ 사전학습은 지도적이거나 비지도적일 수 있으며, 요구사항으로 모델에게 문제 도메인에 대한 기본적인 구조를 가르쳐야 함
 - ✓ 사전학습은 보통 더 크고 다양한 데이터에서 먼저 학습하고, 이후 target task에 맞게 fine tuning
 - ✓ 예시로 ImageNet pre-training은 두 가지 상황이 존재
 - ImageNet에서 배운 feature가 target task에도 실제로 유용한 경우
 - 좋은 초기값 효과로, 랜덤 초기값보다 이미 학습된 가중치에서 시작하므로 학습이 빨라짐
- Unsupervised pre-training (Self-Supervised Learning)
 - ✓ 사람이 직접 라벨을 제공하지 않음
 - ✓ 데이터 자체에서 학습 신호 생성 (예: 가려진 단어 맞추기, 이미지 일부 복원)
 - ✓ 대표적인 세 가지 방식
 - Imputation : 빈칸 채우기
 - Proxy/Pretext : 보조 문제 풀기
 - Contrastive : 비슷한 것은 가깝게, 다른 것은 멀게

03 | Self-Supervised Learning

Imputation Task

- Imputation Task

- ✓ 첫 번째 접근은 imputation task를 푸는 것
- ✓ 입력 벡터 x 를 두 부분 $x = (x_h, x_v)$ 로 나눈 뒤, $\hat{x}_h = f(x_v, x_h = \mathbf{0})$. 형식의 모델을 사용해 숨겨진 부분 x_h 예측
- ✓ 이는 빈칸채우기 과제로 생각할 수 있으며, NLP에서는 이를 cloze 과제라고 함






Figure 19.4: (a) Context encoder for self-supervised learning. From [Pat+16]. Used with kind permission of Deepak Pathak. (b) Some other proxy tasks for self-supervised learning. From [LeC18]. Used with kind permission of Yann LeCun.

03 | Self-Supervised Learning

Proxy Task

- Proxy Task
 - ✓ 두 번째 접근법으로는 프록시 과제를 푸는 것. 이는 Pretext task라고도 함
 - ✓ Proxy task는 두 입력 사이의 관계를 맞추는 문제
 - ✓ 예시
 - X_1 = 원본 강아지 이미지
 - X_2 = 90도 회전된 강아지 이미지
 - ✓ 회전 각도를 맞추는 과정에서, 모델이 이미지 구조를 배우게 만드는 것
 - ✓ $p(y|x_1, x_2) = p(y|r[f(x_1), f(x_2)])$ 형식의 삼 네트워크 분류기를 훈련시킴
 - ✓ $f(x)$ 는 입력 x 를 feature vector로 바꿔주는 feature extractor 함수
 - ✓ r 은 두 feature 사이의 관계를 판단하는 relation function



(a)

03 | Self-Supervised Learning

Contrastive tasks






- Contrastive tasks
 - ✓ 의미가 비슷한 데이터는 embedding space에서 가깝게 만들고, 의미가 다른 데이터는 멀게 만드는 학습 방식
 - ✓ Positive pair : 의미적으로 비슷한 쌍 (원본 강아지, crop된 강아지, 색이 바뀐 강아지)
 - ✓ Negative pair : 의미적으로 다른 쌍 (강아지와 자동차, 강아지와 고양이)
 - ✓ Data Augmentation을 통해 만든 이미지를 두 이미지가 픽셀수준에서 다르더라도, embedding vector는 비슷하게 훈련시킴 → 모델은 자연스럽게 augmentation에 둔감 해지며, 좋은 feature extractor가 만들어짐

03 | Self-Supervised Learning

SimCLR (Simple Contrastive Learning of visual Representation)

- SimCLR

- ✓ 같은 이미지에서 만든 두 개의 증강 이미지 view는 가깝게, 다른 이미지에서 온 view들은 멀게 만드는 대조학습 방법
- ✓ z_i 와 z_j 는 가깝게, 다른 이미지들의 z 는 멀게 학습
- ✓ 즉, 라벨 없이도 “같은 원본에서 나온 것인지, 다른 원본에서 나온 것인지”를 학습 신호로 사용함
- ✓ $J = F(t_1(\mathbf{x}))^T F(t_2(\mathbf{x})) - \log \sum_{\mathbf{x}_i^- \in N(\mathbf{x})} \exp [F(\mathbf{x}_i^-)^T F(t_1(\mathbf{x}))]$
- ✓ SimCLR의 성공을 위한 핵심 요소는 Data Augmentation 방법



04 | Semi-supervised learning

Self-training

- Semi-supervised learning

- ✓ 라벨이 있는 데이터는 조금만 쓰고, 라벨 없는 데이터는 많이 써서, 전체 데이터의 구조를 배움
- ✓ $x, y \sim p(x, y)$, $x \sim p(x)$ ex) 고양이인지 강아지인지 모르는 동물 사진

- Self-training / Pseudo-labeling

- ✓ 라벨링되지 않은 데이터에서 모델 그 자체를 사용해 예측을 추론한 뒤, 이들 예측을 후속 훈련을 위한 라벨로 다루는 것
- ✓ Offline, Online 방식이 있음




Figure 19.8: Illustration of the benefits of semi-supervised learning for a binary classification problem. Labeled points from each class are shown as black and white circles respectively. (a) Decision boundary we might learn given only labeled data. (b) Decision boundary we might learn if we also had a lot of unlabeled data points, shown as smaller grey circles.

04 | Semi-supervised learning

Offline & Online

- Offline

- ✓ 한 번에 크게 처리하는 방식이며, 대량의 unlabeled data가 있을 때 많이 쓰임
- ✓ 라벨 데이터로 모델 학습 → 전체 언라벨 데이터에 pseudo-label 생성 → 라벨데이터 + pseudo-label 데이터로 모델 재학습 → 모델이 수렴하면 다시 전체 unlabeled data에 pseudo-label 재생성 → 반복
- ✓ 장점 : 대량 데이터에 적용하기 좋으며, pseudo-label을 만들어놓고 학습하면 파이프라인이 단순함
- ✓ 단점 : pseudo-label이 자주 업데이트 되지 않아서, 현재 모델 수준과 안 맞을 수 있음

- Online

- ✓ Unlabeled data 에서 랜덤 batch를 뽑음 → 현재 모델이 즉석에서 예측함 → 그 예측을 pseudo-label로 사용함 → 바로 학습함 → 다음 batch에서 또 반복
- ✓ 장점 : 현재 모델 기준으로 pseudo-label을 계속 만들기 때문에 stable label 문제가 덜 함
- ✓ 단점 : 매번 라벨 없는 데이터를 다시 예측해야 하므로 계산비용이 큼

04 | Semi-supervised learning

Combining self-supervised and semi-supervised learning

- Combining

- ✓ 라벨 없는 데이터로 SimCLR 기반 자기지도 사전학습을 수행해 일반적인 표현을 학습
- ✓ 이후 소량의 라벨 데이터로 큰 Teacher 모델을 fine-tuning하고, 원래 unlabeled data에 예측 값을 생성
- ✓ Student 모델은 Teacher의 soft prediction을 따라 학습하며, 이를 knowledge distillation이라고 함

- ✓
$$\mathcal{L}(T) = - \sum_{\mathbf{x}_i \in \mathcal{D}} \left[\sum_y p^T(y|\mathbf{x}_i; \tau) \log p^S(y|\mathbf{x}_i; \tau) \right]$$




Figure 19.13: Combining self-supervised learning on unlabeled data (left), supervised fine-tuning (middle), and self-training on pseudo-labeled data (right). From Figure 3 of [Che+20c]. Used with kind permission of Ting Chen.

Q&A

감사합니다.