



Probabilistic Machine Learning

20. Dimensionality Reduction

박준수 / 2026.05.14



Computational Data Science LAB

CONTENTS

1. Principal Components Analysis (PCA)
2. Factor Analysis & PPCA
3. Autoencoders
4. Manifold Learning

01 | Principal Components Analysis (PCA)

Definition, linear projection, and reconstruction error

- PCA의 정의


- ✓ 고차원 데이터를 선형 · 직교 부분공간으로 투영하는 차원 축소 기법
- ✓ 인코딩 $z = W^T x$, 디코딩 $\hat{x} = Wz$ (인코더 · 디코더 모두 선형)
- ✓ 원본 데이터에 ℓ_2 거리상 가깝도록 저차원 표현 학습

- 재구성 오차 (Reconstruction Error / Distortion)

- ✓ $\mathcal{L}(W) = \frac{1}{N} \sum_{n=1}^N \|x_n - \text{decode}(\text{encode}(x_n; W); W)\|_2^2$
- ✓ 경험적 공분산 행렬 $\hat{\Sigma} = \frac{1}{N} X_c^T X_c$ 의 고유분해로 해결

- 핵심 결과

- ✓ 최적 해: $\hat{W} = U_L$ (가장 큰 L개 고유값의 고유벡터)
- ✓ 확률적 잠재 선형 가우시안 모델(PPCA)의 우도 최대화와 동치



01 | Principal Components Analysis (PCA)

Minimum reconstruction error and maximum variance

- Base Case (w_1 유도)


- ✓ 제약 $\|w_1\| = 1$ 하에 재구성 오차 최소화
- ✓ 최적 임베딩 : $z_{n1} = w_1^T x_n$ (직교 투영)
- ✓ 손실 : $\mathcal{L}(w_1) = \frac{1}{N} \sum \|x_n - w_1 w_1^T x_n\|^2 = -\frac{1}{N} \sum (w_1^T x_n)^2 + \text{const} = -w_1^T \hat{\Sigma} w_1 + \text{const}$

- Lagrangian 풀이

- ✓ $\tilde{\mathcal{L}}(w_1) = w_1^T \hat{\Sigma} w_1 - \lambda_1 (w_1^T w_1 - 1)$
- ✓ 도함수 = 0 $\Rightarrow \hat{\Sigma} w_1 = \lambda_1 w_1$
- ✓ $\Rightarrow$ 공분산 행렬의 최대 고유값에 대응하는 고유벡터

- 분산 최대화 관점

- ✓ $\mathbb{V}[\tilde{z}_1] = -\mathcal{L}(w_1) + \text{const}$
- ✓ $\Rightarrow$ 재구성 오차 최소화 $\equiv$ 투영 데이터의 분산 최대화
- ✓ 귀납적으로 $w_2, w_3, \dots \rightarrow \hat{W} = U_L$



01 | Principal Components Analysis (PCA)


Computational issues in high-dimensional PCA

- 고차원 데이터 ($D \gg N$)
 - ✓ $D \times D$ 공분산 대신 $N \times N$ Gram 행렬 XX^T 사용
 - ✓ $(XX^T)U = U\Lambda \Rightarrow V = X^T U \Lambda^{-1/2}$ 정규화 고유벡터
 - ✓ $\Rightarrow$ 커널 트릭의 기반 (Kernel PCA)
- PCA via Truncated SVD
 - ✓ 데이터 행렬 분해 : $X = U_X S_X V_X^T$
 - ✓ 투영 행렬 : $W = V_X^{(L)} = V_\Sigma^{(L)}$
 - ✓ 주성분 점수 : $Z = XW = U_X^{(L)} S_X^{(L)}$
 - ✓ PCA에서의 재구성 : $\hat{X} = XWW^T = U_X S_X V_X^T V_X^{(L)} (V_X^{(L)})^T = U_X^{(L)} S_X^{(L)} (V_X^{(L)})^T$ (truncated SVD 와 동일)
- 계산 복잡도
 - ✓ Exact SVD : $\mathcal{O}(ND^2) + \mathcal{O}(D^3)$
 - ✓ Randomized SVD : $\mathcal{O}(NL^2) + \mathcal{O}(L^3) \Rightarrow$ 대규모 데이터에 유리


01 | Principal Components Analysis (PCA)

Choosing the number of latent dimensions

- 재구성 오차로 L 선택의 어려움
 - ✓ PCA 는 진정한 생성 모델이 아니므로 L이 커질수록 테스트 오차도 계속 감소
 - ✓ $\Rightarrow$ 지도학습의 U-shape 곡선이 나타나지 않음
- Scree Plot & Fraction of Variance Explained
 - ✓ 잔여 손실 : $\mathcal{L}_L = \sum_{j=L+1}^D \lambda_j$
 - ✓ 분산 설명 비율 : $F_L = \sum_{j=1}^L \lambda_j / \sum_{j=1}^{L^{max}} \lambda_j$
 - ✓ 고유값을 내림차순 플로팅 — 꺾이는 "elbow" 지점을 L 로 선택
- Profile Likelihood (변화점 모델)
 - ✓ $k \leq L: \lambda_k \sim \mathcal{N}(\mu_1, \sigma^2)$, $k > L: \lambda_k \sim \mathcal{N}(\mu_2, \sigma^2)$
 - ✓ $\ell(L) = \sum \log \mathcal{N}(\lambda_k | \mu_1, \sigma^2) + \sum \log \mathcal{N}(\lambda_k | \mu_2, \sigma^2)$
 - ✓ $\Rightarrow \ell(L)$ 이 최대가 되는 지점을 L^* 로 선택



(a)



(b)

02 | Factor Analysis & PPCA

Factor Analysis as a linear-Gaussian latent variable model

- 생성 모델 (Generative Model)


- ✓ 잠재변수 사전분포 : $p(z) = \mathcal{N}(z|0, I)$, $z \in \mathbb{R}^L$
- ✓ 관측 모델 : $p(x|z, \theta) = \mathcal{N}(x|Wz + \mu, \Psi)$
- ✓ $W : D \times L$ 인수 부하 행렬 (factor loading matrix)
- ✓ $\Psi : D \times D$ 공분산 (각 차원별 고유 잡음)

- 주변 분포 (Marginal Distribution)

- ✓ $p(x|\theta) = \int \mathcal{N}(x|Wz + \mu, \Psi) \mathcal{N}(z|0, I) dz = \mathcal{N}(x|\mu, C)$
- ✓ $C = WW^T + \Psi \Rightarrow$ 저랭크(low-rank) 공분산 분해
- ✓ 파라미터 $\mathcal{O}(LD)$ vs 풀 가우시안 $\mathcal{O}(D^2)$ — 유연한 절충

- 사후 분포 (Posterior)

- ✓ $p(z|x) = \mathcal{N}(z | W^T C^{-1}(x - \mu), I - W^T C^{-1}W)$
- ✓ $\Rightarrow x$ 를 저차원 latent z 로 임베딩 가능 (encoder 역할)



02 | Factor Analysis & PPCA

Probabilistic PCA as a special case of Factor Analysis

- PPCA 모델
 - ✓ FA의 특수 케이스 : $\Psi = \sigma^2 I$ (등방성 잡음), W 의 열은 직교
 - ✓ $p(x|\theta) = \mathcal{N}(x|\mu, WW^\top + \sigma^2 I)$
- MLE 해석적 해
 - ✓ $\hat{W} = U_L(L_L - \sigma^2 I)^{1/2} R$ (R 은 임의의 직교 회전)
 - ✓ $\hat{\sigma}^2 = \frac{1}{D-L} \sum_{i=L+1}^D \lambda_i \leftarrow$ 잘려나간 차원들의 평균 분산
 - ✓ $\Rightarrow \sigma^2 \rightarrow 0$ 극한에서 $\hat{W} \propto U_L$ (top eigenvectors, PCA 해)
- PPCA를 통한 임베딩
 - ✓ 사후 평균 : $\mathbb{E}[z|x] = (W^\top W + \sigma^2 I)^{-1} W^\top (x - \bar{x})$
 - ✓ $\Rightarrow \sigma^2 \rightarrow 0$ 극한에서 표준 PCA의 투영과 연결됨
- PPCA의 장점
 - ✓ 확률 모델 $\rightarrow$ 결측치(missing data) 처리, EM 학습, 베이지안 확장 가능
 - ✓ Mixture-FA / 비선형 FA(VAE) 등 더 복잡한 모델의 building block

02 | Factor Analysis & PPCA

EM algorithm and rotation ambiguity

- EM 알고리즘

- ✓ E step : $p(z_i|x_i, \theta) = \mathcal{N}(z_i|m_i, \Sigma_i)$
- ✓ $\Sigma_i = (I_L + W^\top \Psi^{-1} W)^{-1}, \quad m_i = \Sigma_i W^\top \Psi^{-1} (x_i - \mu)$
- ✓ M step : $\hat{W} = [\sum_i x_i b_i^\top] [\sum_i C_i]^{-1}$
- ✓ $\hat{\Psi} = \frac{1}{N} \text{diag}\{\sum_i (x_i - \hat{W} b_i) x_i^\top\}$
- ✓ 장점 : 빠름 $\mathcal{O}(TLND)$, 온라인 가능, 결측치 처리, 변분 EM 으로 확장 용이

- 비식별성 (Unidentifiability)

- ✓ $\tilde{W} = WR \quad (RR^\top = I)$ 로 바뀌어도 $\text{Cov}[x] = \tilde{W}\tilde{W}^\top + \Psi = WW^\top + \Psi$ 동일
- ✓ $\Rightarrow W$ 와 latent factor 가 고유하게 식별되지 않음 (회전 모호성)

- 식별성을 부여하는 방법

- ✓ Orthonormal columns 강제 ✓ Sparsity prior 또는 Varimax 회전
- ✓ Lower-triangular W 사용 ✓ 비가우시안 prior 사용 $\rightarrow$ ICA 와 연결

02 | Factor Analysis & PPCA


Mixtures of factor analyzers for curved manifolds

- 동기 (Motivation)

- ✓ FA는 단일 선형 매핑 $z \rightarrow x \Rightarrow$ 곡선 매니폴드 표현 한계
- ✓ 가정 완화: 국소적으로만 선형, 전체는 K개 FA의 가중 결합
- ✓ $\Rightarrow$ 선형 매니폴드들의 혼합으로 곡선 매니폴드 근사

- 생성 모델 (Generative Model)

- ✓ 잠재 지시변수 $m_n \in \{1, \dots, K\}$: 어느 부분공간(클러스터)인지 결정



- 특수 케이스 및 장점

- ✓ $\Psi_k = \sigma^2 I \rightarrow$ Mixture of PPCA (단, W_k 직교성 보장 어려움)
- ✓ 파라미터 $O(KLD)$ vs Full covariance mixture $O(KD^2) \Rightarrow$ 저랭크 버전
- ✓ $\Rightarrow$ Mixture of Gaussians의 low-rank 버전, 과적합 감소

03 | Autoencoders

Autoencoders as nonlinear extensions of PCA

- Autoencoder 의 기본 구조


- ✓ Encoder $f_e: x \rightarrow z$ Decoder $f_d: z \rightarrow \hat{x}$
- ✓ 재구성 함수 $r(x) = f_d(f_e(x))$ — 손실 $\mathcal{L} = \|r(x) - x\|^2$
- ✓ 병목(bottleneck) 차원 L 에서 latent representation 학습

- Linear AE = PCA

- ✓ $z = W_1 x$, $\hat{x} = W_2 z$ (선형 인코더 · 디코더)
- ✓ $\mathcal{L} = \sum \|x_n - W_2 W_1 x_n\|^2$ 최소화 $\Rightarrow$ 학습된 부분공간은 PCA 와 동치

- Nonlinear Autoencoders


- ✓ MLP / CNN 인코더 · 디코더 도입 시 PCA 보다 더 강력
- ✓ Undercomplete ($L \ll D$) : 자연스러운 정보 압축
- ✓ Overcomplete ($L \gg D$) : identity 학습 방지를 위해 정규화 필수
- ✓ $\Rightarrow$ 정규화에 따라 Denoising / Contractive / Sparse / Variational AE



03 | Autoencoders

Denoising, contractive, and sparse autoencoders

- Denoising AE (DAE)
 - ✓ 입력에 노이즈 추가 $\tilde{x} \sim p_c(\tilde{x}|x) \rightarrow$ 깨끗한 x 를 복원하도록 학습
 - ✓ 가우시안 / 베르누이 (dropout) noise 사용
 - ✓ 잔차 $e(x) = r(\tilde{x}) - x \approx \nabla_x \log p(x)$ (score function)
 - ✓ $\Rightarrow$ DAE 는 데이터 매니폴드로 향하는 벡터장(vector field) 을 학습
- Contractive AE (CAE)
 - ✓ Encoder Jacobian 의 Frobenius norm 을 페널티
 - ✓ $\Omega(z, x) = \lambda \left\| \frac{\partial f_e(x)}{\partial x} \right\|_F^2 = \lambda \sum_k \left\| \nabla_x h_k(x) \right\|^2$
 - ✓ 국소 매니폴드로 입력을 "끌어당기는" 효과 — 단점 : 계산 비용 큼
- Sparse AE
 - ✓ 활성화 희소성 : $\Omega(z) = \lambda \|z\|_1$ (activity regularization)
 - ✓ 또는 KL 페널티 : 평균 활성 q_k 를 목표 분포 p 에 맞춤
 - ✓ $\Rightarrow$ 소수의 unit 만 활성, 생물학적 sparse coding 과 유사



03 | Autoencoders

Variational Autoencoders as nonlinear Factor Analysis

- VAE 의 두 가지 핵심 아이디어

- ✓ 비선형 FA 생성 모델 : $p_{\theta}(x|z) = \mathcal{N}(x|f_d(z; \theta), \sigma^2 I)$

- ✓ 추론망 $q_{\phi}(z|x) = \mathcal{N}(z|f_{\mu}(x; \phi), \text{diag}(f_{\sigma}(x; \phi)))$

- ELBO (Evidence Lower Bound)

- ✓ $\mathcal{L}(\theta, \phi|x) = \mathbb{E}_{q_{\phi}}[\log p_{\theta}(x|z)] - D_{KL}(q_{\phi}(z|x) \parallel p(z))$

- ✓ $\Rightarrow \mathcal{L} \leq \log p_{\theta}(x)$ (Jensen 부등식)


- ✓ 첫 항 : 재구성 (decoder) , 둘째 항 : prior 와의 KL 정규화

- VAE vs Deterministic AE

- ✓ AE는 각 입력을 하나의 점으로 임베딩 → latent space의 연속성 보장이 약함

- ✓ VAE는 분포로 임베딩하고 KL 정규화를 적용 → 더 매끄러운 latent space 형성


- ✓ $\Rightarrow$ VAE 는 새로운 샘플 생성 및 latent interpolation 에 유리



03 | Autoencoders

Reparameterization trick for VAE training


- 문제 : 샘플링은 미분 불가능
 - ✓ ELBO 의 expectation 항을 그대로 두면 인코더 파라미터로 역전파 불가
 - ✓ 직접 $z \sim q_\phi(z|x)$ 를 샘플하면 ∇_ϕ 가 흐를 수 없음
- 해결 : 재매개화 (Reparameterization)
 - ✓ $z = f_{e,\mu}(x; \phi) + f_{e,\sigma}(x; \phi) \odot \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I)$
 - ✓ 랜덤성을 외부 노이즈 ε 로 분리 $\rightarrow z$ 는 (x, ϕ, ε) 의 미분 가능한 함수
 - ✓ $\Rightarrow \nabla_\phi \mathcal{L}$ 을 일반 backpropagation 으로 계산 가능
- KL 항의 닫힌 형태 (가우시안 prior)
 - ✓ $p(z) = \mathcal{N}(0, I), \quad q(z) = \mathcal{N}(\mu, \text{diag}(\sigma))$ 일 때
 - ✓ $D_{KL}(q \parallel p) = -\frac{1}{2} \sum_k [\log \sigma_k^2 - \sigma_k^2 - \mu_k^2 + 1]$
 - ✓ $\Rightarrow$ KL 의 해석적 계산 가능, 효율적 학습




04 | Manifold Learning

Manifold hypothesis and intrinsic dimensionality

- 매니폴드 (Manifold) 의 정의
 - ✓ 국소적으로 유클리드 공간과 동등한 위상 공간
 - ✓ 각 점 $x \in \mathcal{X}$ 은 d 차원 접공간 (tangent space) $\mathcal{T}_x$ 를 가짐
 - ✓ Riemannian manifold : 각 접공간에 내적 부여 $\rightarrow$ 거리 · 각 · 부피 정의
- 매니폴드 가설 (Manifold Hypothesis)
 - ✓ 자연 발생 고차원 데이터는 저차원 매니폴드 위에 놓임
 - ✓ 예 : $64 \times 57 = 3,648$ 차원 회전된 숫자 6 $\rightarrow$ 본질 차원 $d = 2$ (회전 각도)
 - ✓ (Intrinsic dimensionality) $d \ll D$ (ambient dimensionality)
- 매니폴드 학습 접근법
 - ✓ Non-parametric : 학습 데이터의 임베딩만 학습 (out-of-sample 미지원)
 - ✓ Linear / convex : PCA, MDS, kPCA, Isomap, LLE
 - ✓ Nonlinear / nonconvex : t-SNE
 - ✓ Parametric extension : autoencoder



(a)



(c)

04 | Manifold Learning

Distance-preserving embeddings

- Classical MDS

- ✓ 점들 사이의 거리 관계를 최대한 보존하며 저차원에 배치
- ✓ 원래 좌표가 없어도, 거리 행렬만 있으면 저차원 표현 가능
- ✓ Strain 손실 : $\mathcal{L}_{strain}(Z) = \| \tilde{K} - \tilde{Z}\tilde{Z}^T \|_F^2$
- ✓ 해 : $\tilde{Z} = US^{\frac{1}{2}}$ (truncated SVD) $\Rightarrow$ PCA 와 동치

- Metric MDS

- ✓ 원래 거리와 저차원에서의 거리가 최대한 비슷해지도록 반복 조정
- ✓ 거리 차이가 작을수록 좋은 임베딩

- ✓ Stress 함수 : $\mathcal{L}_{stress}(Z) = \sqrt{\frac{\sum_{i < j} (d_{ij} - \hat{d}_{ij})^2}{\sum d_{ij}^2}}$

- Non-metric MDS & Sammon Mapping

- ✓ Non-metric MDS: 정확한 거리값보다 가까운 순서(rank) 보존
- ✓ Sammon Mapping: 가까운 점들 사이의 거리 보존을 더 중요하게 반영
- ✓ 전체 구조보다 국소 구조(local structure)를 잘 보존하는 데 초점

04 | Manifold Learning

Isomap and Kernel PCA for nonlinear dimensionality reduction

- Isomap


- ✓ KNN 그래프 위의 Dijkstra 최단거리 = 매니폴드 측지선 (geodesic) 근사
- ✓ 근사된 거리 행렬에 classical MDS 적용 (PCA)
- ✓ $\Rightarrow$ Swiss roll 같은 곡선 매니폴드를 잘 펼쳐냄
- ✓ 단점 : 노이즈로 인한 "short circuit" edge $\rightarrow$ topological instability

- Kernel PCA (kPCA)


- ✓ PCA 를 Gram 행렬 $K = XX^T$ 고유분해로 풀고 $\rightarrow$ 커널 트릭 적용
- ✓ $K_{ij} = \mathcal{K}(x_i, x_j) \leftarrow$ inner product 를 비선형 커널로 대체
- ✓ 테스트 벡터 투영 : $\phi_*^T V_{kPCA} = k_*^T U \Lambda^{-1/2}$
- ✓ 중심화 : $\tilde{K} = C_N K C_N$

- kPCA의 한계

- ✓ RBF kernel은 고차원 feature space로 암묵적 매핑 $\Rightarrow$ 해석 가능한 입력공간의 unfolding으로 보기는 어려움
- ✓ $\Rightarrow$ MVU (Maximum Variance Unfolding) 으로 명시적 unfolding



(a)




(b)

04 | Manifold Learning

Local geometry preservation with LLE

- Local Linear Embedding (LLE)
 - ✓ 데이터 매니폴드가 각 점 근방에서 국소 선형이라 가정
 - ✓ 각 점을 KNN 의 선형 결합으로 재구성 : $\sum_j w_{ij} x_j \approx x_i, \sum_j w_{ij} = 1$
 - ✓ 저차원에서도 같은 가중치 보존 : $\hat{Z} = \operatorname{argmin}_Z \sum_i \|z_i - \sum_j \hat{w}_{ij} z_j\|^2$
 - ✓ $\Rightarrow (I - W)^\top (I - W)$ 의 가장 작은 비영 고유벡터들이 해
 - ✓ Short-circuit 에 Isomap 보다 덜 민감 (sparse eigen-problem)



(a)

04 | Manifold Learning

Neighbor-preserving visualization with t-SNE

- SNE 기본 아이디어

- ✓ 고차원 유사도를 조건부 확률로 표현, KL 발산 $\sum_i D_{KL}(P_i \parallel Q_i)$ 최소화

- ✓
$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)}$$

- ✓ 저차원에서 $q_{j|i}$ 도 유사하게 정의

- t-SNE 의 핵심 개선

- ✓ Crowding problem : 2D 로 압축 시 점들이 한곳에 뭉치는 현상



- ✓ 저차원에 Student-t (Cauchy) 분포 사용 → heavy tails 로 클러스터 분리

- ✓
$$q_{ij} = \frac{(1 + \|z_i - z_j\|^2)^{-1}}{\sum_{k < l} (1 + \|z_k - z_l\|^2)^{-1}}$$

- 실용적 고려사항

- ✓ σ_i^2 는 perplexity $2^{H(P_i)}$ 로 자동 선택 (보통 5 ~ 50)

- ✓ 결과가 perplexity 값에 매우 민감 → 여러 값으로 반복 실행 후 비교 필요



(b)

Q&A

감사합니다.