



AutoAugment: Learning Augmentation Strategies from Data

김도현 / 2026-03-24



E. D. Cubuk, B. Zoph, D. Mane, V. Vasudevan, and Q. V. Le, “AutoAugment: Learning Augmentation Strategies from Data,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 113–123.

Computational Data Science LAB



CONTENTS

1. Introduction
 2. AutoAugmentation
 3. Experiments and Results
 4. Discussion
 5. Conclusions
- 
- 

01 | Introduction

Augmentation

- 데이터 증강의 중요성
 - ✓ 데이터 증강(Data Augmentation)은 데이터를 무작위로 변환하여 양과 다양성을 동시에 증가시키는 기법
 - ✓ 역할: 모델에게 데이터 도메인의 불변성(invariance)을 학습시킴
 - ✓ 예시: 이미지 이동, 수평 뒤집기, 회전, 색상 변환 등 → 아키텍처 하드코딩보다 증강을 통한 불변성 학습이 더 유연
- 수동 설계의 한계점
 - ① 증강 방법의 정체
 - ImageNet에서 2012년 이후 증강 방법이 거의 변화 없음
 - 아키텍처(VGG→ResNet→NAS 등)는 비약적 발전 vs 증강은 정체
 - ② 데이터셋 간 전이 불가
 - 수평 뒤집기: CIFAR-10에서는 효과적이거나, MNIST에서는 비효과적 (6↔9 등 대칭 구조가 다름)
 - ③ 전문 지식 필요
 - 최적 증강 전략 설계에 도메인 전문 지식과 시행착오 필요



01 | Introduction

Related Work

- 수동 설계 기반 데이터 증강
 - 기존 증강 방법은 모두 사람이 수동 설계하며, 최적 전략은 데이터셋마다 다름
 - MNIST: 탄성 변형, 스케일, 이동, 회전, CIFAR-10/ImageNet: 랜덤 크롭, 이미지 미러링, 색상 이동/화이트닝
 - 한계점: 전문가 지식과 시간 필요, 데이터셋이 바뀌면 재설계 필요
- 기존 학습 기반 데이터 증강
 - Smart Augmentation: 같은 클래스 샘플을 병합하여 증강 데이터 생성
 - Bayesian 접근: 학습 데이터 분포 기반으로 새 데이터 생성
 - 특징 공간 변환: 원본 이미지가 아닌 학습된 특징 공간에서 변환 적용
 - 한계점: 분류 성능을 간접적으로만 개선, 증강 전략 자체를 체계적으로 탐색하는 메커니즘 부재
- GAN 기반 데이터 증강
 - GAN을 활용하여 추가 데이터를 직접 생성하는 연구들 다수 존재, GAN → 증강 이미지 자체를 픽셀 수준에서 직접 생성
 - 한계점: "원본과 유사한 증강"만 학습하므로 보수적인 변환에 그치며, 분류 성능을 직접 높이는 최적 증강을 탐색하지 못함
- 아키텍처 탐색(NAS)
 - 강화학습과 진화 알고리즘으로 최적 모델 아키텍처를 자동 발견하는 NAS 분야에서 착안
 - 대표 연구: NAS, NASNet, AmoebaNet, Progressive NAS 등
 - 한계점: 아키텍처 탐색만으로는 CIFAR-10에서 2% 오류율 돌파하지 못함

01 | Introduction

AutoAugment

- AutoAugment 핵심 아이디어

- ✓ 타겟 데이터셋에 최적화된 증강 정책 자동 탐색
- ✓ 정책(Policy) = 증강 연산(방법)의 종류 + 적용 확률 + 강도의 조합
- ✓ 탐색 알고리즘(RL)으로 검증 정확도를 최대화하는 최적 정책 탐색



- AutoAugment-Direct (직접 탐색)

Dataset	기존 SOTA	AutoAugment	개선폭
CIFAR-10	2.1% (Error rate)	1.5%	-0.6%p
SVHN	1.3% (Error rate)	1.0%	-0.3%p
ImageNet (Top-1)	83.1% (Accuracy)	83.5%	+0.4%p

- AutoAugment-Transfer (정책 전이)

- ✓ ImageNet 정책 → FGVC 데이터셋에 전이 적용 시 유의미한 성능 향상
- ✓ Stanford Cars -1.2%p, FGVC Aircraft -1.8%p 오류율 감소
→ 가중치 전이학습의 대안으로서 증강 정책 전이의 가능성 제시

02 | AutoAugmentation 프레임워크

✓ 최적 증강 정책 탐색을 이산 탐색 문제(discrete search problem)로 정의

✓ 전체 루프


- ① 컨트롤러 RNN이 증강 정책 S를 샘플링
- ② 정책 S로 고정 아키텍처의 child model을 학습
- ③ 검증 정확도 R을 측정
- ④ R을 보상(Reward)로 사용하여 컨트롤러 업데이트

✓ 검증 정확도 R은 미분 불가능 → **policy gradient** 방법으로 컨트롤러 학습

- 기본 원리: gradient를 직접 계산 대신, "좋은 결과를 낸 행동은 앞으로 더 자주 선택하고, 나쁜 결과를 낸 행동은 덜 선택하도록" 확률 조정


- $\theta \leftarrow \theta + \eta \nabla_{\theta} J(\theta) = \theta + \eta ((R - \text{baseline}) \times \nabla_{\theta} \log P(\text{정책} | \theta))$

- θ : 컨트롤러의 파라미터
- R : 해당 정책으로 얻은 검증 정확도 (보상)
- baseline : 이전 보상들의 평균 (지수이동평균, 가중치 0.95). 이를 빼줌으로써 “평균보다 좋은 정책은 강화, 평균보다 나쁜 정책은 약화”
- $\nabla_{\theta} \log P(\text{정책} | \theta)$: 컨트롤러가 해당 정책을 선택할 확률의 log에 대한 gradient. 컨트롤러의 softmax 출력이므로 미분 가능




02 | AutoAugmentation

탐색 공간 설계 (3단계 계층 구조)



- ✓ 정책(Policy) = 5개 서브 정책으로 구성
 - 학습 시 각 미니배치의 각 이미지마다 5개 중 1개를 균일 확률로 무작위 선택
 - 이미지마다 무작위로 선택하여, 학습 데이터의 다양성을 증가시키기 위한 목적
- ✓ 서브 정책(Sub-policy) = 2개 연산(방법)을 명시된 순서대로 적용
 - 각 연산(Operation) = 3가지 요소로 정의
 - 연산 종류: 16가지 이미지 처리 함수 중 선택
 - 적용 확률: 0.0~1.0 (11단계 이산화)
 - 적용 강도: magnitude 범위를 10단계로 이산화
- ✓ 16가지 연산
 - 기하학적: ShearX/Y, TranslateX/Y, Rotate
 - 색상: AutoContrast, Invert, Equalize, Solarize, Posterize, Contrast, Color, Brightness, Sharpness
 - 추가: Cutout, Sample Pairing
- ✓ Identity 연산은 명시적으로 없으나, 적용 확률을 0으로 설정하면 동일 효과
- ✓ 전체 탐색 공간: $(16 \times 10 \times 11)^{10} \approx 2.9 \times 10^{32}$ 가지



02 | AutoAugmentation

컨트롤러 RNN 구조 및 학습

- 컨트롤러 구조: 1-layer LSTM, 100 hidden units (RNN기반 방법의 경우, 결정간의 의존성 모델링 가능)
 - ✓ 총 30개 softmax 예측 (5 서브정책 × 2 연산 × 3 파라미터)
 - ✓ 각 단계의 예측이 다음 단계의 입력(embedding)으로 전달
- 학습 알고리즘: PPO (Proximal Policy Optimization)
 - ✓ 기본 Policy Gradient + 이전 정책 대비 새 정책의 변화 비율을 계산하고, 비율이 일정 범위($1 \pm \epsilon$)를 넘지 않도록 잘라내어 한 번에 정책이 급변하는 것을 방지
 - ✓ 학습률: 0.00035
 - ✓ 엔트로피 패널티: 0.00001 (탐색 다양성 장려): $L_{total} = L_{PPO} + 0.00001 \times H(\pi)$
 - ✓ 보상 baseline: 이전 보상의 지수이동평균 (가중치 0.95)
 - ✓ 가중치 초기화: [-0.1, 0.1] 균일분포
- 탐색 규모: 데이터셋당 약 15,000개 정책 샘플링
- 최종 정책 구성: 탐색 종료 후 상위 5개 정책의 서브 정책을 모두 결합 → 25개 서브 정책으로 최종 모델 학습

03 | Experiments and Results

AutoAugment-direct (CIFAR-10, CIFAR-100, SVHN에서 직접 정책 탐색 및 적용)

Dataset	Model	Baseline	Cutout [12]	AutoAugment
CIFAR-10	Wide-ResNet-28-10 [67]	3.9	3.1	2.6±0.1
	Shake-Shake (26 2x32d) [17]	3.6	3.0	2.5±0.1
	Shake-Shake (26 2x96d) [17]	2.9	2.6	2.0±0.1
	Shake-Shake (26 2x112d) [17]	2.8	2.6	1.9±0.1
	AmoebaNet-B (6,128) [48]	3.0	2.1	1.8±0.1
	PyramidNet+ShakeDrop [65]	2.7	2.3	1.5 ± 0.1
Reduced CIFAR-10	Wide-ResNet-28-10 [67]	18.8	16.5	14.1±0.3
	Shake-Shake (26 2x96d) [17]	17.1	13.4	10.0 ± 0.2
CIFAR-100	Wide-ResNet-28-10 [67]	18.8	18.4	17.1±0.3
	Shake-Shake (26 2x96d) [17]	17.1	16.0	14.3±0.2
	PyramidNet+ShakeDrop [65]	14.0	12.2	10.7 ± 0.2
SVHN	Wide-ResNet-28-10 [67]	1.5	1.3	1.1
	Shake-Shake (26 2x96d) [17]	1.4	1.2	1.0
Reduced SVHN	Wide-ResNet-28-10 [67]	13.2	32.5	8.2
	Shake-Shake (26 2x96d) [17]	12.3	24.2	5.9

수행내용


- ✓ Baseline: 각 데이터셋의 표준 전처리만 적용한 것.
CIFAR-10의 경우 데이터 표준화 + 수평 뒤집기(50%) + 제로 패딩 + 랜덤 크롭
- ✓ Cutout: Baseline 전처리에 Cutout을 추가한 것.
Cutout은 학습 이미지에서 정사각형 영역을 무작위로 잘라내어 회색으로 채우는 정규화 기법. CIFAR-10에서는 16 × 16 픽셀, SVHN에서는 20 × 20 픽셀 사용.
- ✓ AutoAugment: Baseline 전처리 → AutoAugment 정책 적용 → Cutout 적용 순서로 적용

실험결과

- ✓ 일관된 개선: 4개 데이터셋, 6개 아키텍처 전부에서 AutoAugment > Cutout > Baseline
- ✓ 적은 데이터에서 더 큰 효과: Reduced CIFAR-10, Reduced SVHN에서 개선 폭이 더 큼
- ✓ 데이터셋별 최적 정책은 다름: CIFAR-10은 색상 변환 위주, SVHN은 기하학적 변환 + Invert 위주
- ✓ 수동 증강의 위험: Cutout은 Reduced SVHN에서 역효과 → 자동 탐색의 필요성 입증

03 | Experiments and Results

AutoAugment-direct (ImageNet에서 직접 정책 탐색 및 적용)



Model	Inception Pre-processing [59]	AutoAugment ours
ResNet-50	76.3 / 93.1	77.6 / 93.8
ResNet-200	78.5 / 94.2	80.0 / 95.0
AmoebaNet-B (6,190)	82.2 / 96.0	82.8 / 96.2
AmoebaNet-C (6,228)	83.1 / 96.1	83.5 / 96.5

수행내용

- ✓ 전체 ImageNet 대신 **120개 클래스, 6,000개 샘플의 축소 데이터셋에서 정책 탐색**
- ✓ Wide-ResNet-40-2로 200 에폭 학습 (weight decay 10^{-5} , 학습률 0.1, 코사인 감쇠)
- ✓ CIFAR-10과 유사하게 색상 기반 변환이 주류이나, Rotate가 추가로 빈번하게 선택됨
- ✓ 상위 5개 정책의 서브 정책을 결합하여 25개 서브 정책으로 구성 후, 전체 ImageNet에서 처음부터 학습 (270 에폭, 배치 4,096)
- ✓ **Inception-style 전처리(픽셀 스케일링, 수평 뒤집기, 색상 왜곡)에 추가적으로 AutoAugment 적용**

실험결과

- ✓ ResNet-50(단순모델)부터 AmoebaNet-C(최고성능 모델)까지 모든 모델에서 일관된 개선
- ✓ AmoebaNet-C에서 83.5%(Top-1)/96.5%(Top-5) SOTA 달성
- ✓ 최적 정책이 단 6,000개 이미지에서 발견

03 | Experiments and Results

AutoAugment-transfer (ImageNet 정책을 FGVC 데이터셋에 전이 적용)

Dataset	Train Size	Classes	Baseline	AutoAugment-transfer
Oxford 102 Flowers [43]	2,040	102	6.7	4.6
Caltech-101 [15]	3,060	102	19.4	13.1
Oxford-IIIT Pets [14]	3,680	37	13.5	11.0
FGVC Aircraft [38]	6,667	100	9.1	7.3
Stanford Cars [27]	8,144	196	6.4	5.2

수행내용

- ✓ 한 데이터셋에서 찾은 정책을 다른 데이터셋에 전이할 수 있는지 검증
- ✓ ImageNet에서 찾은 정책 (Table 3에서 사용한 것과 동일)을 그대로 사용
- ✓ ImageNet과 이미지 크기가 유사한 5개 FGVC 데이터셋에 적용, 학습 데이터가 적고, 클래스 수가 많아 도전적인 과제
- ✓ Inception v4를 1,000 에폭 학습, 이미지 크기 448×448, 코사인 학습률 감소. 검증 세트로 하이퍼파라미터 선택 후, 학습+검증 세트를 합쳐 최종 학습
- ✓ Inception 전처리만 적용한 Baseline vs ImageNet 정책을 추가한 AutoAugment-transfer

실험결과



- ✓ 모든 5개 데이터셋에서 별도 탐색 없이 ImageNet 정책만으로 유의미한 성능 향상
- ✓ FGVC Aircraft는 ImageNet 가중치 전이학습이 잘 안 되는 것으로 알려진 데이터셋이지만, 증강 정책 전이는 효과적
→ 가중치 전이와 증강 정책 전이는 상호 보완적
- ✓ Stanford Cars에서 5.2% 달성, 이는 ImageNet 사전학습 가중치를 미세조정만 한 기존 SOTA(5.9%)보다도 우수
- ✓ AutoAugment가 특정 데이터셋에 과적합하지 않고 범용적 변환을 발견했음을 입증하며,
가중치 전이학습의 대안적 방법으로서 증강 정책 전이의 가능성 제시

04 | Discussion

Method	Baseline	Augmented	Improvement Δ
LSTM [47]	7.7	6.0	1.6
MF [47]	7.7	5.6	2.1
AutoAugment (ResNet-32)	7.7	4.5	3.2
AutoAugment (ResNet-56)	6.6	3.6	3.0

• 실험결과

- ✓ 원본 유사성을 학습하는 GAN 기반 모델 (Ratner et al.) 대비 약 1%p 이상 더 큰 개선 향상
- ✓ 더 많은 서브 정책 → 더 다양한 증강 → 더 좋은 일반화. 단, 20개를 넘으면 각 서브 정책의 적용 빈도가 너무 낮아져 한계 효용 감소
- ✓ 탐색을 통해 학습된 확률과 강도 정보가 실제로 의미 있음. 좋은 연산을 고르는 것만으로는 불충분하며, 얼마나 자주/강하게 적용할지도 중요
- ✓ 연산 종류, 확률, 강도를 모두 무작위로 샘플링하여 동일 조건으로 20회 반복 학습
 - 무작위 정책만으로도 baseline을 크게 능가(3.9%→3.1%)하여 탐색 공간 자체의 우수성 입증
 - AutoAugment 정책(2.6%)이 확률/강도 무작위화 정책(3.0%)보다 0.4% 우위
 - AutoAugment(2.6%)가 무작위 대비 0.4~0.5%p를 추가 개선하여 체계적 탐색 필요
- ✓ AutoAugment 정책은 아키텍처와 데이터셋에 관계없이 성능을 해치지 않고 일관된 개선을 보이거나, 타겟 데이터 분포에 가장 가까운 데이터에서 찾은 정책이 최선의 성능 달성
- ✓ RL은 편의상 사용한 것이며, 핵심 기여는 탐색 공간 설계이지 최적화 방법론 아님



05 | Conclusions

AutoAugmentation

1. 본 논문을 한마디로 정의하면 무엇인가?
 - ✓ 데이터 증강 전략을 강화학습 기반 이산 탐색 문제로 정의하여 데이터셋에 최적화된 증강 정책 자동 발견 프레임워크 제시
2. 본 논문에서 놀랍고, 새로운 점은 무엇인가? (Contribution)
 - ✓ 아키텍처 탐색(NAS)의 자동 탐색 철학을 데이터 증강이라는 새로운 영역에 적용
 - ✓ 축소 데이터셋(4,000~6,000개)에서 찾은 정책이 전체 데이터셋, 다른 아키텍처, 다른 데이터셋에까지 광범위하게 전이
 - ✓ 무작위 정책도 baseline을 능가하여, 탐색 공간 설계 자체가 핵심 기여임을 입증한 점
3. 본인이 예상한 바와 어떤 점이 다른가? (Weakness)
 - ✓ 탐색 비용이 매우 큼. (무작위 정책과의 차이가 0.4~0.5%p에 불과)
막대한 탐색 비용(CIFAR-10: 5,000 GPU시간, ImageNet: 15,000 GPU시간) 대비 RL 탐색의 비용 효율성이 낮음
 - ✓ 증강 방법을 16가지로 고정
4. 본 논문과 관련된 본인의 아이디어는 무엇인가?
 - ✓ TTA(Test Time Augmentation)과의 결합을 통해 안정적인 예측 및 더 높은 정확도 기대
 - ✓ 정상/ 불량 렌즈 품질검사 데이터에도 활용 가능


06 | 동영상 강의

Augmentation Methods

강화학습 기반 컨트롤러로 최적의 데이터 증강 정책
(연산 종류 · 확률 · 강도)을 자동 탐색하는 방법
(Google Brain, 2019)

최적 정책을 찾기 위한 명시적
탐색 과정을 유지하면서,
어떻게 더 효율적으로 탐색할까?

탐색 과정이
과연 필요한가?



유전 알고리즘 같이 증강 정책 학습 도중 동적으로 진화시켜, AutoAugment 대비 1,000배 이상 빠르게 탐색하는 방법 (Ho et al., 2019).

증강데이터가 원데이터의 분포와 최대한 동일하도록 베이지안 알고리즘으로 탐색하는 방법 (Lim et al., 2019)

GAN의 원리를 빌려와 '데이터 분포'가 같아지도록 경사강하법으로 증강을 학습하는 방법 (Hataya et al., 2020).

모델이 가장 틀리기 쉬운 증강을 GAN처럼 적대적으로 생성하여, 모델의 약점을 집중 훈련시키는 방법 (Zhang et al., 2020).


어떤 증강방법을 쓸지 고르는 이산적 선택 문제를, 미분 가능한 형태로 바꿔서 경사강하법으로 직접 최적화할 수 있게 만든 방법 (Li et al., 2020)

06 | 동영상 강의

Augmentation Methods

최적 정책을 찾기 위한 명시적
탐색 과정을 유지하면서,
어떻게 더 효율적으로 탐색할까?

탐색 과정이
과연 필요한가?



탐색 과정을 완전히 제거하고, 전체 연산 풀에서 N개를 무작위 선택한 뒤, 단일 공유 강도(M)로 적용하는 극도로 단순한 방법 (Cubuk et al., 2020).

RandAugment에서 강도 하이퍼파라미터 제거 후, 각 방법의 확률과 강도를 균일분포에서 샘플링하여 하이퍼파라미터 튜닝이 필요 없는 방법 (Meng et al., 2020).

매 이미지마다 단 하나의 연산을 무작위로 골라 무작위 강도로 적용하는, 가장 단순하면서 경쟁력 있는 baseline 증강 방법 (Müller & Hutter, 2021).

다단계 증강 파이프라인을 구성하고 gradient 기반으로 각 단계의 증강 분포를 학습하여, 더 다양하고 복잡한 증강 조합을 탐색하는 방법 (Zheng et al., 2022)

Q&A
