



RandAugment: Practical automated data augmentation with a reduce search space

김무진 / 2026-04-07



E. D. Cubuk, B. Zoph, J. Shlens, and Q. V. Le,
"RandAugment: Practical Automated Data
Augmentation with a Reduced Search Space," in Proc.
IEEE/CVF Conf. Comput. Vis. Pattern Recognit.
Workshops (CVPRW), 2020.

Computational Data Science LAB




CONTENTS

1. Introduction
 2. Methods
 3. Experiments
 4. Results
 5. Conclusions
- 
- 

01 | Introduction

Data Augmentation

- Data Augmentation
 - ✓ 학습된 데이터 증강 정책을 사용하면, 이미지 분류문제 뿐만 아니라 COCO, PASCAL-VOC 같은 객체탐지에서도 정확도와 모델 안정성, 성능을 크게 향상시킬 수 있음
 - ✓ 하지만, 증강 방법은 각 도메인의 사전 지식을 반영한 정책을 설계하기 위해 전문 지식과 수작업이 필요
 - ✓ 데이터 증강을 위한 정책을 학습하는 방법이 등장했으며, 증강 전략 설계를 자동화 할 수 있는 방법이 등장함




01 | Introduction

AutoAugment & Population Based Augmentation

- Related Work (AA&PBA)
 - ✓ AutoAugment는 Operation, Probability, Magnitude을 강화학습으로 자동 결정
 - ✓ PBA에서는 학습 과정에서 augmentation policy를 동적으로 업데이트하며 Schedule형태로 최적화

- Limitations

- ✓ 본 모델 학습 전에 Augmentation Policy를 따로 탐색하는 단계가 필요
- ✓ Policy Search, Model Training → 두 단계 최적화가 필요하여 모델을 두 번 학습하게 됨
- ✓ 계산량이 늘고 파이프라인이 복잡해짐
- ✓ 따라서 복잡한 Policy Search 없이, 단순한 구조로 동일한 효과를 내는 방법이 필요




02 | Methods

RandAugment

- RandAugment

- ✓ 2개의 hyperparameter N과 M을 통해 학습과정을 단순화
- ✓ N : K개 중, 몇 개의 augmentation을 적용할 지
- ✓ M : augmentation 강도를 얼마나 줄 지



$$\text{Search Space} = (16 \times 10 \times 11)^{2 \times 5} \approx 2.9 \times 10^{32} \quad \longrightarrow \quad N \times M \approx 10^2$$


최적화 grid search만으로 충분

- Flow

- ✓ 학습 전 고정된 N과 M의 조합을 기반으로 training 중 각 이미지마다 augmentation이 적용될 때 랜덤(균일확률)로 선택
- ✓ 예시
 - N = {1,2}, M = {2,6,10,14} 라면, 8가지 경우의 수를 기반으로 Grid Search
 - N, M은 한 번의 학습 run 동안 고정
- ✓ 학습 중 각 이미지마다 어떤 operation 조합이 나올지 랜덤하게 되어 다양성이 생김
- ✓ 각 조합마다 학습한 모델의 Validation accuracy를 보고 가장 좋은 최적의 N, M을 선택

02 | Methods

RandAugment



Random한 Augmentation 2가지를
강도 9로 통일 적용하여 input으로 학습



• Effect

- ✓ Augmentation종류가 K개 있고, 한 이미지에 N개를 연속 적용한다면
가능한 조합 수는 K^N
- ✓ Parameter space를 줄이면서도 diversity는 유지
- ✓ 즉, Policy를 복잡하게 학습하지 않아도, 랜덤 선택만으로 조합 다양성은 충분함
- ✓ 단순한 Python 코드 2줄로 구현 가능


```
transforms = [  
    'Identity', 'AutoContrast', 'Equalize',  
    'Rotate', 'Solarize', 'Color', 'Posterize',  
    'Contrast', 'Brightness', 'Sharpness',  
    'ShearX', 'ShearY', 'TranslateX', 'TranslateY']  
  
def randaugment (N, M):  
    """Generate a set of distortions.  
  
    Args:  
        N: Number of augmentation transformations to  
           apply sequentially.  
        M: Magnitude for all the transformations.  
    """  
  
    sampled_ops = np.random.choice(transforms, N)  
    return [(op, M) for op in sampled_ops]
```

Figure 2. Python code for RandAugment based on numpy.

03 | Experiments and Results

Small Proxy Task Problem

- Small Task Problem
 - ✓ 논문에서의 아이디어 출발점은 기존방식의 한계
 - ✓ 저자는 small proxy task에서 data augmentation policy를 찾는 것을 문제 삼음
 - ✓ 모델 사이즈와 data set 사이즈 두 가지 측면에서 분석
- Interpretation
 - ✓ Parameter가 커질 수록 distortion이 커져야 성능이 좋아짐
 - ✓ Data Set의 사이즈가 클수록 Optimal Distortion Magnitude가 커짐
 - ✓ 즉, 더 큰 Data Set에서는 더 강한 Augmentation이 필요
 - ✓ 일부만으로 파악하는 Proxy Task에서 찾은 최적 값은 Sub-Optimal 일 가능성이 높음



03 | Experiments

Small Proxy Task Problem

- CIFAR-100
 - ✓ WideResNet-28-2, WideResNet-28-10 두 모델 사용
 - ✓ Validation 5,000개로 N, M 후보 시험
 - $N = \{1, 2\}$
 - $M = \{2, 6, 10, 14\}$
 - ✓ 각 모델 별 최적값
 - WRN-28-2 $\rightarrow N=1, M=2$
 - WRN-28-10 $\rightarrow N=2, M=14$
 - ✓ 최적 Augmentation 세기는 모델 크기/용량에 따라 달라질 수 있다는 점을 실험을 통해 보여줌


	baseline	PBA	Fast AA	AA	RA
CIFAR-10					
Wide-ResNet-28-2	94.9	-	-	95.9	95.8
Wide-ResNet-28-10	96.1	97.4	97.3	97.4	97.3
Shake-Shake	97.1	98.0	98.0	98.0	98.0
PyramidNet	97.3	98.5	98.5	98.5	98.5
CIFAR-100					
Wide-ResNet-28-2	75.4	-	-	78.5	78.3
Wide-ResNet-28-10	81.2	83.3	82.7	82.9	83.3
SVHN (core set)					
Wide-ResNet-28-2	96.7	-	-	98.0	98.3
Wide-ResNet-28-10	96.9	-	-	98.1	98.3
SVHN					
Wide-ResNet-28-2	98.2	-	-	98.7	98.7
Wide-ResNet-28-10	98.5	98.9	98.8	98.9	99.0

Table 2. **Test accuracy (%) on CIFAR-10, CIFAR-100, SVHN and SVHN core set.** Comparisons across default data augmentation (baseline), Population Based Augmentation (PBA) [20] and Fast AutoAugment (Fast AA) [25], AutoAugment (AA) [5] and proposed RandAugment (RA). Note that baseline and AA are replicated in this work. SVHN core set consists of 73K examples. The Shake-Shake model [12] employed a 26 $2 \times 96d$ configuration, and the PyramidNet model used the ShakeDrop regularization [51]. Results reported by us are averaged over 10 independent runs. Bold indicates best results.

03 | Experiments

“K” Random Justified

- Why is Random Selection of K Justified?
 - ✓ 성능을 높이거나 줄이는 증강기법이 존재
 - ✓ 하지만 전체 증강의 종류가 많아지면 비슷한 효과를 냄
 - ✓ 즉, 어떤 증강기법을 쓸 지 탐색하는 비용보다 랜덤하게 임의로 증강을 적용시켜서 얻는 다양성이 더 좋은 효과를 냄
 - ✓ Augmentation마다 확률을 탐색할 필요가 없음




03 | Experiments

“M” Fixed Justified

- Why is a Fixed M Justified?

- ✓ PBA에서 최적의 강도는 특정 값으로 수렴 → 에포크마다 강도를 다르게 주는 복잡한 스케줄이 불필요
- ✓ Accuracy가 magnitude schedule 변화에 둔감하여 세밀한 조정보다 적절한 고정 값이 중요
- ✓ 즉, 성능 향상의 핵심은 복잡한 magnitude 탐색 자체보다 적절한 수준의 augmentation을 일관되게 주는 것에 가까움



Magnitude Method	Accuracy
Random Magnitude	97.3
Constant Magnitude	97.2
Linearly Increasing Magnitude	97.2
Random Magnitude with Increasing Upper Bound	97.3

04 | Results

• Results

- ✓ RandAugment는 복잡한 Policy 탐색 과정 없이 SOTA달성
- ✓ 별도 Policy Search없이 간단한 Parameter로 모델/데이터 규모에 맞게 조절 가능
- ✓ SVHN(core set)은 7만 3천장 사용, SVHN은 60만 4천장 사용
- ✓ RandAugment는 SVHN에서 데이터 53만장을 추가한 것과 같은 효과를 냄

	baseline	PBA	Fast AA	AA	RA
CIFAR-10					
Wide-ResNet-28-2	94.9	-	-	95.9	95.8
Wide-ResNet-28-10	96.1	97.4	97.3	97.4	97.3
Shake-Shake	97.1	98.0	98.0	98.0	98.0
PyramidNet	97.3	98.5	98.3	98.5	98.5
CIFAR-100					
Wide-ResNet-28-2	75.4	-	-	78.5	78.3
Wide-ResNet-28-10	81.2	83.3	82.7	82.9	83.3
SVHN (core set)					
Wide-ResNet-28-2	96.7	-	-	98.0	98.3
Wide-ResNet-28-10	96.9	-	-	98.1	98.3
SVHN					
Wide-ResNet-28-2	98.2	-	-	98.7	98.7
Wide-ResNet-28-10	98.5	98.9	98.8	98.9	99.0

Table 2. Test accuracy (%) on CIFAR-10, CIFAR-100, SVHN and SVHN core set. Comparisons across default data augmenta-

04 | Results

- Results

- ✓ CIFAR-10 / CIFAR-100 , SVHN, ImageNet, COCO 다양한 벤치마크에서 성능을 보여줌

	baseline	Fast AA	AA	RA
ResNet-50	76.3 / 93.1	77.6 / 93.7	77.6 / 93.8	77.6 / 93.8
EfficientNet-B5	83.2 / 96.7	-	83.3 / 96.7	83.9 / 96.8
EfficientNet-B7	84.0 / 96.9	-	84.4 / 97.1	85.0 / 97.2

Table 3. **ImageNet results.** Top-1 and Top-5 accuracies (%) on ImageNet. Baseline and AutoAugment (AA) results on ResNet-50 are from [5]. Fast AutoAugment (Fast AA) results are from [25]. EfficientNet results with and without AutoAugment are from [47]. Highest accuracy for each model is presented in bold. Note that Population Based Augmentation (PBA) [20] has not been implemented on ImageNet.

model	augmentation	mAP	search space
ResNet-101	Baseline	38.8	0
	AutoAugment	40.4	10^{34}
	RandAugment	40.1	10^2
ResNet-200	Baseline	39.9	0
	AutoAugment	42.1	10^{34}
	RandAugment	41.9	10^2

Table 4. **Results on object detection.** Mean average precision (mAP) on COCO detection task. Higher is better. Search space size is reported as the order of magnitude of the number of possible augmentation policies. Models are trained for 300 epochs from random initialization following [57].

05 | Conclusion

- 본 논문을 한마디로 정의하면 무엇인가?
 - ✓ 가설을 바탕으로 실험을 통해 얻은 인사이트를 이용하여 유의미하게 적은 탐색비용과 우수한 성능을 보여준 연구
 - ✓ 또한 성능 자체를 높이기보다는 불필요한 복잡성과 비용을 제거한 연구라고 생각됨
- 본 논문에서 놀랍고, 새로운 점은 무엇인가?
 - ✓ 탐색비용과 성능은 어떠한 Trade-Off 관계라고 생각하였는데, 단순한 Trade-Off만은 아님을 깨닫게 됨
- 본인이 예상한 바와 어떤 점이 다른가?
 - ✓ 성능이 기존의 방식들과 비슷하거나 살짝 낮은 정도로 예상하였는데, 기존 방식을 뛰어넘는 성능도 있었음
- 본 논문과 관련된 본인의 아이디어는 무엇인가?
 - ✓ RandAugment를 활용한 분류문제에서 마지막 softmax를 적용하는 층에서 최대 확률이 낮을 경우 다음 에포크에서 M을 크게 부여하는 방식

06 | 동영상 강의

- Photometric Augmentation

- ✓ 색깔에 noise를 주는 방법

- Geometric Augmentation

- ✓ Cutout과 같이 기하적 변형을 주는 방법


[aleju/imgaug: Image augmentation for machine learning experiments. \(github.com\)](https://github.com/aleju/imgaug)

Photometric augmentation



[aleju/imgaug: Image augmentation for machine learning experiments. \(github.com\)](https://github.com/aleju/imgaug)

Geometric augmentation



06 | 동영상 강의

- Self-Supervised Learning (SSL)
 - ✓ 라벨 없이 데이터의 표현을 자가 학습
 - ✓ 예시 : SimCLR, MoCo, SimSiam





Figure 2. Conceptual comparison of three contrastive loss mechanisms (empirical comparisons are in Figure 3 and Table 3). Here we illustrate one pair of query and key. The three mechanisms differ in how the keys are maintained and how the key encoder is updated. (a): The encoders for computing the query and key representations are updated *end-to-end* by back-propagation (the two encoders can be different). (b): The key representations are sampled from a *memory bank* [61]. (c): *MoCo* encodes the new keys on-the-fly by a momentum-updated encoder, and maintains a queue (not illustrated in this figure) of keys.

MoCo

I



SimSiam

- Semi-Supervised Learning (FixMatch)
 - ✓ 비라벨 이미지에 대해 모델이 스스로 임시 정답을 만들고, 같은 이미지의 강한 증강본도 그 정답을 유지하도록 학습하는 방식
 - ✓ 예시 : FixMatch




Figure 1: Diagram of FixMatch. A weakly-augmented image (top) is fed into the model to obtain predictions (red box). When the model assigns a probability to any class which is above a threshold (dotted line), the prediction is converted to a one-hot pseudo-label. Then, we compute the model's prediction for a strong augmentation of the same image (bottom). The model is trained to make its prediction on the strongly-augmented version match the pseudo-label via a cross-entropy loss.

FixMatch
(Image Classification)

Q&A

감사합니다.