



Why Should I Trust You? Explaining the Predictions of Any Classifier

안재국 / 2026.05.26



Computational Data Science LAB



CONTENTS

1. Introduction
 2. Desired Characteristics
 3. Methods
 4. Experiments
 5. Conclusions
- 
- 

01 | Introduction

Why Black-Boxes Need Explanations to Be Trusted

- Background


- ✓ 최근 머신러닝 모델은 의료, 금융, 자율주행 등 high-stakes 의사결정에 사용됨
- ✓ 그러나 대부분의 모델은 "black-box" — 예측의 근거를 알 수 없음
- ✓ 사용자가 모델을 신뢰하지 못하면, 결국 사용되지 않음

- Two Types of Trust

- ✓ 예측 (prediction) 신뢰 : 이 개별 예측을 믿고 행동해도 되는가?
- ✓ 모델 (model) 신뢰 : 실제 환경에 배포해도 되는가?
- ✓ 두 신뢰 모두 사용자가 모델을 이해해야 가능

- Limits of Validation Accuracy

- ✓ Validation 정확도가 높아도 실제 성능을 보장하지 못함 (data leakage, dataset shift)
- ✓ 예측에 대한 설명을 봐야만 발견할 수 있는 결함 존재



02 | Desired Characteristics


Requirements for Trustworthy Explainers

- Interpretable (해석 가능성)
 - ✓ 설명은 사람이 이해할 수 있는 형태여야 함
 - ✓ 수천 개 feature를 모두 보여주기보다 소수의 핵심 근거를 제시
- Locally Faithful (국소 충실성)
 - ✓ 모델 전체가 아니라 설명 대상 x 주변을 잘 설명해야 함
- Model-agnostic (모델 독립성)
 - ✓ 모델 종류에 상관없이 적용 가능한 설명 기법
 - ✓ 입력과 예측값만 있으면 다양한 classifier에 적용 가능
- Global Perspective (전역적 관점)
 - ✓ 단일 예측 설명만으로는 모델 전체를 신뢰할 수 없음
 - ✓ 대표적이고 비중복인 예측들의 집합을 선택해 보여주는 SP-LIME 단계 필요

03 | Methods

LIME: Local Interpretable Model-agnostic Explanations

- What is LIME?
 - ✓ Local Interpretable Model-agnostic Explanations
 - ✓ 임의의 black-box 분류기 f 의 예측을 설명하는 model-agnostic 기법
 - ✓ x 주변에서만 단순한 해석 모델 g 로 f 를 근사
- Local Surrogate Model
 - ✓ 전체 decision boundary는 매우 복잡 / 비선형
 - ✓ 그러나 특정 관측치 x 주변만 보면 단순한 경계로 근사 가능
 - ✓ 이 "국소 근사" 모델 g 가 곧 설명 (explanation)
- Why is it Powerful?
 - ✓ 신경망, 랜덤 포레스트, GBM 등 어떤 모델에도 적용
 - ✓ 텍스트, 이미지, 표 등 모든 데이터 형식에 유연
 - ✓ 사용자가 모델을 이해할 수 있는 형태로 변환



03 | Methods

Speaking the User's Language — Interpretable Features

- Why Separate Representations?

- ✓ 모델이 쓰는 feature (예: word embedding, raw pixel)는 사람에게 무의미
- ✓ 설명에서는 사람이 이해할 수 있는 표현 $x' \in \{0,1\}^{d'}$ 사용
- ✓ $x \in \mathbb{R}^d$ (원본) $\leftrightarrow x' \in \{0,1\}^{d'}$ (해석 가능 binary 벡터)

- Text — Bag of Words


- ✓ x' : 단어 존재 여부를 나타내는 이진 벡터
- ✓ 설명은 복잡한 임베딩값이 아니라, 단어의 포함 여부(1/0) 단위로 표현

- Image — Super-pixel

- ✓ x' : 인접한 유사 픽셀의 그룹(super-pixel)으로 구성된 해석 가능한 표현
- ✓ 원본 이미지는 모든 super-pixel이 존재하는 상태로 표현됨
- ✓ 이후 일부 super-pixel을 0으로 바꿔 교란 샘플을 생성


Text · Bag of Words

"From: paul@mju.ac.kr — DAVID KORESH is GOD"



$x' = [1, 1, 1, 1, 0]$ → binary presence vector

Image · Super-pixel



03 | Methods

Balancing Fidelity and Simplicity

• LIME Objective

- ✓ $\xi(x) = \operatorname{argmin}_{g \in G} L(f, g, \pi_x) + \Omega(g)$
- ✓ $g \in G$: 해석 가능한 설명 모델들의 집합
- ✓ $L(f, g, \pi_x)$: 원래 모델을 얼마나 잘 따라가는지
- ✓ $\Omega(g)$: 설명 모델이 얼마나 복잡한지

• Fidelity Loss


- ✓ $L(f, g, \pi_x) = \sum_{z, z' \in Z} \pi_x(z) (f(z) - g(z'))^2$
- ✓ z' : x' 의 일부 feature를 꺼서 만든 0/1 perturbation sample
- ✓ z : z' 를 원래 데이터 형식으로 복원한 perturbation sample
- ✓ $f(z)$: 원래 black-box 모델의 예측값
- ✓ $g(z')$: 설명 모델 g 의 예측값
- ✓ $\pi_x(z)$: z 가 x 와 가까울수록 커지는 가중치
- ✓ 두 예측값의 차이를 줄일수록 f 를 잘 모방하는 설명 모델

• Complexity Penalty

- ✓ 설명 모델 g 가 복잡할수록 큰 벌점
- ✓ 적은 feature만 사용해 단순하고 이해 가능한 설명 선호

• What does the objective mean?

- ✓ 관측치 x 에 대한 좋은 설명 모델 g 를 찾는 문제
- ✓ 좋은 설명 모델은 원래 모델 f 를 x 주변에서 잘 따라가야 함
- ✓ 동시에 사람이 이해할 수 있을 만큼 단순해야 함



03 | Methods

Learning Explanations from Perturbations · K-LASSO

• Why Sampling?

- ✓ Model-agnostic이므로 모델 내부 구조나 gradient를 볼 필요 없음
- ✓ 대신 x' 의 feature를 일부러 꺾다/켜며 교란 샘플 생성
- ✓ 각 샘플을 f 에 넣어 예측이 어떻게 바뀌는지 관찰
- ✓ 최종적으로 g 의 feature weight가 큰 feature일수록 중요한 feature로 판단

• How to Generate Samples

- ✓ x' 에서 값이 1인 feature 중 일부를 무작위로 선택해 유지하고, 나머지는 0으로 만들어 교란 샘플 z' 생성
- ✓ 생성된 z' 를 원래 입력 형식 z 로 복원 후 $f(z)$ 계산

• Procedure

- ✓ Step 1. N 개 교란 샘플 z' 를 생성하고 $f(z), \pi_x(z)$ 기록
- ✓ Step 2. Lasso 정규화로 중요한 K 개 feature 선택
- ✓ Step 3. 선택된 K 개 feature로 weighted least squares 학습

Algorithm 1 Sparse Linear Explanations using LIME

Require: Classifier f , Number of samples N

Require: Instance x , and its interpretable version x'

Require: Similarity kernel π_x , Length of explanation K

$\mathcal{Z} \leftarrow \{\}$

for $i \in \{1, 2, 3, \dots, N\}$ **do**

$z'_i \leftarrow \text{sample_around}(x')$

$\mathcal{Z} \leftarrow \mathcal{Z} \cup \langle z'_i, f(z_i), \pi_x(z_i) \rangle$

end for


$w \leftarrow \text{K-Lasso}(\mathcal{Z}, K) \triangleright$ with z'_i as features, $f(z)$ as target

return w

$w = [0.42, 0.31, 0.18, -0.07, 0.00]$

$\text{features} = [\text{GOD}, \text{KORESH}, \text{DAVID}, \text{paul}, \text{verdix}]$

Perturbation Sampling around x



03 | Methods

SP-LIME — Building the Explanation Matrix

• Why SP-LIME?

- ✓ LIME은 하나의 instance x 에 대한 local explanation 제공
- ✓ 모델 전체를 신뢰하려면 여러 예측 설명을 함께 봐야 함
- ✓ 모든 explanation을 볼 수 없으므로 대표 설명을 선택해야 함

• Explanation Matrix W


- ✓ 각 instance x_i 에 대해 LIME 설명 모델 g_i 생성
- ✓ 각 설명에서 feature 중요도 w_{g_i} 를 추출
- ✓ 이를 행렬 W 로 정리하여 모델의 판단 근거를 구조화
- ✓ $W_{ij}=|w_{g_{ij}}|$
- ✓ W_{ij} : instance i 의 설명에서 feature j 의 중요도

• Global Feature Importance

$$I_j = \sqrt{\sum_{i=1}^n W_{ij}}$$

- ✓ I_j : feature j 가 전체 explanation에서 얼마나 중요한지
- ✓ 여러 설명에서 자주 나오고 크게 등장할수록 I_j 증가

1. 각 instance에 LIME을 적용 → 설명 모델 g_i 의 feature weight 얻기



2. $W_{ij} = |w_{g_{ij}}| \rightarrow W$ 행렬(절댓값) 구성

W matrix				
	GOD	Posting	Host	Bible
Instance 1	0.8	0.5	0.3	0
Instance 2	0.6	0.7	0	0
Instance 3	0	0	0	0.9

👤 각 행(row) = 하나의 LIME explanation (instance)

📊 각 열(column) = interpretable feature

★ 값 = feature weight의 절댓값
(영향의 크기만 반영)

03 | Methods


SP-LIME — Selecting Representative Explanations

• Coverage Function

- ✓ $c(V, W, I) = \sum_{j=1}^d \mathbb{1}_{[\exists i \in V: W_{ij} > 0]} I_j$
- ✓ 선택된 explanation 집합 V 가 중요한 feature들을 얼마나 cover하는지 측정
- ✓ 선택된 설명 중 하나라도 feature j 를 포함하면 I_j 를 더함
- ✓ 이미 본 feature보다 새로운 중요한 feature를 포함한 설명 선호

• Pick Problem (NP-hard)

- ✓ $Pick(W, I) = \underset{V, |V| \leq B}{\operatorname{argmax}} c(V, W, I)$
- ✓ 예산 B 안에서 coverage가 가장 큰 explanation 집합 선택
- ✓ 즉, 중요한 feature를 많이 보여주면서 중복은 적은 설명을 선택
- ✓ greedy 방식으로 marginal gain이 가장 큰 instance를 순차적으로 선택



04 | Experiments

Case Study 1 — Detecting Dataset Artifacts in Text

- Goal

- ✓ 높은 validation accuracy를 가진 모델이 실제로 올바른 feature를 사용하는지 확인

- Setup

- ✓ Task: 20 Newsgroups Christianity vs Atheism text classification
- ✓ Model: SVM with RBF kernel

- Key Result

- ✓ Algorithm 1 (정상): GOD, mean 등 실제 본문 내용(의미)을 바탕으로 예측
- ✓ validation accuracy 88.6%, real-world accuracy 69.0 %
- ✓ Algorithm 2 (꼼수): Posting, Host 등 내용과 무관한 Header 단어에 의존
- ✓ validation accuracy 94.0%, real-world accuracy 57.3%
- ✓ 원인: Posting 포함 데이터의 99%가 Atheism 클래스인 데이터 왜곡 존재

- Interpretation

- ✓ 높은 accuracy에도 불구하고 모델은 실제 의미가 아닌 dataset artifact(잡음) 를 학습
- ✓ LIME은 validation accuracy만으로 발견하기 어려운 data leakage를 드러냄


Example #3 of 6

True Class:  Atheism

[Instructions](#)

[Previous](#)

[Next](#)



04 | Experiments

Case Study 2 — Are LIME Explanations Faithful?

- Goal
 - ✓ LIME 설명이 실제 모델이 중요하게 사용하는 feature를 잘 찾아내는지 평가
- Setup
 - ✓ Books / DVDs sentiment classification dataset 사용
 - ✓ Sparse Logistic Regression, Decision Tree처럼 실제 중요 feature를 알 수 있는 모델 사용
 - ✓ LIME, Parzen, Greedy, Random 설명 방법 비교
- Key Result
 - ✓ LIME은 두 데이터셋과 두 모델에서 대부분 90% 이상 recall 달성
 - ✓ Recall: LIME이 찾아낸 진짜 중요 피쳐 수/모델이 실제로 사용한 전체 중요 피쳐 수
 - ✓ Random, Parzen, Greedy보다 실제 중요 feature를 더 잘 복원
- Takeaway
 - ✓ LIME 설명은 임의로 만든 설명이 아니라 모델의 실제 판단 근거를 잘 반영




Figure 6: Recall on truly important features for two interpretable classifiers on the books dataset.




Figure 7: Recall on truly important features for two interpretable classifiers on the DVDs dataset.

04 | Experiments

Case Study 3 — Human Evaluation: Choosing the Better Model

- Goal

- ✓ LIME 설명이 사용자의 better classifier 선택을 도와주는지 평가

- Setup


- ✓ 20 Newsgroups 기반 Christianity vs Atheism 분류
- ✓ Original model vs Cleaned model 비교
- ✓ 모델 A(곰수 학습) vs 모델 B(정상 학습)의 설명을 나란히(Side-by-side) 제시
- ✓ 일반 사용자들에게 "실제 환경에 배포할 더 나은 모델을 골라보라"고 요청

- Key Result

- ✓ RP-Greedy: 68% / SP-Greedy: 75%
- ✓ RP-LIME: 80% / SP-LIME: 89%

- Takeaway

- ✓ LIME 설명은 사용자가 더 나은 classifier를 선택하는 데 도움을 줌
- ✓ 특히 SP-LIME은 대표적이고 비중복적인 설명을 보여주어 model selection 성능을 향상시킴




04 | Experiments

Case Study 4 — Human-in-the-loop Feature Engineering

- Goal
 - ✓ LIME 설명을 보고 사람이 잘못된 feature를 제거해 모델을 개선할 수 있는지 평가
- Setup
 - ✓ 20 Newsgroups Christianity vs Atheism task
 - ✓ 원본 데이터로 학습된 untrustworthy classifier 사용
 - ✓ 사용자에게 LIME 설명에 나온 단어들을 제시
 - ✓ 의미 없거나 일반화되지 않을 단어를 삭제하도록 요청
 - ✓ 삭제된 feature를 제외하고 classifier 재학습
- Key Result
 - ✓ Interaction round가 증가할수록 real-world accuracy 향상
 - ✓ SP-LIME이 RP-LIME보다 더 효과적으로 모델 개선
 - ✓ 비전문가도 설명을 보고 feature engineering에 기여 가능

- Takeaway
 - ✓ LIME은 문제를 발견하는 도구를 넘어, 모델을 개선하는 debugging tool로 활용 가능
 - ✓ 설명 가능성은 model trust뿐 아니라 model improvement에도 연결됨



04 | Experiments

Case Study 5 — Right for the Wrong Reason

- Goal
 - ✓ 모델이 정답을 맞더라도 올바른 근거로 판단했는지 확인
- Setup
 - ✓ Wolf images: 눈(snow)이 있는 배경
 - ✓ Husky images: 눈이 없는 배경
 - ✓ 의도적으로 snow와 wolf class가 함께 나타나도록 bad classifier 학습
- Key Result
 - ✓ LIME 설명에서 동물의 얼굴/몸이 아니라 snow 영역이 강조됨
 - ✓ bad model을 신뢰한 사람: 10/27 → 3/27
 - ✓ snow를 potential feature로 언급한 사람: 12/27 → 25/27
- Takeaway
 - ✓ LIME은 모델을 무조건 신뢰하게 만드는 도구가 아님
 - ✓ 오히려 “언제 신뢰하면 안 되는지”를 알려주는 도구



	Before	After
Trusted the bad model	10 out of 27	3 out of 27
Snow as a potential feature	12 out of 27	25 out of 27

05 | Conclusions

Contributions, Limitations & Future Directions

- 본 논문을 한마디로 정의
 - ✓ Black-box 모델의 개별 예측을 사람이 이해 가능한 local explanation으로 설명하는 방법
- 가장 크게 기여한 부분
 - ✓ 모델 내부를 몰라도 적용 가능한 model-agnostic 설명 프레임워크 제안
 - ✓ Local surrogate model을 통해 복잡한 모델을 특정 예측 주변에서만 단순한 모델로 근사해 설명
 - ✓ SP-LIME으로 개별 예측 설명을 모델 선택과 신뢰 판단까지 확장
- 아쉬운 점
 - ✓ Local explanation은 모델의 국소적 판단 근거일 뿐, 인과관계 설명은 아님
- 관련 아이디어
 - ✓ SHAP처럼 feature contribution을 정량화하는 후속 설명 기법과 연결 가능
 - ✓ LIME 설명 결과를 활용해 데이터 누수, 편향, 잘못된 feature 의존성을 점검할 수 있음

Q&A

감사합니다.

01 | 동영상 강의 (추가)

Grad-CAM: Visual Explanations via Gradient-based Localization

- What is Grad-CAM?


- ✓ CNN 기반 이미지 모델이 어느 영역을 보고 예측했는지 시각화하는 방법
- ✓ 마지막 convolution layer의 feature map을 이용해 중요한 영역을 찾음
- ✓ 결과를 heatmap으로 표시하여 모델의 판단 근거를 직관적으로 확인

- Grad-CAM Process

- ✓ Step 1. 이미지와 target class를 CNN에 입력
- ✓ Step 2. 마지막 convolution layer의 feature map 확인
- ✓ Step 3. target class에 대한 gradient 계산
- ✓ Step 4. 중요한 feature map을 가중합하여 heatmap 생성
- ✓ Step 5. 원본 이미지 위에 heatmap overlay

- LIME과의 차이


- ✓ LIME: 입력 일부를 가려보며 예측 변화로 중요한 feature를 찾음
- ✓ Grad-CAM: CNN 내부의 feature map과 gradient를 이용해 중요한 이미지 영역을 찾음
- ✓ 둘 다 모델의 판단 근거를 사람이 이해할 수 있게 보여주는 XAI 기법




| 동영상 강의 (추가)

Grad-CAM: Visual Explanations via Gradient-based Localization

Original



Grad-CAM



53. 20260409165534801_NG.jpg

source=NG_New | type=color | true=NG | pred=NG | p_NG=0.9999, p_OK=0.0001